术语索引表

> 按字母/拼音排序。每个缩写/术语附带**英文全称 + 中文全称**，一句话解释，括号内标注出现在哪些报告中。

> 零基础读者遇到不认识的词，直接 Ctrl+F 搜。

A

术语（英文全称 + 中文）	一句话解释	相关报告
A2A（Agent-to-Agent Protocol，智能体间通信协议）	Google 2025 年推出，解决 Agent 之间怎么互相通信	AI Agent
Adapter（适配器）	在预训练模型层间插入的小型可训练模块，只改不到 1% 的参数就能做微调	PEFT
Agent（智能体）	LLM + 工具 + 记忆 + 自主循环，能自主决策和行动的 AI 实体	AI Agent
AGI（Artificial General Intelligence，通用人工智能）	能在大多数智力任务上达到人类水平的 AI	AI Safety
AI Overviews（AI 概览）	Google 搜索结果页顶部的 AI 生成摘要，2024 年 5 月上线	AI搜索
AIME（American Invitational Mathematics Examination，美国数学邀请赛）	LLM 数学推理能力的基准	LLM大模型
Alignment（对齐）	让模型输出符合人类偏好——"有帮助、诚实、无害"	评估与对齐, AI Safety
AllReduce（全归约）	多卡训练的核心通信操作——每张卡的梯度求和取平均，同步回所有卡	训练框架
ASR（Automatic Speech Recognition，自动语音识别）	把音频转成文字	AI语音
Attention（注意力机制）	Transformer 核心机制——让模型判断句子中哪些词对当前任务最重要	Transformer

B

术语（英文全称 + 中文）	一句话解释	相关报告
BDI（Belief–Desire–Intention，信念–愿望–意图模型）	1987 年提出，将 Agent 内部状态分为信念、愿望、意图三层	AI Agent
Bi–streaming（双向流式处理）	语音对话中同时处理输入和输出，大幅降低延迟	AI语音
Blackwell（NVIDIA Blackwell 架构）	NVIDIA 2024 年发布——双 die 封装，FP4 精度，NVLink 5（1.8 TB/s）	AI芯片格局

C

术语（英文全称 + 中文）	一句话解释	相关报告
C4（Colossal Clean Crawled Corpus，大规模清洗网络语料）	Google 2019 年发布的首个系统化清洗的网页数据集	数据工程
Chatbot Arena（聊天机器人竞技场）	LMSYS 的盲测平台，用 ELO 分数衡量模型相对表现	LLM大模型
Chinchilla（Chinchilla 法则，计算最优模型规模法则）	DeepMind 2022 年提出——模型参数与训练数据量应按约 1:20 匹配	数据工程，Transformer训练
Chiplet（芯粒/小芯片）	把一个大芯片拆成多个小 chiplet 通过高速互联拼在一起	AI芯片格局
CLIP（Contrastive Language-Image Pre-training，对比语言-图像预训练）	OpenAI 2021 年发布，用 4 亿图文对训练模型学会"图文匹配"	多模态大模型
Code Completion（代码补全）	AI 根据上下文补全下一行或下一段代码——AI 编程最基本的能力	AI编程
CommonCrawl（通用网络爬虫）	每月爬取整个互联网的公开网页，是预训练数据的核心来源	数据工程
Constitutional AI（宪法 AI）	Anthropic 的对齐方法——让 AI 根据"宪法"自我评判输出	LLM大模型, AI Safety
Context Window（上下文窗口）	模型一次能"看到"多少 token——从 GPT-1 的 512 到 Gemini 的 200 万	长上下文技术, LLM大模型
Continuous Batching（连续批处理）	推理优化——多个请求动态拼成一批处理，提升 GPU 利用率	Transformer推理部署
ControlNet（控制网络）	Stable Diffusion 生态工具——给图像生成加额外控制条件（如指定人物姿势）	AI图像生成
CoT（Chain-of-Thought，思维链）	让 LLM "一步一步推理"而不是直接给答案，大幅提升推理准确率	Prompt Engineering, AI Agent
CPC（Cost Per Click，按点击付费）	OpenAI 2026 年 4 月在 ChatGPT 搜索中启动的广告模式	AI搜索
CUDA（Compute Unified Device Architecture，统一计算设备架构）	NVIDIA 2007 年推出的 GPU 编程平台，AI 生态最坚固的护城河	AI芯片格局

D

术语（英文全称 + 中文）	一句话解释	相关报告
DCLM（DataComp for Language Models，语言模型数据竞赛）	2024 年提出的标准数据筛选 benchmark，240T token 候选池	数据工程
DDPM（Denoising Diffusion Probabilistic Models，去噪扩散概率模型）	2020 年 Ho 等人论文，第一个系统超越 GAN 的扩散模型，奠定现代扩散模型基础	AI图像生成
Deep Research（深度研究）	AI 搜索模式——不只给出简短答案，而是自动分析数十到数百个网页后生成研究报告	AI搜索
Dense（稠密模型）	传统架构——每个 token 激活全部参数，与 MoE（只激活部分）相对	LLM大模型, MoE
DiT（Diffusion Transformer，扩散 Transformer）	用 Transformer 替代 U-Net 做扩散模型主体，2024 年起成为图像/视频生成主流	AI图像生成, AI视频生成
DPO（Direct Preference Optimization，直接偏好优化）	2023 年 Stanford 提出——不需训练奖励模型，直接用偏好数据做优化	Post-training RL, 评估与对齐
Durable Execution（持久化执行）	Agent 在任何步骤中断后都能恢复，Temporal 是代表方案	Agent Runtime

E

术语（英文全称 + 中文）	一句话解释	相关报告
Early Fusion（早融合，原生多模态架构）	图像和文本在 token 层面统一表示，不依赖独立的视觉编码器	多模态大模型
ELO（Elo Rating System，埃洛评分系统）	源于国际象棋的排名系统，Chatbot Arena 用它衡量模型在盲测中的相对表现	LLM大模型
Embedding（嵌入/向量表示）	把文字/图片转换成模型能理解的数字向量——"语义相近的内容数学上接近"	RAG, 多模态大模型
Encoder-only / Decoder-only（仅编码器/仅解码器）	Transformer 两种变体——BERT 只用编码器（理解），GPT 只用解码器（生成）	Transformer

F

术语（英文全称 + 中文）	一句话解释	相关报告
FineWeb（精炼网络数据）	HuggingFace 2024 年发布的 15T token 高质量预训练数据集及方法论	数据工程
FlashAttention（快速注意力）	2022 年提出，通过 IO 优化让注意力计算接近 O(N)，实际训练快 2–4 倍	Transformer训练, 长上下文技术
Fork IDE（分支式集成开发环境）	拿开源 IDE（VS Code）改造成 AI 原生编辑器，Cursor 是代表	AI编程
FP4 / FP8 / FP16（Float Point，浮点精度）	数字越小计算越快、显存越省。2026 年已能做到 FP4 训练匹配 FP16 准确度	AI芯片格局, 模型压缩
FSDP（Fully Sharded Data Parallelism，全分片数据并行）	PyTorch 原生支持的分布式训练策略——模型参数分片存储在多张 GPU 上	训练框架
Function Calling（函数调用/工具调用）	OpenAI 2023 年 6 月引入，让 LLM 输出结构化 API 调用请求	AI Agent, LLM应用框架

G

术语（英文全称 + 中文）	一句话解释	相关报告
GAN（Generative Adversarial Network，生成对抗网络）	2014 年提出——生成器和判别器对抗博弈来生成内容，图像生成的起点	AI图像生成, AI视频生成
GGUF（GPT-Generated Unified Format，GPT 通用量化格式）	llama.cpp 的量化模型格式，能在普通电脑本地运行 LLM	模型压缩
GQA（Grouped Query Attention，分组查询注意力）	多查询注意力的折中方案——分组共享 Key-Value，平衡效率与质量	长上下文技术
GPTQ / AWQ（GPT 量化/激活感知权重量化）	两种主流的 4-bit 量化方法——用极低精度损失换取大幅显存节省	模型压缩
GRPO（Group Relative Policy Optimization，分组相对策略优化）	DeepSeek 2024 年提出——同一批生成回答互相比较，不需 critic 模型	Post-training RL, 评估与对齐
Guardrails（护栏）	Agent 的安全过滤层——话题限制、内容安全、越狱检测	Agent Runtime, AI Safety

H

术语（英文全称 + 中文）	一句话解释	相关报告
Hallucination（幻觉）	模型"编造"不存在的答案——AI 搜索和 LLM 的最大风险之一	AI搜索, LLM大模型
Harness（夹具/控制面）	Agent 的控制层——沙箱、护栏、权限、状态持久化。2026 年被定义为正式工程领域	Agent Runtime, AI Agent
HBM（High Bandwidth Memory，高带宽内存）	AI 芯片的核心存储——制约芯片性能的战略瓶颈	AI芯片格局
HumanEval（人类评估基准）	OpenAI 发布的代码生成基准，测试 LLM 写代码的准确率	LLM大模型, AI编程
Human-in-the-Loop（人在回路）	人类在关键步骤介入 Agent 决策循环，防止全自动出错	Agent Runtime, AI Agent

I

术语（英文全称 + 中文）	一句话解释	相关报告
Identity Drift（身份漂移/角色漂移）	视频生成中人物在连续帧中"变脸"——AI 视频最头疼的问题之一	AI视频生成
InfiniBand（无限带宽）	NVIDIA（Mellanox）的高速互联网络方案，万卡 GPU 集群的通信基石	AI芯片格局

K

术语（英文全称 + 中文）	一句话解释	相关报告
KV Cache（键值缓存）	推理时缓存已计算的 Key-Value 注意力矩阵，避免重复计算，显存占用随序列长度线性增长	Transformer推理部署, 长上下文技术

L

术语（英文全称 + 中文）	一句话解释	相关报告
LLM（Large Language Model，大语言模型）	在海量文本上预训练的生成式语言模型——所有 AI 应用的底层引擎	LLM大模型
LoRA（Low-Rank Adaptation，低秩适配）	在模型权重旁加"低秩更新"矩阵，只改几千个参数就能做微调	PEFT, AI图像生成

M

术语（英文全称 + 中文）	一句话解释	相关报告
MCP（Model Context Protocol，模型上下文协议）	Anthropic 2024 年底推出——标准化 Agent 与工具的连接方式，被称为"AI 的 USB-C"	AI Agent, LLM应用框架
MCTS（Monte Carlo Tree Search，蒙特卡洛树搜索）	像下棋 AI 一样，在推理时探索多条路径并选最佳——o3 的核心机制	Post-training RL
MLA（Multi-head Latent Attention，多头潜在注意力）	DeepSeek 提出——大幅降低 KV Cache，让推理成本降到同级模型的 1/3	MoE, Transformer推理部署
MLP（Multi-Layer Perceptron，多层感知器）	最简单的视觉-文本连接方案——几层神经网络直接把视觉 token 映射到 LLM 空间	多模态大模型
MMLU（Massive Multitask Language Understanding，大规模多任务语言理解）	57 个学科（物理到法律）的综合知识测试——LLM 核心基准	LLM大模型, 评估与对齐
MMLU-Pro（MMLU 增强版）	MMLU 的加强版，更难的推理题	LLM大模型
Model Collapse（模型崩溃）	合成数据训练过多后模型性能回退——多样性下降、长尾知识丢失	数据工程
MoE（Mixture of Experts，混合专家）	把大模型拆成多个"专家"，每个 token 只激活其中几个。2024-2026 年主流架构	MoE, LLM大模型
MQA（Multi-Query Attention，多查询注意力）	Key-Value 在所有注意力头之间共享——大幅减少 KV Cache，速度更快	长上下文技术

N

术语（英文全称 + 中文）	一句话解释	相关报告
NVLink（NVIDIA 高速互联）	NVIDIA GPU 之间的专用高速通信链路，多卡训练的通信基石	AI芯片格局, 训练框架

O

术语（英文全称 + 中文）	一句话解释	相关报告
Omni（全模态）	来自拉丁语 "omnis"（全部）——一个模型统一处理文本+图像+音频+视频	LLM大模型, 多模态大模型

P

术语（英文全称 + 中文）	一句话解释	相关报告
PagedAttention（分页注意力）	vLLM 核心创新——把 KV Cache 像操作系统分页一样管理，解决显存碎片化	Transformer推理部署
Parameter（参数）	模型内部的可调节"刻度盘"。1B = 10 亿参数，主流 LLM 在 7B–671B 之间	LLM大模型
PEFT（Parameter-Efficient Fine-Tuning，参数高效微调）	冻结模型绝大部分参数，只训练极小比例的额外参数来做微调	PEFT
Perceiver Resampler（感知器重采样器）	Flamingo 的连接器——视觉信号在 LLM 每一层都通过交叉注意力注入	多模态大模型
Pipeline Bubble（流水线气泡）	流水线并行中 GPU 空闲等待的时间空隙，bubble 越小效率越高	训练框架
PPO（Proximal Policy Optimization，近端策略优化）	最主流的 RL 算法——"小步更新"，防止模型步子太大导致崩溃	Post-training RL
Prompt Engineering（提示工程）	设计和优化给 LLM 的提示词，让模型输出更好结果的技术	Prompt Engineering
Prompt Injection（提示注入攻击）	攻击者通过恶意输入操纵 Agent 执行危险操作——Agent 安全的核心威胁	AI Agent

Q

术语（英文全称 + 中文）	一句话解释	相关报告
Q-Former（Query-Former，查询变换器）	BLIP-2 核心——用可学习 query 向量从视觉输出中提取关键信息、压缩成少量 token	多模态大模型
QKV（Query-Key-Value，查询-键-值机制）	自注意力核心——Query 查什么、Key 匹配什么、Value 提取什么	Transformer
QLoRA（Quantized LoRA，量化低秩适配）	模型先量化为 4-bit，再做 LoRA 微调——让消费级 GPU 也能微调大模型	PEFT
Quantization（量化）	把模型参数从 FP16 压到 INT4/INT8 等低精度，大幅减少显存和推理成本	模型压缩

R

术语（英文全称 + 中文）	一句话解释	相关报告
RAG（Retrieval-Augmented Generation，检索增强生成）	大模型"先查资料再回答"——AI 搜索和知识库的核心技术	RAG, AI搜索
ReAct（Reasoning + Acting，推理-行动协同）	2022 年 Yao et al. 提出——推理和行动交错循环，几乎所有现代 Agent 的底层设计	AI Agent
Red Teaming（红队测试）	组织团队尝试攻击自己的 AI 系统，找到漏洞后修复——AI 安全标准实践	AI Safety
RL（Reinforcement Learning，强化学习）	智能体通过试错学习——做对了得奖励，做错了受罚，目标是最大化累计奖励	Post-training RL
RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）	让人类标注者评判模型输出，然后训练模型对齐人类偏好	Post-training RL, 评估与对齐
ROCm（Radeon Open Compute，AMD 开源计算平台）	AMD 的 GPU 编程平台，对标 CUDA，开源但生态成熟度逊于 CUDA	AI芯片格局
RoPE（Rotary Position Embedding，旋转位置编码）	最主流的位置编码方案——通过旋转变换让序列长度可以灵活外推	长上下文技术, Transformer
Rubin（NVIDIA Vera Rubin 架构）	NVIDIA 2026 年下半年投产——首款 HBM4 GPU（288GB），50 PFLOPs 算力	AI芯片格局

S

术语（英文全称 + 中文）	一句话解释	相关报告
Sandbox（沙箱）	隔离的执行环境——Agent 在其中运行代码但无法影响外部系统	Agent Runtime
Scaling Law（规模定律/缩放法则）	模型性能与参数量、数据量、计算量之间的幂律关系——"更大就更好"的理论基础	Transformer, LLM大模型
SigLIP（Sigmoid Loss for Language-Image Pre-training，Sigmoid 损失语言-图像预训练）	CLIP 改进版——用 sigmoid loss 替代 softmax，小 batch 也能高效训练	多模态大模型
Speculative Decoding（投机解码/推测解码）	用小模型快速"猜测"输出，大模型验证——不损失质量但速度提升 2-3 倍	Transformer推理部署
SWE-bench（Software Engineering Benchmark，软件工程基准）	根据 GitHub Issue 修 Bug 让测试通过——AI 编程能力的核心基准	AI编程, LLM大模型

T

术语（英文全称 + 中文）	一句话解释	相关报告
Tensor Core（张量核心）	NVIDIA GPU 中专为矩阵乘法设计的硬件单元——效率是普通核心的 8–16 倍	AI芯片格局
Test-time Compute Scaling（推理时计算扩展）	推理时花更多算力"思考"，比训练时花更多算力更划算——o1/R1/o3 路线	Post-training RL
Token（词元/令牌）	模型处理文本的最小单位。"你好世界" = 4 token，"Hello world" = 2 token	LLM大模型
Transformer（变换器）	2017 年 Google 提出——完全基于自注意力的神经网络架构，驱动了全球几乎所有大模型	Transformer, LLM大模型
Triton（OpenAI 开源 GPU 编程语言）	写一次就能在 NVIDIA/AMD/Intel 上跑，正在削弱 CUDA 锁定效应	AI芯片格局
TTS（Text-to-Speech，文字转语音/语音合成）	把文本合成为人声	AI语音
TTFB（Time To First Byte，首包时间）	从用户说完话到 AI 开始回话的延迟——语音对话核心指标	AI语音

V

术语（英文全称 + 中文）	一句话解释	相关报告
VAE（Variational Autoencoder，变分自编码器）	把图片压缩到小巧的"潜在空间"，在这里做扩散，再解压回高清图	AI图像生成
Vibe Coding（氛围编程/直觉编程）	Andrej Karpathy 创造——用自然语言描述需求，让 AI 生成代码，完全"凭感觉"	AI编程
vLLM（虚拟大语言模型推理引擎）	UC Berkeley 2023 年发布——PagedAttention 解决 KV Cache 显存碎片化	Transformer推理部署

W

术语（英文全称 + 中文）	一句话解释	相关报告
Whisper（OpenAI 语言识别模型）	OpenAI 2022 年开源——68 万小时多语言数据训练，支持 99 种语言	AI语音
World Model（世界模型）	AI 不仅生成画面，还理解三维结构、重力、光影等物理规律——视频生成的终极方向	AI视频生成

Z

术语（英文全称 + 中文）	一句话解释	相关报告
ZeRO（Zero Redundancy Optimizer，零冗余优化器）	DeepSpeed 内存优化策略——优化器状态、梯度、参数分片存储	训练框架, Transformer 训练
Distillation（蒸馏）	用大模型（教师）输出来训练小模型（学生），让小模型继承大模型能力	模型压缩
Self-Attention（自注意力）	Transformer 核心——让句子中任意两个词直接交互，捕捉全局依赖	Transformer
Visual Grounding（视觉定位）	多模态模型不仅能"看懂"图片，还能"指出"物体位置	多模态大模型
Gated Cross-Attention（门控交叉注意力）	Flamingo 连接器机制——LLM 每一层决定"这一层要不要看图片"	多模态大模型