# 术语索引表

> 按字母/拼音排序，一个词一句话解释，括号内标注该术语在哪些报告中出现。

> 零基础读者遇到不认识的词，直接 Ctrl+F 搜。

## A

| 术语 | 一句话解释 | 相关报告 |
|---|---|---|
| **A2A** | Agent-to-Agent 协议，Google 2025 年推出，解决 Agent 之间怎么互相通信 | AI Agent, LLM应用框架 |
| **Adapter（适配器）** | 在预训练模型层间插入的小型可训练模块，只改不到 1% 的参数就能做微调 | PEFT |
| **Agent（智能体）** | LLM + 工具 + 记忆 + 自主循环，能自主决策和行动的 AI 实体 | AI Agent |
| **Agentic Engineering** | 用 AI Agent 来辅助或替代人类做软件工程 | AI编程, AI Agent |
| **AGI** | Artificial General Intelligence，通用人工智能——能在大多数智力任务上达到人类水平的 AI | AI Safety, LLM大模型 |
| **AI Overviews** | Google 搜索结果页顶部的 AI 生成摘要，2024 年 5 月上线 | AI搜索 |
| **AIME** | 美国数学邀请赛（American Invitational Mathematics Examination），被用作 LLM 数学推理能力的基准 | LLM大模型 |
| **Alignment（对齐）** | 让模型输出符合人类偏好——"有帮助、诚实、无害" | 评估与对齐, AI Safety |
| **ASR** | Automatic Speech Recognition，语音识别——把音频转成文字 | AI语音 |
| **Attention（注意力机制）** | Transformer 的核心机制，让模型判断句子中哪些词对当前任务最重要 | Transformer, LLM大模型 |

## B

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **BDI 模型** | Belief-Desire-Intention，1987 年提出，定义 Agent 的信念/愿望/意图三个内部状态 | AI Agent |
| **Benchmark（基准测试）** | 一套标准化题目用来评估和比较不同模型的能力 | LLM大模型，评估与对齐 |
| **Bi-streaming** | 双向流式——语音对话中同时处理输入和输出，大幅降低延迟 | AI语音 |
| **Blackwell** | NVIDIA 2024 年发布的 GPU 架构，2080 亿晶体管，双 die 封装 | AI芯片格局 |

## C

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **C4** | Colossal Clean Crawled Corpus，Google 发布的首个系统化清洗的网页数据集 | 数据工程 |
| **Chatbot Arena** | LMSYS 的盲测平台，用户对比两个模型的回答后投票，计算 ELO 分数 | LLM大模型 |
| **Chinchilla 法则** | DeepMind 2022 年提出：模型参数和训练数据量应按约 1:20 的比例匹配 | 数据工程, Transformer训练 |
| **Chiplet** | 把一个大芯片拆成多个小芯片（chiplets）通过高速互联拼在一起 | AI芯片格局 |
| **CLIP** | OpenAI 2021 年发布，用 4 亿对图文数据训练，让模型学会"图文是否匹配" | 多模态大模型, AI图像生成 |
| **Code Completion（代码补全）** | AI 根据上下文补全下一行或下一段代码 | AI编程 |
| **CommonCrawl** | 非营利项目，每月爬取整个互联网的公开网页，是预训练数据的核心来源 | 数据工程 |
| **Constitutional AI** | Anthropic 的对齐方法——让 AI 根据一份"宪法"（行为准则）自我评判输出 | LLM大模型, AI Safety |
| **Context Window（上下文窗口）** | 模型一次能"看到"多少 token。从 GPT-1 的 512 到 Gemini 的 200 万 | 长上下文技术, LLM大模型 |
| **Continuous Batching** | 推理优化技术——多个请求动态拼成一批一起处理，提升 GPU 利用率 | Transformer推理部署 |
| **ControlNet** | Stable Diffusion 生态的工具——给生成过程加额外控制条件（如指定人物姿势） | AI图像生成 |
| **CoT（Chain-of-Thought，思维链）** | 让 LLM "一步一步推理"而不是直接给答案，大幅提升推理准确率 | Prompt Engineering, AI Agent |
| **CPC 广告** | 按点击付费（Cost Per Click）——OpenAI 2026 年 4 月在 ChatGPT 搜索中启动 | AI搜索 |
| **CUDA** | NVIDIA 的 GPU 编程平台，2007 年发布，是 AI 芯片生态最坚固的护城河 | AI芯片格局, Transformer训练 |
| **Custom Silicon（自研芯片）** | 云厂商自己设计 AI 芯片而不买 NVIDIA 的——Google TPU、AWS Trainium 等 | AI芯片格局 |

## D

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **DCLM** | DataComp for Language Models——2024 年提出的标准数据筛选 benchmark | 数据工程 |
| **DDPM** | Denoising Diffusion Probabilistic Models，2020 年奠定现代扩散模型基础的论文 | AI图像生成 |
| **Dense 模型** | 传统架构——每个 token 激活模型的所有参数，与 MoE（只激活部分）相对 | LLM大模型, MoE |
| **DiT（Diffusion Transformer）** | 用 Transformer 替代 U-Net 做扩散模型的主体，2024 年起成为图像/视频生成主流架构 | AI图像生成, AI视频生成 |
| **DPO** | Direct Preference Optimization，2023 年 Stanford 提出的简化对齐方法——不需要训练奖励模型 | Post-training RL, 评估与对齐 |
| **Durable Execution** | Agent 在任何步骤中断后都能恢复到中断前的状态继续执行 | Agent Runtime |
| **动态分辨率** | 根据图片实际尺寸动态决定切分方式，而非把所有图片缩放到固定尺寸 | 多模态大模型 |

## E

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Early Fusion（早融合）** | 原生多模态架构——图像和文本在 token 层面统一表示，不加单独视觉编码器 | 多模态大模型 |
| **ELO 评分** | 源于国际象棋的排名系统，Chatbot Arena 用它来衡量模型在盲测中的相对表现 | LLM大模型 |
| **Embedding（嵌入）** | 把文字/图片转换成模型能理解的数字向量 | RAG, 多模态大模型 |
| **Encoder-only / Decoder-only** | Transformer 的两种变体——BERT 只用编码器（理解），GPT 只用解码器（生成） | Transformer |
| **Ethical AI（AI 伦理）** | 确保 AI 系统的设计和使用不伤害人类、不制造偏见、不侵犯隐私 | AI Safety |

## F

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **FineWeb / FineWeb-Edu** | HuggingFace 2024 年发布的 15T token 高质量预训练数据集和筛选方法论 | 数据工程 |
| **FlashAttention** | 2022 年提出，通过 IO 优化让注意力计算从 $O(N^2)$ 降到接近 O(N)，实际训练快 2-4 倍 | Transformer训练, 长上下文技术 |
| **Fork IDE** | 拿开源 IDE（VS Code）改造成 AI 原生编辑器，Cursor 就是这条路 | AI编程 |
| **FP4 / FP8 / FP16** | 浮点精度——数字越小计算越快、显存越省，但精度越低。2026 年已能做到 FP4 训练 | AI芯片格局, 模型压缩 |
| **FSDP** | Fully Sharded Data Parallelism，把模型参数分片存储在多张 GPU 上，PyTorch 原生支持 | 训练框架 |
| **Function Calling（工具调用）** | OpenAI 2023 年 6 月引入，让 LLM 输出结构化的 API 调用请求 | AI Agent, LLM应用框架 |

## G

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **GAN（生成对抗网络）** | 2014 年提出，生成器和判别器对抗博弈来生成内容——图像生成的起点 | AI图像生成, AI视频生成 |
| **GGUF** | GPT-Generated Unified Format，llama.cpp 的量化模型格式，能在普通电脑上跑 LLM | 模型压缩 |
| **GPTQ / AWQ** | 两种主流的 4-bit 量化方法——用极低的精度损失换取大幅显存节省 | 模型压缩 |
| **GRPO** | Group Relative Policy Optimization，DeepSeek 提出的 RL 算法——同一批生成的多个回答互相比较，不需要 critic 模型 | Post-training RL, 评估与对齐 |
| **Guardrails（护栏）** | Agent 的安全过滤层——话题限制、内容安全、越狱检测 | Agent Runtime, AI Safety |

## H

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Hallucination（幻觉）** | 模型"编造"不存在的答案——AI 搜索的最大风险之一 | AI搜索, LLM大模型 |
| **Harness** | Agent 的控制面——负责沙箱、护栏、权限、状态持久化、人机协作。2026 年被定义为正式工程领域 | Agent Runtime, AI Agent |
| **HBM（High Bandwidth Memory）** | 高带宽内存——AI 芯片的核心存储，制约芯片性能的战略瓶颈 | AI芯片格局 |
| **HumanEval** | OpenAI 发布的代码生成基准，测试 LLM 写代码的准确率 | LLM大模型, AI编程 |
| **Human-in-the-Loop** | 人类在关键步骤介入 Agent 的决策循环，防止全自动出错 | Agent Runtime, AI Agent |

## I

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Identity Drift（身份漂移）** | 视频生成中人物在连续帧中"变脸"——AI 视频生成最头疼的问题之一 | AI视频生成 |
| **InfiniBand** | NVIDIA 下属 Mellanox 的高速网络方案，万卡 GPU 集群的通信基石 | AI芯片格局 |
| **InstructGPT** | OpenAI 2022 年 3 月论文——用 RLHF 对齐语言模型，是 ChatGPT 的前身 | Post-training RL, 评估与对齐 |

## K

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **KV Cache** | 推理时缓存已计算的 Key-Value 注意力矩阵，避免重复计算——显存占用与序列长度成正比 | Transformer推理部署, 长上下文技术 |

## L

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **LoRA** | Low-Rank Adaptation，在预训练模型的权重旁加"低秩更新"矩阵，只改几千个参数就能做微调 | PEFT, AI图像生成 |
| **LLM（大语言模型）** | 在海量文本上预训练的生成式语言模型——所有 AI Agent、AI 搜索、AI 编程的底层引擎 | LLM大模型 |

## M

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **MCP** | Model Context Protocol，Anthropic 2024 年底推出的开放协议——标准化 Agent 与工具的连接方式，被称为"AI 的 USB-C" | AI Agent, LLM应用框架 |
| **MCTS（蒙特卡洛树搜索）** | 像下棋 AI 一样，在推理时探索多条推理路径并选最佳——o3 的核心机制 | Post-training RL |
| **MLA** | Multi-head Latent Attention，DeepSeek 提出——大幅降低 KV Cache，推理成本降到同级模型的 1/3 | MoE, Transformer推理部署 |
| **MLP 连接器** | 最简单的视觉-文本连接方案——几层神经网络直接映射 token | 多模态大模型 |
| **MMLU** | Massive Multitask Language Understanding，57 个学科（物理到法律）的综合知识测试 | LLM大模型, 评估与对齐 |
| **MMLU-Pro** | MMLU 的加强版，更难的推理题 | LLM大模型 |
| **Model Collapse（模型崩溃）** | 合成数据训练过多后模型性能开始回退——多样性下降、长尾知识丢失 | 数据工程 |
| **MoE（混合专家）** | 把大模型拆成多个"专家"，每个 token 只激活其中几个——2024-2026 年主流架构 | MoE, LLM大模型 |

## N

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **NVLink** | NVIDIA 的 GPU 之间高速互联技术——多卡训练的通信基石 | AI芯片格局, 训练框架 |

## O

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **o1 / o3（推理模型）** | OpenAI 的推理时计算扩展模型——回答前先"思考"，在数学和编程上大幅领先 | Post-training RL, LLM大模型 |
| **Omni（全模态）** | 统一处理文本+图像+音频+视频的模型（如 GPT-4o、Qwen3.5-Omni） | 多模态大模型, LLM大模型 |

## P

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **PagedAttention** | vLLM 的核心创新——把 KV Cache 像操作系统分页一样管理，解决显存碎片化问题 | Transformer推理部署 |
| **参数（Parameter）** | 模型内部的可调节"刻度盘"。1B = 10 亿参数。当前主流 LLM 在 7B–671B 之间 | LLM大模型 |
| **Perceiver Resampler** | Flamingo 的连接器——用固定 query 压缩视觉特征，视觉信号在 LLM 每一层都注入 | 多模态大模型 |
| **Pipeline Bubble（流水线气泡）** | 流水线并行中 GPU 空闲等待的时间，bubble 越小效率越高 | 训练框架 |
| **PPO** | Proximal Policy Optimization，最主流的 RL 算法——"小步更新"，防止模型步子太大崩溃 | Post-training RL |
| **Prompt Engineering** | 设计和优化给 LLM 的提示词，让模型输出更好结果的技术 | Prompt Engineering |
| **Prompt Injection** | 攻击者通过恶意输入操纵 Agent 执行危险操作——Agent 安全的核心威胁 | AI Agent |

## Q

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Q-Former** | BLIP-2 的核心——用一组可学习的 query 向量从视觉输出中提取关键信息、压缩成少量 token | 多模态大模型 |
| **QKV 机制** | 自注意力的核心——Query 查什么、Key 匹配什么、Value 提取什么 | Transformer |
| **QLoRA** | Quantized LoRA——把模型先量化为 4-bit，再做 LoRA 微调，让消费级 GPU 也能微调大模型 | PEFT |
| **量化（Quantization）** | 把模型参数从高精度（FP16）压到低精度（INT4 等），大幅减少显存和推理成本 | 模型压缩 |

## R

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **RAG** | Retrieval-Augmented Generation，大模型"先查资料再回答"——AI 搜索和知识库的核心技术 | RAG, AI搜索 |
| **ReAct** | Reasoning + Acting，2022 年提出——推理和行动交错循环，几乎所有现代 Agent 的底层设计模式 | AI Agent |
| **Red Teaming** | 组织团队尝试攻击自己的 AI 系统，找到漏洞后修复——AI 安全的标准实践 | AI Safety |
| **Reinforcement Learning（强化学习/RL）** | 智能体通过试错学习——做对了得奖励，做错了受罚，目标是最大化累计奖励 | Post-training RL |
| **RLHF** | 基于人类反馈的强化学习——让人类标注者评判模型输出，然后训练模型对齐人类偏好 | Post-training RL, 评估与对齐 |
| **ROCm** | AMD 的 GPU 编程平台——对标 CUDA，开源，但生态成熟度逊于 CUDA | AI芯片格局 |
| **RoPE** | Rotary Position Embedding，目前最主流的位置编码方案——旋转式编码让序列长度可以灵活外推 | 长上下文技术, Transformer |
| **Rubin** | NVIDIA 2026 年下半年全面投产的下一代 GPU 架构——288GB HBM4，首款 HBM4 GPU | AI芯片格局 |

## S

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Sandbox（沙箱）** | 隔离的执行环境——Agent 在其中运行但无法影响外部系统 | Agent Runtime |
| **Scaling Law** | 模型性能与参数量、训练数据量、计算量之间的数学关系——"模型越大越好"的理论基础 | Transformer, LLM大模型 |
| **SigLIP** | CLIP 的改进版——用 sigmoid loss 替代 softmax 对比损失，小 batch 也能训练 | 多模态大模型 |
| **Speculative Decoding（投机解码）** | 用小模型快速"猜测"输出，大模型验证——不损失质量但速度提升 2-3 倍 | Transformer推理部署 |
| **SWE-bench** | AI 软件工程能力的基准测试——根据 GitHub Issue 修 Bug 让测试通过 | AI编程, LLM大模型 |

## T

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Tensor Core** | NVIDIA GPU 中专为矩阵乘法设计的硬件单元——一次执行 4×4 矩阵乘法，效率是普通核心的 8–16 倍 | AI芯片格局 |
| **Test-time Compute Scaling（推理时计算扩展）** | 在推理时花更多算力"思考"，比在训练时花更多算力"学习"更划算 | Post-training RL |
| **Token** | 模型处理文本的最小单位。"你好世界"=4 token，"Hello world"=2 token | LLM大模型 |
| **Tool Calling** | 见 Function Calling | AI Agent |
| **Transformer** | 2017 年 Google 提出——完全基于自注意力的神经网络架构，驱动了全球几乎所有大模型 | Transformer, LLM大模型 |
| **Triton** | OpenAI 的 GPU 编程语言——写一次就能在 NVIDIA/AMD/Intel 上运行，正在削弱 CUDA 的锁定效应 | AI芯片格局 |
| **TTS** | Text-to-Speech，文字转语音——把文本合成为人声 | AI语音 |
| **TTFB** | Time To First Byte，首包时间——语音对话中从用户说完到 AI 开始回话的延迟时间，核心指标 | AI语音 |

## V

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **VAE（变分自编码器）** | 把图片压缩到小巧的"潜在空间"，在这个压缩空间里做扩散，再把结果解压回高清图 | AI图像生成 |
| **Vibe Coding** | Andrej Karpathy 创造的词——用自然语言描述需求，让 AI 生成代码，完全"凭感觉"编程 | AI编程 |
| **vLLM** | UC Berkeley 的推理引擎（2023），PagedAttention 解决了 KV Cache 显存碎片化问题 | Transformer推理部署 |

## W

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **Whisper** | OpenAI 2022 年开源的语音识别模型，68 万小时多语言数据训练，99 种语言 | AI语音 |
| **世界模型** | AI 不仅生成画面，还理解物体的三维结构、重力、光影等物理规律——视频生成的终极方向 | AI视频生成 |

## Z

| 术语 | 一句话解释 | 相关报告 |
| --- | --- | --- |
| **ZeRO** | DeepSpeed 的内存优化策略——把优化器状态、梯度、参数分片存储在集群各 GPU 上 | 训练框架, Transformer 训练 |
| **蒸馏（Distillation）** | 用大模型（教师）的输出来训练小模型（学生），让小模型继承大模型的能力 | 模型压缩 |
| **自注意力（Self-Attention）** | Transformer 的核心机制——让句子中任意两个词直接交互，捕捉全局依赖关系 | Transformer |