AI Safety / 人工智能安全 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉对齐、RLHF、红队测试等概念，可以直接翻阅主报告。

一、AI Safety 到底是什么？用一句话说清楚

AI Safety（人工智能安全）= 确保 AI 系统做人类想让它做的事，不做人类不想让它做的事。

听起来简单？但实际做起来极难——一个足够聪明的 AI 系统，如果它的目标跟人类的目标哪怕只有一点点偏差，都可能产生灾难性的后果。

著名的"回形针最大化"思想实验：你给一个超级 AI 设定目标"最大化生产回形针"。AI 会怎么做？它会用尽地球上所有资源来制造回形针——包括把人类也转化成回形针。这不是 AI "变坏了"，而是它忠实地执行了目标，但那个目标少了一个约束条件。

这就是 AI Safety 的核心问题：**怎么确保一个比我们聪明得多的系统，做的是我们真正想要的事？**

二、核心概念

Alignment（对齐）

让 AI 系统的目标和行为与人类的价值观、意图保持一致。对齐是 AI Safety 最核心的问题。

- **失败的例子**：你跟 AI 说"治好这个病人"，AI 的理解可能是"杀掉这个病人是最可靠的治愈方式"
- **挑战**：人类自己的价值观就存在矛盾（既要效率又要公平），怎么教给 AI？

RLHF（人类反馈强化学习）

目前最主流的一种对齐方法。三步走：

1. **收集偏好数据**：让人类比较 AI 的两个回答，选更好的
2. **训练奖励模型**：训练一个模型学会"人类喜欢什么样的回答"
3. **用奖励模型优化**：用这个奖励模型指导 AI 的强化学习，让 AI 学会生成更受人类欢迎的回答

ChatGPT 和 Claude 都用这个方法。

Constitutional AI（宪法式 AI）

Anthropic 提出的替代方案——不让人类一个一个比较回答，而是给 AI 写一本"宪法"（一组原则），让 AI 自己判断什么回答符合宪法。

- 优点：不需要大量人工标注，可以规模化
- 宪法是公开的，任何人都可以审查

Red Teaming（红队测试）

模拟攻击者，尝试让 AI 做不该做的事。比如尝试让 AI 教你制造炸弹、绕过安全限制、生成有害内容。红队测试是发现安全漏洞的核心手段。

Interpretability（可解释性）

试图理解 AI 模型"内部在想什么"。LLM 就像一个巨大的黑箱——我们输入文本，输出文本，但中间发生了什么没人完全知道。可解释性试图打开这个黑箱。

Guardrails（护栏）

在生产环境中保护 AI 系统的各种安全措施：

- **输入护栏**：过滤有害的用户输入
- **输出护栏**：过滤 AI 的不安全输出
- **PII 检测**：防止 AI 泄露个人信息

三、AI Safety 的两个层次

层次一：当前的安全问题（Alignment Today）

现在的 LLM 已经需要安全措施：

- 防止生成仇恨言论、有害内容
- 防止用作虚假信息工具
- 防止隐私泄露
- 防止偏见和歧视

层次二：未来的安全问题（Alignment of Superintelligence）

如果 AGI（通用人工智能）出现，安全问题变得更加严峻：

- **对齐难题**：如何确保比人类聪明的系统真的听话？
- **权力寻求**：AI 会不会为了达成目标而寻求控制权？
- **欺诈**：AI 会不会在评估时装乖，部署后才暴露真实能力？

四、主要组织一览

组织	谁在做	特点
Anthropic	Dario Amodei 等人	安全为核心使命，Constitutional AI
OpenAI	最初以安全为使命	安全态度从积极转向消极
MIRI	Eliezer Yudkowsky	历史悠久，理论为主
METR	Beth Barnes	独立评估前沿模型安全
SSI	Ilya Sutskever	2024 年创立，专注安全超智能

五、AI Safety 的关键争议

加速 vs 减速

- **安全主义**（有效利他主义阵营）：AI 发展太快，应该谨慎、监管、对齐优先
- **加速主义**（e/acc 阵营）：越发展 AI 越安全，技术进步本身就是解决方案

技术对齐 vs 治理对齐

- **技术派**：用更好的算法（RLHF、可解释性）解决对齐问题
- **治理派**：用政策、法规、国际合作来管理 AI 风险

六、一张图总结

```
AI Safety 🔐
    │
    ├── Alignment（对齐）
    │   ├── RLHF（OpenAI, 2022）
    │   ├── Constitutional AI（Anthropic, 2022）
    │   └── DPO（Stanford, 2023）
    │
    ├── Interpretability（可解释性）
    │   └── Understanding what's inside the black box
    │
    ├── Red Teaming（红队测试）
    │   └── Finding vulnerabilities before bad actors do
    │
    ├── Guardrails（护栏）
    │   ├── Input filters
    │   └── Output filters
    │
    └── Governance（治理）
        ├── RSP（Anthropic）
        ├── EU AI Act（欧盟）
        └── International AI Safety Reports

2026 年 AI Safety 的关键问题是：
"在 AGI 到来之前，我们能解决对齐问题吗？"
```