# AI 图像生成 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉 AI 图像生成的基本概念，可以直接翻阅主报告。

---

## 一、AI 图像生成是做什么的?

AI 图像生成就是用 AI 模型"凭空"画出图片——你输入一段文字（"一只戴礼帽的柴犬，油画风格"），AI 输出一张图片。

2022 年是 AI 图像生成进入大众视野的元年：DALL-E 2 和 Midjourney 让"文字变图片"从一个研究实验变成了人人可用的产品。到 2026 年，AI 生成图片已经无处不在——从社交媒体头像到电商产品图到电影概念设计。

---

## 二、关键概念

### 扩散模型（Diffusion Model）

2022 年至今，扩散模型是 AI 图像生成的核心技术。原理简单说：

1. **训练**：给大量图片逐步"加噪"（加随机噪点直到完全变雪花），然后让模型学会"去噪"（从雪花还原回图片）
2. **生成**：从纯噪点出发，模型一步步去噪，最终生成一张清晰图片

扩散模型之所以取代了之前的 GAN（生成对抗网络），是因为训练更稳定、多样性更好。GAN 需要同时训练"生成器"和"判别器"两个网络对抗博弈，极易失败。扩散模型只需要训练一个去噪网络。

### 潜在扩散（Latent Diffusion）—— Stable Diffusion 的核心

直接在像素空间做扩散太慢（一张 1024×1024 的图就是 300 万像素）。Stable Diffusion 的聪明之处：先用一个 VAE（变分自编码器）把图片压缩到小巧的"潜在空间"（latent space），在压缩后的空间里做扩散，最后再把结果解压回高清图。

这就像：写一部长篇小说的提纲（潜在空间），而不是写完整本书再修改。

### DiT（Diffusion Transformer）

2024 年开始普及的新架构。之前扩散模型的核心网络是 U-Net（一种编码-解码结构）。DiT 用 Transformer 替代 U-Net，效果更好、扩展性更强。Flux（2024 年 8 月）是第一个大获成功的 DiT 图像生成模型。

### 文本编码器（Text Encoder）

AI 图像生成需要"理解用户输入的文字"，然后生成匹配的图片。这个"理解"靠的是文本编码器——把用户输入的文字转化成模型能理解的向量表示。

不同的模型用不同的文本编码器，直接影响生成效果：CLIP（OpenAI）最常用，T5（Google）更长文本理解更强。

### ControlNet / LoRA

ControlNet 和 LoRA 是 Stable Diffusion 生态的两个核心技术，让开源社区能做很多闭源产品做不了的事：

- **ControlNet**：给生成过程加额外的控制条件——比如提供一张"人物姿势骨架"图，让生成的图片完全按照这个姿势来
- **LoRA**：用少量图片微调模型，让模型学会生成特定风格或特定人物

这些技术让 Stable Diffusion 的开源生态比任何闭源产品都丰富。

---

## 三、主流产品速览

| 产品 | 开发商 | 一句话 | 开/闭源 |
|---|---|---|---|
| **Midjourney** | 独立实验室 | 设计圈标杆，画质最好，审美最强 | ❌ |
| **DALL-E / GPT Image** | OpenAI | 集成 ChatGPT，文字理解力强 | ❌ |
| **Stable Diffusion 3.5** | Stability AI | 开源代表，生态最丰富 | ✅ |
| **Flux** | Black Forest Labs | SD 原班人马，DiT 架构，写实度高 | ✅（部分） |
| **Adobe Firefly** | Adobe | 商用安全，集成 Photoshop | ❌ |
| **Imagen 3/4** | Google | 2K 分辨率，通过 Gemini 分发 | ❌ |
| **Ideogram** | Ideogram | 文字生成最强（图片里的文字可读） | ❌ |
| **Recraft** | Recraft | 设计工具，矢量图输出 | ❌ |

---

## 四、一个简单直觉

```
AI 图像生成的进化史 = 从"这什么东西"到"这是 AI 画的？"到"这居然是人画的？"

2014-2021（GAN 时代）：能生成"像图片"的东西但经常翻车
2022（扩散革命）：DALL-E 2 / Midjourney / SD 让"文生图"成为现实
2023-2024（质量飞跃）：Midjourney V6 摄影级，SD 生态遍地开花
2024-2026（DiT 时代）：Flux 写实度接近 Midjourney，开源追赶闭源

2026 年的状态：
- 静态图生成 → 已经极其成熟
- 文字生成 → 大部分时候对但偶尔翻车（Ideogram 最强）
- 一致性 → 多张图保持同一角色还不行
- 商业可用的合规训练 → Adobe 在这块赢麻了
```

AI 图像生成在 2026 年是所有 AI 赛道中"最成熟"的——生成质量已经够好、成本足够低、工具链足够完善。它不再是"能不能做"的问题，而是"怎么做得更好、更可控、更商用"的问题。