AI 视频生成 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉 AI 视频生成的基本概念，可以直接翻阅主报告。

一、AI 视频生成是做什么的?

AI 视频生成就是用 AI 模型"凭空"创造出视频——你输入一段文字描述（"一只金毛犬在雪地里奔跑"），AI 输出一段视频。也可以输入一张图片让 AI 把它变成动态视频，或者输入一段现有视频让 AI 编辑它。

图像生成和视频生成的本质区别是一个图像——静态单帧，100 万像素。一条 10 秒的 1080p 视频——300 帧（30fps），3 亿像素。视频不仅要保证每一帧的质量，还要确保帧与帧之间的连续性——同一个物体在连续帧里不能位置突变、形态突变或消失。

二、关键概念

扩散模型（Diffusion Model）

这是 2022–2026 年 AI 视频生成的核心技术。用人类的方式理解：

1. **训练阶段**：给模型看大量视频，同时在视频上逐步"加噪"（添加随机噪点，直到画面变成纯雪花）。模型学会"逆向"这个过程——从纯噪点一步步还原出清晰的视频。
1. **生成阶段**：从一个纯噪点出发，模型一步步"去噪"，最后产生一段清晰的视频。

扩散模型的关键特性是**概率生成**——同一个提示每次生成的视频都不同，因为起点（随机噪点）不同。

DiT（Diffusion Transformer）

2024 年之前，扩散模型的核心网络结构是 **U–Net**（一种类似沙漏的编码–解码结构）。2024 年 OpenAI 的 Sora 带火了 DiT——用 **Transformer**（GPT 用的那种架构）替代 U–Net 做扩散。

为什么 Transformer 更好？U–Net 处理的是固定分辨率的像素网格，而 Transformer 可以把视频切成"patch"（小块），处理任意分辨率、时长和宽高比。Sora 凭借 DiT 第一次实现了"在不同分辨率、不同时长下都能生成高质量视频"。

潜在空间（Latent Space）与 VAE

一个"压缩技巧"。原始视频太大（比如 1080p × 30fps × 10 秒），直接在像素空间做扩散计算量无法承受。

VAE（变分自编码器）先把视频压缩到一个"潜在空间"——可以理解为给视频提取"骨干信息"，压缩掉细节。在压缩后的空间里做扩散计算，再把结果解压回高清视频。所有主流视频生成模型都用这个技巧，但压缩率各有不同。

自回归视频生成

Diffusion 以外的新路线——把视频当成一串"token"来预测，跟 GPT 预测下一个词类似。Google 的某些研究和 2025–2026 年的尝试在探索这条路线。优点是可以利用语言模型的成熟技术，缺点是视频 token 数量远大于文本 token，计算量惊人。

I2V（Image-to-Video）与 T2V（Text-to-Video）

- **T2V（文生视频）**：从文字描述生成视频
- **I2V（图生视频）**：从一张静态图生成视频，AI 让图片里的东西动起来
- **视频编辑**：修改现有视频的某部分（换背景、换脸、改风格）

三、视频质量怎么看?

AI 生成的视频有以下几个核心质量维度：

维度	含义	不好的表现
分辨率	画面有多清晰	模糊、马赛克
时长	能连续生成多久	最长为 4–20 秒
一致性	同一物体在不同帧里是否一致	人脸忽大忽小、衣服颜色突变
物理合理性	运动是否符合物理规律	水往上流、物体穿透、关节扭曲
提示遵循度	生成的是不是你要的	指示"狗"给了"猫"

身份漂移是最常见的问题：视频里的人物在前一帧长这样，后一帧突然变成另一个人。所有模型都或多或少存在这个问题。

四、从视频生成到世界模型

2025–2026 年，行业提出了一个新方向：**不只是生成"看起来像视频的视频"，而是生成"符合物理规律的世界模拟"**。

视频生成关注的是"画面好不好看"，世界模型关注的是"因果对不对"——打破杯子碎片应该怎么飞、风吹过树叶应该怎么动。Runway 的 GWM-1（通用世界模型）和 PixVerse 的 R1 是这个方向的代表。

这个区别解释了为什么 Sora 虽然生成的画面惊艳，但物理上经常出错（物体穿透、重力异常）。它没有在"理解物理"，而是在"制造漂亮的像素序列"。

五、关键成本问题

AI 视频生成比文本生成贵几个数量级：

类型	成本参考（2026）
文本生成 1000 tokens	~$0.003（Claude Haiku）
图像生成 1 张	~$0.01–0.10
视频生成 5–10 秒	~$0.02–0.40（API 价格）

视频生成需要多次模型推理（每帧都要算），而且扩散过程本身就需要几十步迭代。Sora 的关停直接原因就是"不可持续的计算成本"——收入远不及算力成本。

六、主流产品速览

产品	开发商	一句话
Sora（已关停）	OpenAI	2024 年引爆行业但 2026 年因成本关停
Veo 3.1	Google	4K 画质，YouTube 生态集成，原生音频
Runway Gen-4.5	Runway ML	电影级画质，导演模式，发布了 GWM 世界模型
Kling 3.0（可灵）	快手	物理模拟最强，人体运动最自然
PixVerse V6	爱诗科技	当前 ELO 排名第一，多模型平台
Pika 2.5	Pika Labs	风格化和创意工具最强，搞怪特效出圈
Vidu Q3	生数科技	中国早期 Sora 级别模型，动漫生成强
海螺AI / Seedance	MiniMax / 字节	生成速度最快，成本最低
Stable Video Diffusion	Stability AI	唯一主流开源方案，研究用

七、一个简单直觉

把 AI 视频生成的路线画一条线：

```
2018 ——— GAN 时代 ——— 短视频、低分辨率、不稳定
2022 ——— 扩散模型 ——— 画质飞跃，但运动仍然生硬
2024.02 — Sora ———— 60 秒、1080p、物理一致的惊艳 demo
2024-2025 — 国产追赶 —— 可灵、PixVerse、Vidu 集体赶超
2026.04 — Sora 关停 —— 成本问题杀死明星产品
              ↓
        PixVerse / Kling / Runway 三强并立
        开源方案仍落后 2-3 年
        核心矛盾：画面好看 vs 物理正确，还没解决
```

AI 视频生成在 2026 年遇到的根本问题是：**你看到的并不等于真实的。** 模型可以生成看起来完美的画面，但物理上的因果关系是缺失的。从"视频生成"到"世界模拟"，这条路可能还需要 3-5 年。