LLM 大模型 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉语言模型的基本概念，可以直接翻主报告。

一、语言模型是什么?

语言模型就是"会预测下一个词的 AI"。

给它"今天天气真"，它预测"好"。

给它"今天天气真好，适合出去"，它预测"散步"。

这个"预测下一个词"的能力训练到极致后，模型开始涌现出理解、推理、对话、编程等能力。没人教过它"2+3=5"，但它在海量文本中见过无数次类似的模式，就能自己学会算术。

二、关键概念

参数（Parameter）

参数是模型内部的"可调节刻度盘"。参数越多，模型能存储的知识和模式越多。简单理解：

- **1亿参数** ≈ 小学课本厚度
- **10亿参数** ≈ 书架
- **1000亿参数** ≈ 图书馆
- **万亿级参数** ≈ 几个大图书馆

当前主流的 LLM 通常在 7B–671B 参数之间（1B = 10亿）。

Token

模型不认字，只认 token。Token 是模型处理文本的最小单位：

- "Hello world" = 2 个 token
- "你好世界" = 4 个 token
- 100 个 token ≈ 75 个英文单词 ≈ 50 个中文字

上下文窗口（Context Window）

模型一次能"看到"多少内容。从 GPT-1 的 512 token 到 Gemini 1.5 Pro 的 200 万 token——相当于从"只能看一句话"到"能看 20 本书"。

Transformer

2017 年 Google 提出的神经网络架构。几乎所有现代 LLM（GPT、Claude、Gemini、Llama）都基于它。核心机制是**注意力**（Attention）——模型能判断句子中哪些词跟当前任务相关。

预训练（Pre-training）

把模型放在海量互联网文本上"读书"。学会语法、知识、推理模式。这步占模型训练成本的 95% 以上。

MoE（混合专家，Mixture of Experts）

传统的 Dense 模型：每个 token 激活全部参数。

MoE 模型：模型内部被分成多个"专家"，每个 token 只激活其中几个。训练成本更低、推理效率更高。2024-2026 年几乎所有新模型都在转向 MoE。

推理时计算扩展（Test-time Compute Scaling）

传统方式：模型一次推理直接给答案。

新方式（o1、DeepSeek-R1）：生成答案前先用更多计算"思考"——类似考试时打草稿。

三、如何评价一个模型?

基准	测什么
MMLU	综合知识（57个学科，从物理到法律）
MMLU-Pro	MMLU 的加强版（更难的推理题）
HumanEval	写代码的准确率
SWE-bench	真实软件工程任务（修 Bug）
Chatbot Arena ELO	人类主观评分（盲测对比）
MATH/GSM8K	数学推理
AIME	数学竞赛级别

四、主流模型一句话

模型家族	开发商	一句话
GPT 系列	OpenAI	LLM 的定义者和持续领跑者
Claude 系列	Anthropic	安全优先，编程最强，全面且可靠
Gemini 系列	Google	原生多模态，超长上下文（2M）
Llama 系列	Meta	开源大模型的旗帜
DeepSeek 系列	深度求索	中国开源效率革命，训练成本仅为同级 1/10
Qwen 系列	阿里巴巴	中国最强开源多模态，迭代速度极快
Mistral 系列	Mistral AI	欧洲最强，参数利用率极高
Grok 系列	xAI	马斯克的"叛逆"AI，实时接入 X 平台

五、一个简单直觉

```
LLM 的进化史 = 从"鹦鹉学舌"到"能推理"

2018-2020（GPT-1→GPT-3）：能流畅说话了，但不懂逻辑
2022（ChatGPT）：会聊天了，能回答问题
2023（GPT-4）：通过律师考试了，能看懂图片
2024（GPT-4o/Gemini/DeepSeek-V3）：能实时语音对话，开源追平闭源
2025（R1/o1）：学会"思考"了——回答前先推理
2026 年的状态：
- 最强模型在大多数基准上超过人类平均水平
- 开源模型在各项能力上与闭源模型差距大幅缩小
- 推理成本持续下降，端侧部署日益可行
- 竞争焦点从"谁能做"转向"谁更安全、更可控、更便宜"
```

LLM 大模型在 2026 年是整个 AI 生态的基石——所有 AI Agent、AI 搜索、AI 编程、多模态应用，底层都是 LLM 在驱动。