术语索引表

> 按字母/拼音排序。每个缩写/术语附带**英文全称 + 中文全称**，一句话解释，括号内标注出现在哪些报告中。

> 零基础读者遇到不认识的词，直接 Ctrl+F 搜。

A

术语（英文全称 + 中文）	一句话解释	相关报告
A2A（Agent-to-Agent Protocol，智能体间通信协议）	Google 2025 年推出，解决 Agent 之间怎么互相通信	AI Agent
Adapter（适配器）	在预训练模型层间插入的小型可训练模块，只改不到 1% 的参数就能做微调	PEFT
Agent（智能体）	LLM + 工具 + 记忆 + 自主循环，能自主决策和行动的 AI 实体	AI Agent
AGI（Artificial General Intelligence，通用人工智能）	能在大多数智力任务上达到人类水平的 AI	AI Safety
AI Overviews（AI 概览）	Google 搜索结果页顶部的 AI 生成摘要，2024 年 5 月上线	AI搜索
AIME（American Invitational Mathematics Examination，美国数学邀请赛）	LLM 数学推理能力的基准	LLM大模型
Alignment（对齐）	让模型输出符合人类偏好——"有帮助、诚实、无害"	评估与对齐, AI Safety
AllReduce（全归约）	多卡训练的核心通信操作——每张卡的梯度求和取平均，同步回所有卡	训练框架
ASR（Automatic Speech Recognition，自动语音识别）	把音频转成文字	AI语音
Attention（注意力机制）	Transformer 核心机制——让模型判断句子中哪些词对当前任务最重要	Transformer

B

术语（英文全称 + 中文）	一句话解释	相关报告
Backpropagation（反向传播）	神经网络训练的核心算法——从输出层向输入层逐层计算梯度，更新权重	Transformer训练
BDI（Belief–Desire–Intention，信念–愿望–意图模型）	1987 年提出，将 Agent 内部状态分为信念、愿望、意图三层	AI Agent
BF16（Brain Floating Point 16，脑浮点16位）	Google 提出的 16 位浮点格式——和 FP32 指数位相同，数值范围一致但精度更低，训练更稳定	Transformer训练, AI芯片格局
Bi–streaming（双向流式处理）	语音对话中同时处理输入和输出，大幅降低延迟	AI语音
Blackwell（NVIDIA Blackwell 架构）	NVIDIA 2024 年发布——双 die 封装，FP4 精度，NVLink 5（1.8 TB/s）	AI芯片格局
BPE（Byte Pair Encoding，字节对编码）	最主流的分词算法——从字符开始反复合并高频字符对，构建子词词表	Transformer, LLM大模型

C

术语（英文全称 + 中文）	一句话解释	相关报告
C4（Colossal Clean Crawled Corpus，大规模清洗网络语料）	Google 2019 年发布的首个系统化清洗的网页数据集	数据工程
Chatbot Arena（聊天机器人竞技场）	LMSYS 的盲测平台，用 ELO 分数衡量模型相对表现	LLM大模型
Chinchilla（Chinchilla 法则，计算最优模型规模法则）	DeepMind 2022 年提出——模型参数与训练数据量应按约 1:20 匹配	数据工程
Chiplet（芯粒/小芯片）	把一个大芯片拆成多个小 chiplet 通过高速互联拼在一起	AI芯片格局
Claude Code（Anthropic 的 CLI AI 编程工具）	Anthropic 2025 年推出的命令行 AI 编程助手，可直接在终端中编写和修改代码	AI编程
Claude Opus（Anthropic 最强模型系列）	Anthropic 的旗舰模型系列，2025–2026 年与 GPT-5 并称"两超"	LLM大模型
CLIP（Contrastive Language-Image Pre-training，对比语言-图像预训练）	OpenAI 2021 年发布，用 4 亿图文对训练模型学会"图文匹配"	多模态大模型
CNN（Convolutional Neural Network，卷积神经网络）	通过卷积核提取局部特征——Transformer 前时代图像处理的绝对主力	Transformer, AI图像生成
Code Completion（代码补全）	AI 根据上下文补全下一行或下一段代码——AI 编程最基本的能力	AI编程
Codex（OpenAI 代码模型）	OpenAI 2021 年发布的代码专用模型，GitHub Copilot 的底层引擎（2024 年已弃用）	AI编程
CommonCrawl（通用网络爬虫）	每月爬取整个互联网的公开网页，是预训练数据的核心来源	数据工程
Constitutional AI（宪法 AI）	Anthropic 的对齐方法——让 AI 根据"宪法"自我评判输出	LLM大模型, AI Safety
Context Window（上下文窗口）	模型一次能"看到"多少 token——从 GPT-1 的 512 到 Gemini 的 200 万	长上下文技术, LLM大模型
Continuous Batching（连续批处理）	推理优化——多个请求动态拼成一批处理，提升 GPU 利用率	Transformer推理部署
ControlNet（控制网络）	Stable Diffusion 生态工具——给图像生成加额外控制条件（如指定人物姿势）	AI图像生成
Copilot（GitHub Copilot，AI 编程助手）	GitHub/Microsoft 2021 年推出——在 IDE 中自动补全代码，AI 编程商业化的起点	AI编程

CoT（Chain-of-Thought，思维链）	让 LLM "一步一步推理"而不是直接给答案，大幅提升推理准确率	Prompt Engineering, AI Agent
CPC（Cost Per Click，按点击付费）	OpenAI 2026 年 4 月在 ChatGPT 搜索中启动的广告模式	AI搜索
Cross-Attention（交叉注意力）	Transformer Decoder 中的注意力变体——Query 来自解码器自身，Key/Value 来自编码器输出	Transformer
CUDA（Compute Unified Device Architecture，统一计算设备架构）	NVIDIA 2007 年推出的 GPU 编程平台，AI 生态最坚固的护城河	AI芯片格局

D

术语（英文全称 + 中文）	一句话解释	相关报告
DCLM（DataComp for Language Models，语言模型数据竞赛）	2024 年提出的标准数据筛选 benchmark，240T token 候选池	数据工程
DDPM（Denoising Diffusion Probabilistic Models，去噪扩散概率模型）	2020 年 Ho 等人论文，第一个系统超越 GAN 的扩散模型，奠定现代扩散模型基础	AI图像生成
Deep Research（深度研究）	AI 搜索模式——不只给出简短答案，而是自动分析数十到数百个网页后生成研究报告	AI搜索
DeepSeek-R1（DeepSeek 推理模型）	DeepSeek 2025 年 1 月发布——首个开源复现 o1 推理能力的模型，用 GRPO 训练出思维链	Post-training RL, 评估与对齐
DeepSeek-V2（DeepSeek 第二代模型）	DeepSeek 2024 年发布——首次引入 MLA（多头潜在注意力），大幅降低推理成本	MoE, Transformer
DeepSeek-V3（DeepSeek 第三代模型）	DeepSeek 2024 年底发布——671B MoE，训练成本仅 $5.6M，性能对标 GPT-4o	MoE, LLM大模型
Dense（稠密模型）	传统架构——每个 token 激活全部参数，与 MoE（只激活部分）相对	LLM大模型, MoE
Diffusion Model（扩散模型）	图像/视频生成的核心技术——学习给数据逐步加噪再逆向去噪，从纯噪声中生成内容	AI图像生成, AI视频生成
Dify（低代码 LLM 应用平台）	开源的低代码 AI 应用开发平台，支持 RAG、Agent、工作流编排，2025-2026 年中国市场最活跃的 LLMOps 工具之一	LLM应用框架
DiT（Diffusion Transformer，扩散 Transformer）	用 Transformer 替代 U-Net 做扩散模型主体，2024 年起成为图像/视频生成主流	AI图像生成, AI视频生成
DPO（Direct Preference Optimization，直接偏好优化）	2023 年 Stanford 提出——不需训练奖励模型，直接用偏好数据做优化	Post-training RL, 评估与对齐
Durable Execution（持久化执行）	Agent 在任何步骤中断后都能恢复，Temporal 是代表方案	Agent Runtime

E

术语（英文全称 + 中文）	一句话解释	相关报告
Early Fusion（早融合，原生多模态架构）	图像和文本在 token 层面统一表示，不依赖独立的视觉编码器	多模态大模型
ELO（Elo Rating System，埃洛评分系统）	源于国际象棋的排名系统，Chatbot Arena 用它衡量模型在盲测中的相对表现	LLM大模型
Embedding（嵌入/向量表示）	把文字/图片转换成模型能理解的数字向量——"语义相近的内容数学上接近"	RAG, 多模态大模型
Encoder-only / Decoder-only（仅编码器/仅解码器）	Transformer 两种变体——BERT 只用编码器（理解），GPT 只用解码器（生成）	Transformer

F

术语（英文全称 + 中文）	一句话解释	相关报告
FineWeb（精炼网络数据）	HuggingFace 2024 年发布的 15T token 高质量预训练数据集及方法论	数据工程
FlashAttention（快速注意力）	2022 年提出，通过 IO 优化让注意力计算接近 O(N)，实际训练快 2-4 倍	Transformer训练, 长上下文技术
Fork IDE（分支式集成开发环境）	拿开源 IDE（VS Code）改造成 AI 原生编辑器，Cursor 是代表	AI编程
FP4 / FP8 / FP16（Float Point，浮点精度）	数字越小计算越快、显存越省。2026 年已能做到 FP4 训练匹配 FP16 准确度	AI芯片格局, 模型压缩
FSDP（Fully Sharded Data Parallelism，全分片数据并行）	PyTorch 原生支持的分布式训练策略——模型参数分片存储在多张 GPU 上	训练框架
Function Calling（函数调用/工具调用）	OpenAI 2023 年 6 月引入，让 LLM 输出结构化 API 调用请求	AI Agent, LLM应用框架

G

术语（英文全称 + 中文）	一句话解释	相关报告
GAIA（General AI Assistant Benchmark，通用 AI 助手基准）	Meta 2023 年提出的 Agent 能力基准——测试多步推理、工具使用、网页浏览等真实世界任务	AI Agent
GAN（Generative Adversarial Network，生成对抗网络）	2014 年提出——生成器和判别器对抗博弈来生成内容，图像生成的起点	AI图像生成, AI视频生成
GELU（Gaussian Error Linear Unit，高斯误差线性单元）	Transformer 常用的激活函数——比 ReLU 更平滑，GPT-2/3 和 BERT 的标准选择	Transformer
Gemma（Google 开源模型系列）	Google 2024 年推出的开源 LLM 系列，与 Llama 直接竞争	LLM大模型
GGUF（GPT-Generated Unified Format，GPT 通用量化格式）	llama.cpp 的量化模型格式，能在普通电脑本地运行 LLM	模型压缩
GPT-5 / GPT-5.5（OpenAI 第五代模型系列）	OpenAI 2025-2026 年的旗舰模型，GPT-5.5 为当前最新（2026.04），在推理、编码、多模态全面领先	LLM大模型
GPTQ / AWQ（GPT 量化/激活感知权重量化）	两种主流的 4-bit 量化方法——用极低精度损失换取大幅显存节省	模型压缩
GQA（Grouped Query Attention，分组查询注意力）	多查询注意力的折中方案——分组共享 Key-Value，平衡效率与质量	长上下文技术
GRPO（Group Relative Policy Optimization，分组相对策略优化）	DeepSeek 2024 年提出——同一批生成回答互相比较，不需 critic 模型	Post-training RL, 评估与对齐
Guardrails（护栏）	Agent 的安全过滤层——话题限制、内容安全、越狱检测	Agent Runtime, AI Safety

H

术语（英文全称 + 中文）	一句话解释	相关报告
Hallucination（幻觉）	模型"编造"不存在的答案——AI 搜索和 LLM 的最大风险之一	AI搜索, LLM大模型
Harness（夹具/控制面）	Agent 的控制层——沙箱、护栏、权限、状态持久化。2026 年被定义为正式工程领域	Agent Runtime, AI Agent
HBM（High Bandwidth Memory，高带宽内存）	AI 芯片的核心存储——制约芯片性能的战略瓶颈	AI芯片格局
HumanEval（人类评估基准）	OpenAI 发布的代码生成基准，测试 LLM 写代码的准确率	LLM大模型, AI编程
Human-in-the-Loop（人在回路）	人类在关键步骤介入 Agent 决策循环，防止全自动出错	Agent Runtime

I

术语（英文全称 + 中文）	一句话解释	相关报告
Identity Drift（身份漂移/角色漂移）	视频生成中人物在连续帧中"变脸"——AI 视频最头疼的问题之一	AI视频生成
InfiniBand（无限带宽）	NVIDIA（Mellanox）的高速互联网络方案，万卡 GPU 集群的通信基石	AI芯片格局

K

术语（英文全称 + 中文）	一句话解释	相关报告
KV Cache（键值缓存）	推理时缓存已计算的 Key-Value 注意力矩阵，避免重复计算，显存占用随序列长度线性增长	Transformer推理部署，长上下文技术

L

术语（英文全称 + 中文）	一句话解释	相关报告
LangChain（LLM 应用开发框架）	Harrison Chase 2022 年创建——最早的 LLM 应用框架，通过 Chain/Agent/Tool 抽象让开发者编排 LLM 调用流程	LLM应用框架
LayerNorm（Layer Normalization，层归一化）	对每个样本的所有特征做归一化——Post-LN 是原始 Transformer 选择，Pre-LN 是现代 LLM 的主流	Transformer
Learning Rate（学习率）	控制每次参数更新的步长——太大训练不稳定，太小收敛太慢，是训练最重要的超参数之一	Transformer训练
LLM（Large Language Model，大语言模型）	在海量文本上预训练的生成式语言模型——所有 AI 应用的底层引擎	LLM大模型
Llama（Meta 开源 LLM 系列）	Meta 2023 年起推出的开源 LLM 系列，从 Llama 1 到 Llama 4，是开源生态的核心驱动力	LLM大模型
LlamaIndex（数据索引框架）	Jerry Liu 2022 年创建——专注 RAG 的数据连接层，提供丰富的数据加载器和索引类型	LLM应用框架，RAG
LoRA（Low-Rank Adaptation，低秩适配）	在模型权重旁加"低秩更新"矩阵，只改几千个参数就能做微调	PEFT，AI图像生成
LSTM（Long Short-Term Memory，长短期记忆网络）	1997 年提出——RNN 的一种特殊形式，用输入门/遗忘门/输出门缓解梯度消失问题	Transformer

M

术语（英文全称 + 中文）	一句话解释	相关报告
MCP（Model Context Protocol，模型上下文协议）	Anthropic 2024 年底推出——标准化 Agent 与工具的连接方式，被称为"AI 的 USB-C"	AI Agent, LLM应用框架
MCTS（Monte Carlo Tree Search，蒙特卡洛树搜索）	像下棋 AI 一样，在推理时探索多条路径并选最佳——o3 的核心机制	Post-training RL
MLA（Multi-head Latent Attention，多头潜在注意力）	DeepSeek 提出——大幅降低 KV Cache，让推理成本降到同级模型的 1/3	MoE
MLP（Multi-Layer Perceptron，多层感知器）	最简单的视觉-文本连接方案——几层神经网络直接把视觉 token 映射到 LLM 空间	多模态大模型
MMLU（Massive Multitask Language Understanding，大规模多任务语言理解）	57 个学科（物理到法律）的综合知识测试——LLM 核心基准	LLM大模型, 评估与对齐
MMLU-Pro（MMLU 增强版）	MMLU 的加强版，更难的推理题	LLM大模型
Model Collapse（模型崩溃）	合成数据训练过多后模型性能回退——多样性下降、长尾知识丢失	数据工程
MoE（Mixture of Experts，混合专家）	把大模型拆成多个"专家"，每个 token 只激活其中几个。2024-2026 年主流架构	MoE, LLM大模型
MQA（Multi-Query Attention，多查询注意力）	Key-Value 在所有注意力头之间共享——大幅减少 KV Cache，速度更快	长上下文技术

N

术语（英文全称 + 中文）	一句话解释	相关报告
NVLink（NVIDIA 高速互联）	NVIDIA GPU 之间的专用高速通信链路，多卡训练的通信基石	AI芯片格局, 训练框架

O

术语（英文全称 + 中文）	一句话解释	相关报告
Omni（全模态）	来自拉丁语 "omnis"（全部）——一个模型统一处理文本+图像+音频+视频	LLM大模型, 多模态大模型

P

术语（英文全称 + 中文）	一句话解释	相关报告
PagedAttention（分页注意力）	vLLM 核心创新——把 KV Cache 像操作系统分页一样管理，解决显存碎片化	Transformer推理部署
Parameter（参数）	模型内部的可调节"刻度盘"。1B = 10 亿参数，主流 LLM 在 7B–671B 之间	LLM大模型
PEFT（Parameter-Efficient Fine-Tuning，参数高效微调）	冻结模型绝大部分参数，只训练极小比例的额外参数来做微调	PEFT
Perceiver Resampler（感知器重采样器）	Flamingo 的连接器——视觉信号在 LLM 每一层都通过交叉注意力注入	多模态大模型
Pipeline Bubble（流水线气泡）	流水线并行中 GPU 空闲等待的时间空隙，bubble 越小效率越高	训练框架
Policy Model（策略模型）	RL 训练中被优化的目标模型——"考生"，与奖励模型（"阅卷老师"）相对	Post-training RL, 评估与对齐
PPO（Proximal Policy Optimization，近端策略优化）	最主流的 RL 算法——"小步更新"，防止模型步子太大导致崩溃	Post-training RL
Pre-training（预训练）	在海量无标注文本上训练模型学会"下一个 token 预测"——LLM 训练的第一阶段和最主要阶段	数据工程, Transformer训练, LLM大模型
Prompt Caching（提示缓存）	复用之前请求的 KV Cache 计算结果——重复前缀的后续请求成本降低 90%	Context Engineering, Transformer推理部署
Prompt Engineering（提示工程）	设计和优化给 LLM 的提示词，让模型输出更好结果的技术	Prompt Engineering
Prompt Injection（提示注入攻击）	攻击者通过恶意输入操纵 Agent 执行危险操作——Agent 安全的核心威胁	AI Agent

Q

术语（英文全称 + 中文）	一句话解释	相关报告
Q-Former（Query-Former，查询变换器）	BLIP-2 核心——用可学习 query 向量从视觉输出中提取关键信息、压缩成少量 token	多模态大模型
QKV（Query-Key-Value，查询-键-值机制）	自注意力核心——Query 查什么、Key 匹配什么、Value 提取什么	Transformer
QLoRA（Quantized LoRA，量化低秩适配）	模型先量化为 4-bit，再做 LoRA 微调——让消费级 GPU 也能微调大模型	PEFT
Quantization（量化）	把模型参数从 FP16 压到 INT4/INT8 等低精度，大幅减少显存和推理成本	模型压缩
Qwen（通义千问，阿里开源 LLM 系列）	阿里云推出的开源 LLM 系列，从 Qwen 1 到 Qwen 3.5，中国市场最活跃的开源模型家族	LLM大模型

R

术语（英文全称 + 中文）	一句话解释	相关报告
RAG（Retrieval-Augmented Generation，检索增强生成）	大模型"先查资料再回答"——AI 搜索和知识库的核心技术	RAG, AI搜索
ReAct（Reasoning + Acting，推理-行动协同）	2022 年 Yao et al. 提出——推理和行动交错循环，几乎所有现代 Agent 的底层设计	AI Agent
Red Teaming（红队测试）	组织团队尝试攻击自己的 AI 系统，找到漏洞后修复——AI 安全标准实践	AI Safety
Residual Connection（残差连接）	把输入直接加到输出上——"跳层连接"让深层网络的梯度能顺畅回传	Transformer
Reward Hacking（奖励破解）	RL 训练中模型学会"欺骗"奖励模型来拿高分，而非真正提升质量——对齐的核心陷阱	评估与对齐, Post-training RL
Reward Model（奖励模型）	RLHF 中的"阅卷老师"——一个专门训练来判断回答好坏的模型，给策略模型的输出打分	Post-training RL, 评估与对齐
RL（Reinforcement Learning，强化学习）	智能体通过试错学习——做对了得奖励，做错了受罚，目标是最大化累计奖励	Post-training RL
RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）	让人类标注者评判模型输出，然后训练模型对齐人类偏好	Post-training RL, 评估与对齐
RMSNorm（Root Mean Square Normalization，均方根归一化）	LayerNorm 的简化版——去掉减均值的步骤，计算更快，LLaMA 等现代模型的标准选择	Transformer
RNN（Recurrent Neural Network，循环神经网络）	按顺序逐个处理输入——Transformer 前 NLP 的主流架构，受限于串行计算不能并行	Transformer
ROCm（Radeon Open Compute，AMD 开源计算平台）	AMD 的 GPU 编程平台，对标 CUDA，开源但生态成熟度逊于 CUDA	AI芯片格局
RoPE（Rotary Position Embedding，旋转位置编码）	最主流的位置编码方案——通过旋转变换让序列长度可以灵活外推	长上下文技术, Transformer
Rubin（NVIDIA Vera Rubin 架构）	NVIDIA 2026 年下半年投产——首款 HBM4 GPU（288GB），50 PFLOPs 算力	AI芯片格局

S

术语（英文全称 + 中文）	一句话解释	相关报告
Sandbox（沙箱）	隔离的执行环境——Agent 在其中运行代码但无法影响外部系统	Agent Runtime
SayCan（Google 机器人-LLM 协同系统）	Google Robotics 2022 年提出——让 LLM 为机器人规划行动，机器人评估可行性，两者协商	AI Agent
Scaling Law（规模定律/缩放法则）	模型性能与参数量、数据量、计算量之间的幂律关系——"更大就更好"的理论基础	Transformer
SFT（Supervised Fine-Tuning，监督微调）	在人工标注的指令-回答对数据上微调模型，让模型学会"对话格式"——LLM 训练的第二阶段	Post-training RL, 评估与对齐, LLM大模型
SigLIP（Sigmoid Loss for Language-Image Pre-training，Sigmoid 损失语言-图像预训练）	CLIP 改进版——用 sigmoid loss 替代 softmax，小 batch 也能高效训练	多模态大模型
SOAR（State Operator And Result，状态-操作-结果架构）	1983 年 CMU 创建的第一个可计算通用智能体架构——现代 Agent "思考→行动→观察"循环的祖先	AI Agent
Softmax（归一化指数函数）	把任意实数向量映射为概率分布——Transformer 输出层的核心操作	Transformer, LLM大模型
Speculative Decoding（投机解码/推测解码）	用小模型快速"猜测"输出，大模型验证——不损失质量但速度提升 2-3 倍	Transformer推理部署
SSM（State Space Model，状态空间模型）	Transformer 的替代架构——用常微分方程建模序列，O(N) 复杂度，Mamba 是代表	Transformer, 长上下文技术
SWE-bench（Software Engineering Benchmark，软件工程基准）	根据 GitHub Issue 修 Bug 让测试通过——AI 编程能力的核心基准	AI编程, LLM大模型
SwiGLU（Swish-Gated Linear Unit，Swish 门控线性单元）	现代 LLM 标配的 FFN 激活函数——结合 Swish 和门控机制，PaLM/LLaMA 首次大规模采用	Transformer
Symbolic AI（符号 AI）	用人类手写的逻辑规则来表示知识和推理——2010 年前 AI 的主流范式，受限于规则无法覆盖真实世界复杂性	AI Agent
System Prompt（系统提示词）	对话开头设置的角色和行为规范——告诉模型"你是谁、做什么、不做什么"，是整个对话的底层约束	Prompt Engineering, Context Engineering

T

术语（英文全称 + 中文）	一句话解释	相关报告
Tensor Core（张量核心）	NVIDIA GPU 中专为矩阵乘法设计的硬件单元——效率是普通核心的 8–16 倍	AI芯片格局
Test-time Compute Scaling（推理时计算扩展）	推理时花更多算力"思考"，比训练时花更多算力更划算——o1/R1/o3 路线	Post-training RL
Token（词元/令牌）	模型处理文本的最小单位。"你好世界" = 4 token，"Hello world" = 2 token	LLM大模型
Transformer（变换器）	2017 年 Google 提出——完全基于自注意力的神经网络架构，驱动了全球几乎所有大模型	Transformer, LLM大模型
Triton（OpenAI 开源 GPU 编程语言）	写一次就能在 NVIDIA/AMD/Intel 上跑，正在削弱 CUDA 锁定效应	AI芯片格局
TTS（Text-to-Speech，文字转语音/语音合成）	把文本合成为人声	AI语音
TTFB（Time To First Byte，首包时间）	从用户说完话到 AI 开始回话的延迟——语音对话核心指标	AI语音

V

术语（英文全称 + 中文）	一句话解释	相关报告
VAE（Variational Autoencoder，变分自编码器）	把图片压缩到小巧的"潜在空间"，在这里做扩散，再解压回高清图	AI图像生成
Vibe Coding（氛围编程/直觉编程）	Andrej Karpathy 创造——用自然语言描述需求，让 AI 生成代码，完全"凭感觉"	AI编程
ViT（Vision Transformer，视觉 Transformer）	Google 2020 年提出——把图片切成 16×16 patch 当成 token，直接扔进 Transformer，证明 Transformer 在视觉领域同样有效	Transformer, 多模态大模型
vLLM（虚拟大语言模型推理引擎）	UC Berkeley 2023 年发布——PagedAttention 解决 KV Cache 显存碎片化	Transformer推理部署

W

术语（英文全称 + 中文）	一句话解释	相关报告
WebArena（网页智能体基准）	模拟真实网站的 Agent 测试环境——测试 Agent 在 Reddit/GitLab/eBay 等真实网页上完成任务的端到端能力	AI Agent
WebGPT（OpenAI 网页搜索 GPT）	OpenAI 2021 年提出——让 GPT-3 通过浏览器搜索回答问题，是后来 AI 搜索和 Agent 工具调用的雏形	AI Agent, AI 搜索
Whisper（OpenAI 语言识别模型）	OpenAI 2022 年开源——68 万小时多语言数据训练，支持 99 种语言	AI语音
World Model（世界模型）	AI 不仅生成画面，还理解三维结构、重力、光影等物理规律——视频生成的终极方向	AI视频生成

Z

术语（英文全称 + 中文）	一句话解释	相关报告
ZeRO（Zero Redundancy Optimizer，零冗余优化器）	DeepSpeed 内存优化策略——优化器状态、梯度、参数分片存储	训练框架，Transformer训练
Distillation（蒸馏）	用大模型（教师）输出来训练小模型（学生），让小模型继承大模型能力	模型压缩
Gradient（梯度）	损失函数对各参数的偏导数——指向"往哪个方向调参数能让模型变好"的方向和大小	Transformer训练
Self-Attention（自注意力）	Transformer 核心——让句子中任意两个词直接交互，捕捉全局依赖	Transformer
Visual Grounding（视觉定位）	多模态模型不仅能"看懂"图片，还能"指出"物体位置	多模态大模型
Gated Cross-Attention（门控交叉注意力）	Flamingo 连接器机制——LLM 每一层决定"这一层要不要看图片"	多模态大模型