大模型技术全景研究 · 横纵分析报告目录

> 共 30 篇 · 约 1100KB（38 万+字）· 截至 2026-05-02

> 每篇报告均配有独立的前置知识文档，零基础读者可先读前置知识再读主报告。

阅读指南

如果你完全不懂 AI，从这里开始：

```
LLM 大模型 → Prompt Engineering → AI Agent → 感兴趣就继续
```

3 篇读完，你有了"大模型是什么、怎么用它、它能自己做任务"的完整框架。

接下来按你的角色选一条路线：

🎓 **学术/研究路线**（理解原理，能读论文）：

```
LLM大模型 → Transformer → 大模型训练 → Post-training RL → 大模型强化学习 → MoE → 长上下文技术
```

8 篇读完，你对大模型从架构到训练到推理的技术栈有了系统性理解。

🔧 **工程/开发路线**（能建产品，能部署）：

```
LLM大模型 → Prompt Engineering → RAG → LLM应用框架 → AI Agent
进阶：Context Engineering → Agent Runtime/Harness → 大模型推理部署 → 端侧AI
```

8 篇读完，你能从零搭建一个生产级 AI 应用，包括云端和端侧部署。

📱 **移动/端侧路线**（做手机/PC 上的 AI）：

```
小语言模型 SLM → 端侧AI → 大模型蒸馏 → 模型压缩 → 大模型推理部署
```

5 篇读完，你理解了怎么把 AI 塞进手机并让它跑得快。

📊 **全面系统学习**，按七大类顺序：

一、基础模型 → 二、基础架构 → 三、训练与数据 → 四、推理与部署 → 五、应用范式 → 六、垂直赛道 → 七、安全与治理

30 篇全读完，你对 2026 年 AI 技术的全景就有了覆盖从芯片到应用、从训练到安全的全维度理解。

如果只想快速定位：

- 我想了解 AI 能做什么 → **六、垂直产品赛道**
- 我想知道模型怎么训练出来的 → **三、训练与数据**（含强化学习、蒸馏）
- 我想在手机/PC 上跑 AI → **小语言模型 SLM + 端侧AI**
- 我想理解技术原理 → **二、基础架构**
- 我想让 AI 自己干活（Agent）→ **AI Agent + Agent Runtime/Harness + 大模型强化学习**
- 我关心安全问题 → **七、安全与治理**

一、基础模型

> **起点**。LLM 本身——GPT、Claude、Gemini、Llama、DeepSeek、Qwen 等八大家族的竞争史。这是理解其他所有报告的前提。

报告	主题	篇幅	一句话
LLM 大模型	基础语言模型全景	33KB	从 GPT-1 到 GPT-5.5 和 Claude Opus 4.7 的"两超"对决——八大家族的崛起与"王座 88 天一换"的混战格局。
多模态大模型	视觉语言模型	27KB	LLM 长出了"眼睛"——CLIP、视觉编码器、LLM 三者如何协作让模型"看懂"图片和视频。原生多模态正在挑战分离式架构。
小语言模型 / SLM	小模型革命	14KB	从"大模型崇拜"到"小模型革命"——Phi-4 14B 追平 70B、R1-Distill 让推理能力可蒸馏、Qwen 3.6-27B 在本地跑出 Opus 4.5 水平。

二、基础架构

> LLM 的"骨骼"和"神经"。Transformer 是骨架，MoE 是肌肉，长上下文是记忆系统，芯片是心脏。

报告	主题	篇幅	一句话
Transformer	注意力机制	55KB	2017 年诞生的序列建模架构，如今驱动了全球几乎所有大模型。从机器翻译实验到统治世界。
MoE	混合专家模型	67KB	把大模型拆成多个专家，每个 token 只激活少数——1991 年的想法，2026 年成为核心架构选择。
长上下文技术	上下文扩展	34KB	从 512 tokens 到 10M tokens——位置编码、注意力计算、KV Cache 三条技术线如何突破 $O(N^2)$ 的诅咒。
AI 芯片格局	算力硬件	25KB	NVIDIA 80% 份额的 GPU 战场——从 CUDA 生态到万卡集群，谁在决定 AI 的算力天花板。

三、训练与数据

> 模型怎么"长大"。从零开始训练、用什么数据、怎么对齐、怎么微调、怎么压缩。

报告	主题	篇幅	一句话
大模型训练	大规模训练与框架	80KB	从单卡到万卡集群——3D 并行、ZeRO、FlashAttention 如何让千亿参数模型在合理时间内完成训练，以及 DeepSpeed、Megatron、FSDP 等框架的选型与对比。
大模型数据工程	数据清洗配比	40KB	从 Reddit Karma 到 DCLM 评分器——如何在 240TB 的互联网垃圾中捞出教科书级的好数据。
大模型强化学习	RL 算法与范式	21KB	从 RLHF 的 4 个模型到 RLVR 的零人类标注——强化学习如何从"对齐工具"升级为定义 AI 智能上限的核心引擎。
Post-training / RL 训练基础设施	对齐训练基础设施	27KB	RLHF、DPO、GRPO、推理时计算扩展——Post-training 的工程实现与框架选型。
PEFT 参数高效微调	低资源微调	21KB	冻结 99.9% 的参数、只改 0.1%——Adapter、LoRA、QLoRA 如何让"一人一模型"变成现实。
大模型蒸馏	知识蒸馏	13KB	从 Hinton 的"暗知识"到 DeepSeek V4 OPD——蒸馏如何从"压缩小技巧"变成制造智能的核心工艺。
模型压缩	量化剪枝	24KB	从 4-bit 量化到推理链蒸馏，模型如何在精度、大小和速度之间走出"既要又要还要"的路。

四、推理与部署

> 模型训练好之后——怎么用得起来、用得好。

报告	主题	篇幅	一句话
大模型推理部署	推理优化	49KB	训练只做一次，推理跑无数次——Continuous Batching、PagedAttention、投机解码如何平衡延迟、吞吐与成本。
端侧 AI / 设备端部署	端侧推理	14KB	从"云端 API 是唯一答案"到"3B 模型在手机上实时跑"——芯片（NPU）、OS（Apple Intelligence / Gemini Nano）、混合 AI 终局。
Context Engineering	上下文编排	25KB	上下文窗口从 4K 涨到 2M，但"放得下"不等于"用得好"。
Agent Runtime / Harness	Agent 运行时基础设施	32KB	沙箱、编排、护栏、监控——为什么"模型不重要，Harness 才重要"。从 AutoGPT 的 while True 到 OpenAI Harness 范式。

五、应用范式

> 开发者怎么用大模型构建真实产品。四种核心方法论。

报告	主题	篇幅	一句话
Prompt Engineering	提示工程	31KB	"Let's think step by step"可能是 AI 史上最有影响力的七个词——从手工模板到自动化推理策略设计。
RAG	检索增强生成	28KB	大模型学会"先查资料再回答"——从 2020 年的三篇开山论文到 2026 年的 Modular RAG 体系。
LLM 应用框架	开发框架	18KB	LangChain、LlamaIndex、Dify 等框架如何在"API 的简单性"和"应用的复杂性"之间架起桥梁。
AI Agent	智能体	43KB	从 1983 年 SOAR 到 OpenClaw 30 万 Stars——Agent 如何从学术概念变成能订机票、写代码、操作电脑的自主实体。

六、垂直产品赛道

> AI 技术落地成产品——七个具体的 AI 产品品类。每篇都有完整的竞品对比和用户口碑。

报告	主题	篇幅	一句话
AI 编程 / 代码智能	AI 编程	33KB	从 Copilot 到 Cursor 再到 Claude Code——AI 编程如何在四年内从代码补全插件长成 600 亿美元新战场。
AI 搜索	AI 搜索	29KB	从 Perplexity 到 ChatGPT Search 再到 Gemini——"直接给答案"如何用三年颠覆搜索引擎二十年的广告帝国。
AI 语音	AI 语音	31KB	从 WaveNet 到 GPT-4o voice 再到 CosyVoice——AI 语音如何在十年间从机械朗读进化到能跟人类实时对话的语音智能。
AI 视频生成	视频生成	34KB	从 GAN 到 Sora 再到后 Sora 时代——AI 视频生成如何在"画面好看"和"物理正确"之间挣扎了八年。
AI 图像生成	图像生成	23KB	从 GAN 到扩散模型到 DiT——AI 图像生成如何从"实验室怪图"变成十亿人使用的创作工具。
具身智能 / 机器人	具身智能	—	从机械臂到人形机器人——大模型如何给机器人装上"大脑"，以及 2026 年全球具身智能赛道的全面爆发。

七、安全与治理

> 模型"能跑"之后——怎么让它"听话"、怎么知道它"变强了"。

报告	主题	篇幅	一句话
AI Safety	AI 安全	31KB	从图灵 1951 年的警告到 2026 年——"确保 AI 做人类想让它做的事"如何从哲学问题变成全球议程。
大模型评估与对齐	对齐方法	30KB	RLHF、DPO、GRPO 等对齐方法的四次范式转换——从人类反馈到规则自博弈，从 InstructGPT 到 DeepSeek-R1。

数据总览

指标	数值
报告总数	30 篇
总篇幅	~1100KB（约 38 万+字）
前置知识	30 篇（独立文档，零基础友好）
覆盖类别	7 类：基础模型 / 基础架构 / 训练与数据 / 推理与部署 / 应用范式 / 垂直赛道 / 安全与治理
时间跨度	GPT-1（2018）→ 2026 年 5 月最新动态
研究方法	横纵分析法（纵向时间线 + 横向竞品对比）

各报告前置知识

每份主报告配有一份独立的前置知识文档，面向完全零基础读者，使用比喻和例子讲解基础概念：

主报告	前置知识
LLM 大模型	LLM 大模型前置知识
多模态大模型	多模态大模型前置知识
Transformer	Transformer 前置知识
MoE	MoE 前置知识
长上下文技术	长上下文技术前置知识
AI 芯片格局	AI 芯片格局前置知识
大模型训练	大模型训练前置知识（含并行策略、ZeRO、框架对比，综合了原 Transformer 训练前置知识与训练框架前置知识）
大模型数据工程	数据工程前置知识
Post-training / RL	Post-training 前置知识
PEFT	PEFT 前置知识
模型压缩	模型压缩前置知识
大模型推理部署	Transformer 前置知识
Context Engineering	Context Engineering 前置知识
Agent Runtime / Harness	Agent Runtime / Harness 前置知识
Prompt Engineering	Prompt Engineering 前置知识
RAG	RAG 前置知识
LLM 应用框架	LLM 应用框架前置知识
AI Agent	AI Agent 前置知识
AI 编程	AI 编程前置知识
AI 搜索	AI 搜索前置知识
AI 语音	AI 语音前置知识
AI Safety	AI Safety 前置知识
评估与对齐	评估与对齐前置知识
AI 视频生成	AI 视频生成前置知识

AI 图像生成	AI 图像生成前置知识
具身智能 / 机器人	具身智能前置知识
小语言模型 / SLM	SLM 前置知识
端侧 AI	端侧 AI 前置知识
大模型蒸馏	大模型蒸馏前置知识
大模型强化学习	大模型强化学习前置知识