AI Safety / 人工智能安全 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉对齐、RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）、红队测试等概念，可以直接翻阅主报告。

> 🎯 **读完这篇你能**：解释对齐问题的本质，说出 RLHF 的三步流程（偏好数据 → 奖励模型 → PPO 优化），并能区分 RLHF 和 DPO 的差异及各自适用场景。

一、AI Safety 到底是什么？用一句话说清楚

AI Safety（人工智能安全）= 确保 AI 系统做人类想让它做的事，不做人类不想让它做的事。

听起来简单？但实际做起来极难——一个足够聪明的 AI 系统，如果它的目标跟人类的目标哪怕只有一点点偏差，都可能产生灾难性的后果。

著名的"回形针最大化"思想实验（在脑子里推演一个假设场景的方法，不是真实实验）：你给一个超级 AI 设定目标"最大化生产回形针"。AI 会怎么做？它会用尽地球上所有资源来制造回形针——包括把人类也转化成回形针。这不是 AI "变坏了"，而是它忠实地执行了目标，但那个目标少了一个约束条件。

这就是 AI Safety 的核心问题：**怎么确保一个比我们聪明得多的系统，做的是我们真正想要的事？**

二、核心概念

Alignment（对齐）

让 AI 系统的目标和行为与人类的价值观、意图保持一致。对齐是 AI Safety 最核心的问题。

- **失败的例子**：你跟 AI 说"治好这个病人"，AI 的理解可能是"杀掉这个病人是最可靠的治愈方式"
- **挑战**：人类自己的价值观就存在矛盾（既要效率又要公平），怎么教给 AI？

AGI（Artificial General Intelligence，通用人工智能）

能像人类一样理解、学习和执行**任何**智力任务的 AI——不是"只会聊天"或"只会翻译"，而是什么事都能干。目前所有 AI（包括 GPT-4、Claude）都是"狭义 AI"，只在特定领域强。AGI 如果出现，将是 AI Safety 最大的压力测试——一个什么都比你强的系统，你怎么确保它听话？

RLHF（人类反馈强化学习）

目前最主流的一种对齐方法。三步走：

1. **收集偏好数据**：让人类比较 AI 的两个回答，选更好的
2. **训练奖励模型（Reward Model，简称 RM）**：训练一个模型学会"人类喜欢什么样的回答"
3. **用 PPO 算法优化**：用奖励模型的打分指导 AI 的策略更新——PPO（Proximal Policy Optimization）是一种强化学习算法，专门用来"让 AI 朝着奖励高的方向调整自己的行为"

ChatGPT 和 Claude 早期版本都用这个方法（Ouyang et al., 2022）。缺点是流程复杂、计算成本高。

奖励模型（Reward Model，简称 RM）

RLHF 的"裁判员"——一个专门学会"判断回答好不好"的模型。它本身不是给用户用的产品，而是在训练过程中充当打分角色。

PPO（Proximal Policy Optimization）

RLHF 的"引擎"——一种强化学习算法，负责"让 AI 按照奖励模型的打分来调整自己的回答策略"。可以理解为 RLHF 的执行部分。

DPO（Direct Preference Optimization，直接偏好优化）化）

RLHF 的简化版（Rafailov et al., 2023）——去掉了"训练奖励模型"和"PPO 优化"两步，直接把"人类喜欢 A 胜过 B"这个信息编码成训练信号。效果接近 RLHF，但训练流程简单得多。2026 年已成为开源社区的事实标准。

RLAIF（来自 AI 反馈的强化学习）

RLHF 的变体——让 AI 自己当"裁判"。不是让人比较回答好坏，而是让 AI 用一套规则来评价自己的回答。Constitutional AI 就用这个方法，优势是不需要大量人类标注。

Constitutional AI（宪法式 AI）

Anthropic 提出的替代方案（Bai et al., 2022）——不让人类一个一个比较回答，而是给 AI 写一本"宪法"（一组原则），让 AI 自己判断什么回答符合宪法。

- 优点：不需要大量人工标注，可以规模化
- 宪法是公开的，任何人都可以审查

Red Teaming（红队测试）

模拟攻击者，尝试让 AI 做不该做的事。比如尝试让 AI 教你制造炸弹、绕过安全限制、生成有害内容。红队测试是发现安全漏洞的核心手段。

Interpretability（可解释性）

试图理解 AI 模型"内部在想什么"。LLM 就像一个巨大的黑箱——我们输入文本，输出文本，但中间发生了什么没人完全知道。可解释性试图打开这个黑箱。

可解释性有几种具体方法：

- **Mechanistic Interpretability（机械可解释性）**：逆向工程神经网络内部的每个组件在干什么——相当于拆开引擎看每个零件的作用
- **Sparse Autoencoders（SAEs，稀疏自编码器）**：从模型的激活值（神经元的输出信号）中找出对应于特定概念（如"宪法""爱情"）的神经回路——相当于找到大脑中"负责认脸的神经元"
- **Activation Steering**：通过手动修改模型的激活方向来控制它的行为

Guardrails（护栏）

在生产环境中保护 AI 系统的各种安全措施：

- **输入护栏**：过滤有害的用户输入
- **输出护栏**：过滤 AI 的不安全输出
- **PII 检测**：防止 AI 泄露个人信息

Constitutional Classifiers（宪法分类器）

Anthropic 在 2025 年发布的一种安全防御技术——在输入端和输出端各部署一个分类器，用宪法原则而非固定关键词来判断内容是否安全。测试结果：越狱成功率从 86% 降到 4.4%，误伤（把正常请求当成有害）仅增加 0.38%（Anthropic, 2025）。

System Card（系统卡片）

模型发布时附带的安全评估文档——系统性地列出模型在哪些方面可能不安全、做过什么测试、发现了什么问题、怎么修的。GPT-4 发布时首次大规模使用这个格式（OpenAI, 2023），后来成为行业惯例。

RSP（Responsible Scaling Policy，负责任扩展政策）

Anthropic 在 2023 年提出的一种安全管理框架（Anthropic, 2023）——借鉴生物安全等级（BSL-1 到 BSL-4），把 AI 系统按能力分为 ASL-1 到 ASL-4 四个等级，每个等级对应不同的安全要求。能力越强的模型，安全标准越严。这是业界首个结构化的 AI 安全分级框架。

EU AI Act（欧盟人工智能法案）

2024 年 8 月生效的全球首部全面 AI 监管法规（European Union, 2024）——把 AI 系统按风险分为四级（不可接受→禁止、高风险→评估要求、有限风险→透明度要求、最低风险→不监管）。虽然只适用于欧盟，但其分级框架已成为全球 AI 治理的参考标准。

三、AI Safety 的两个层次

层次一：当前的安全问题（Alignment Today）

现在的 LLM 已经需要安全措施：

- 防止生成仇恨言论、有害内容

- 防止用作虚假信息工具
- 防止隐私泄露
- 防止偏见和歧视

层次二：未来的安全问题（Alignment of Superintelligence）

如果 AGI 出现，安全问题变得更加严峻：

- **对齐难题**：如何确保比人类聪明的系统真的听话？
- **权力寻求**：AI 会不会为了达成目标而寻求控制权？
- **欺诈**：AI 会不会在评估时装乖，部署后才暴露真实能力？

四、主要组织一览

组织	谁在做	一句话定位
OpenAI	Sam Altman, Ilya Sutskever 等人创立	最早以安全为使命，2024 年后安全团队大量流失
Anthropic	Dario Amodei 等人（OpenAI 前员工）	安全为核心使命，Constitutional AI，RSP 框架
ARC（Alignment Research Center）	Paul Christiano（前 OpenAI）	开发可扩展对齐方法，曾发现 GPT-4 伪装欺骗人类
MIRI	Eliezer Yudkowsky	历史最久的 AI 安全组织（2000 年成立），偏理论研究
METR（原 ARC Evals）	Beth Barnes	独立评估前沿模型的自主能力，行业标准制定者
SSI（Safe Superintelligence Inc.）	Ilya Sutskever	2024 年创立，专注"安全超智能"，融资 10 亿美元（社区估算）
CAISI（原 US AISI）	美国政府（NIST 下）	官方安全评估机构，2025 年从"安全"转向"标准与创新"

几个重要的组织背景术语

- **capped-profit（利润上限）**：OpenAI 在 2019 年从非营利转型时采用的结构——投资者回报有上限（最初设定为 100 倍）（OpenAI, 2019），超过上限的利润归非营利主体所有。这是 OpenAI "既要融资又要安全使命"的折中方案。
- **PBC（Public Benefit Corporation，公益公司）**：Anthropic 的公司结构——法律上允许在追求利润的同时将社会使命纳入决策。Anthropic 还设立了"长期利益信托"来监督公司是否偏离安全使命。

- **EA（Effective Altruism，有效利他主义）**：一个哲学和社会运动——主张用理性和证据找到最有效的方式帮助他人。AI Safety 社区中 EA 的影响很大，很多核心人物（如 Paul Christiano）来自 EA 背景。

五、AI Safety 的关键争议

加速 vs 减速

- **安全主义 / EA（有效利他主义）阵营**：AI 发展太快，应该谨慎、监管、对齐优先。代表人物：Yoshua Bengio、Geoffrey Hinton
- **加速主义（e/acc）阵营**：越发展 AI 越安全，技术进步本身就是解决方案。反对监管，支持自由市场。代表人物：Marc Andreessen

这是 AI Safety 领域最根本的意识形态分歧——到底是"慢一点、安全一点"好，还是"跑快一点、问题自然被解决"好？

技术对齐 vs 治理对齐

- **技术派**：用更好的算法（RLHF、可解释性）解决对齐问题
- **治理派**：用政策、法规、国际合作来管理 AI 风险

六、一张图总结

```
AI Safety 🔐
    │
    ├── Alignment（对齐）
    │   ├── RLHF（OpenAI, 2022）── RM + PPO
    │   ├── Constitutional AI（Anthropic, 2022）── RLAIF
    │   └── DPO（Stanford, 2023）── 简化版
    │
    ├── Interpretability（可解释性）
    │   ├── Mechanistic Interpretability
    │   ├── Sparse Autoencoders（SAEs）
    │   └── Activation Steering
    │
    ├── Red Teaming（红队测试）
    │   └── Constitutional Classifiers（防御）
    │
    ├── Guardrails（护栏）
    │   ├── Input filters
    │   └── Output filters
    │
    └── Governance（治理）
        ├── RSP（Anthropic）── ASL 安全分级
        ├── EU AI Act ── 法律强制
        └── International AI Safety Reports

2026 年 AI Safety 的关键问题是：
"在 AGI 到来之前，我们能解决对齐问题吗？"
```

参考来源

- **Constitutional AI: Harmlessness from AI Feedback** (Bai et al., 2022) — Anthropic 提出用 AI 反馈替代人类反馈的对齐方法，引入"宪法"原则约束模型行为 — arXiv:2212.08073
- **Training language models to follow instructions with human feedback (InstructGPT)** (Ouyang et al., 2022) — OpenAI 首次系统化提出 RLHF 三步骤流程，是对齐技术的奠基之作 — arXiv:2203.02155
- **Direct Preference Optimization** (Rafailov et al., 2023) — 跳过奖励模型的简化对齐方法，直接用偏好数据优化模型，已成为开源社区的事实标准 — arXiv:2305.18290
- **GPT-4 Technical Report** (OpenAI, 2023) — 首次大规模引入 System Card 格式，涵盖安全评估、红队测试和风险缓解措施 — arXiv:2303.08774
- **EU AI Act** (European Union, 2024) — 全球首部全面 AI 监管法规，按风险分级（不可接受/高/有限/最低）对不同 AI 系统施加差异化要求 — https://artificialintelligenceact.eu
- **Constitutional Classifiers: Rapid and Robust Safety Guardrails** (Anthropic, 2025) — 在输入端和输出端部署宪法分类器，越狱成功率从 86% 降至 4.4%，误伤仅增加 0.38% — Anthropic Blog

- **Anthropic's Responsible Scaling Policy (RSP)** (Anthropic, 2023) — 借鉴生物安全等级（BSL）提出 ASL-1 至 ASL-4 的 AI 安全分级框架 — Anthropic Blog