AI 搜索 前置知识

> 这份文档为零基础读者准备。如果你已经熟悉 AI 搜索的基本概念，可以直接翻阅主报告。

> 🎯 **读完这篇你能**：画出 RAG 的核心流程（检索 → 增强 → 生成），解释它为什么能缓解幻觉问题，并能判断什么场景下 AI 搜索比传统搜索更有效。

一、AI 搜索是做什么的?

AI 搜索就是把大语言模型（LLM）和搜索引擎结合起来，让搜索结果从"一堆蓝色链接"变成"一个直接答案"。

传统搜索引擎的工作方式：

```
你搜"2024年中国GDP是多少"
  → Google/百度返回一堆链接
  → 你一个个点开看，自己找答案
  → 可能要点 3-5 个网页才能拼出答案
```

AI 搜索的工作方式：

```
你搜"2024年中国GDP是多少"
  → AI 搜索：搜索网络 → 阅读多个网页 → 综合 → 直接告诉你答案
  → "2024年中国GDP为134.9万亿元，同比增长5.0%。来源：国家统计局"
```

省去了"打开链接→找答案→确认"的步骤。这就是 AI 搜索的核心价值：**从"给链接"到"给答案"**。

二、关键概念

RAG（Retrieval-Augmented Generation，检索增强生成）

AI 搜索的技术基础（Lewis et al., Facebook AI, 2020）。AI 模型不靠自己的知识回答——它先搜索网络，把搜到的内容作为"参考资料"，再基于这些资料生成答案。

类比：RAG 就像开卷考试，而纯模型回答是闭卷考试。闭卷靠记忆（模型参数里的知识），可能记错或过时；开卷可以翻书查资料，答案更准确。AI 搜索本质上是让每个问题都变成"开卷考试"。

这跟 ChatGPT 纯靠模型参数回答问题不一样。纯靠模型（比如让 GPT 直接回答"2024年GDP"）可能遇到知识截止日期或幻觉。RAG 模式先搜了最新数据再回答，准确性和时效性都更好。

RAG 的核心流程：

```
用户提问 → 搜索引擎检索相关页面 → 提取页面内容
  → 把内容+问题一起发给 LLM → LLM 基于搜到的内容生成答案
```

幻觉（Hallucination）

AI 模型会"编造"看起来合理但其实不对的内容（Ji et al., 2023）。在 AI 搜索中，幻觉尤其危险——用户相信搜索结果应该是"真实"的。

类比：就像班里一个成绩不怎么样但特别自信的同学——老师说"谁知道 GDP 是多少？"，他立刻举手说"134.9万亿！"即使说对了你也不知道他是真知道还是蒙的。更可怕的是，他还会编造出看起来完全正确但其实是瞎说的答案。

2024 年 Google AI Overviews 翻车事件就是典型（Google, 2024）：AI 建议用户在披萨上加胶水防止奶酪滑落（曲解了一个 Reddit 玩笑帖）。这暴露了 AI 搜索的核心风险——90% 的正确率意味着每 10 次回答就有 1 次可能出错。

引用来源（Citation）

AI 搜索区别于 ChatGPT 纯生成的关键设计：每个答案后面标注了信息来源。Perplexity 定义了"对话式+引用来源"的范式（Perplexity）——先给答案，再告诉用户答案来自哪里。用户自己可以点进去验证。

类比：就像老师告诉学生答案后还要说"这个答案在第 37 页的第三段"，而不是只给答案。有了引用来源，你才能判断这个答案靠不靠谱——而不是只能"信"或"不信"。

深度搜索（Deep Research）

2025–2026 年的新能力——AI 不只是回答一个问题，而是针对复杂问题做"多步研究"：

类比：普通搜索就像一次问一个简单问题（"北京今天多少度？"）。深度搜索就像你雇了一个研究助理——你只问了一句"2026 年最适合做 AI 创业的城市"，助理自己会想"这个问题需要查排名、政策、人才、融资"，然后分别查完再给你一份综合报告。

例子：搜"2026年最适合做 AI 创业的城市"

→ AI 先搜全球 AI 创业城市排名

→ 发现需要知道政策支持、人才密度、融资活跃度

→ 分别搜这三个方面

→ 综合形成分析报告

Perplexity 的 Pro Search、You.com 的 ARI、Genspark 的 Agent 工作台都在做这个。

三、AI 搜索的产品形态

形态	代表	特点
对话式搜索	Perplexity、秘塔	像聊天一样搜索，每个答案带引用
传统搜索 + AI 摘要	Google AI Overviews、百度	在原有搜索结果上加 AI 摘要框
深度研究引擎	Kimi、Genspark	处理长上下文，做多步调研写报告
AI Agent 工作台	Genspark (后期)、Comet	不只是搜索，还能帮你执行任务（订票、填表）

四、商业模式为何难以解决?

Google 靠搜索广告年收入 2000 亿美元（Alphabet 2024 年报）。AI 搜索面临一个结构性问题：

传统搜索 → 用户点广告 → Google 赚钱

AI 搜索 → AI 直接告诉用户答案 → 用户不点广告了 → 钱从哪来?

Perplexity 试过广告模式，但 2026 年放弃了——原因是"答案引擎"的页面空间有限，放广告会破坏体验。现在转向订阅 + 企业 API。

另一个问题是 **算力成本**：传统搜索一次请求的成本约 $0.0002（社区估算），AI 搜索一次请求的成本约 $0.01–0.05（社区估算，调用 LLM 的费用）。成本差了 50–250 倍。

五、主流产品速览

产品	一句话
Perplexity	AI 搜索的品类定义者（Perplexity），2026 年估值 $210 亿（社区估算）
Google AI Overviews	传统搜索巨头被迫 AI 化（Google, 2024），至今准确率争议未消
Kimi	月之暗面（Moonshot AI / 月之暗面），200 万字上下文，适合深度研究
秘塔 AI 搜索	"中国版 Perplexity"，中文搜索体验好
天工 AI 搜索	国内第一款 AI 搜索（2023.08），昆仑万维
豆包	字节跳动，App 端使用量最大的国产 AI 搜索
Genspark	前百度 VP 创立，45 天冲到 $3600 万 ARR（社区估算）
You.com	最早做 AI 搜索（2021），后来转向企业端

六、一个简单的直觉

```
传统搜索 = 图书馆 + 管理员指路
（给你说"在第三排第二列"，你自己去找）

AI 搜索 = 图书馆 + 管理员帮你把书读完了告诉你答案
（直接说"答案是这个，在第 37 页和第 42 页都提到了"）
```

AI 搜索的效率更高，但风险也更大——图书管理员可能读错了、可能曲解了原文。而且图书馆的收入模式（靠指路收广告费）被颠覆了。这就是 AI 搜索在 2026 年的真实状态：**技术上更先进，商业模式上还在探索中。**

参考来源

- **Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks** (Lewis et al., Facebook AI, 2020) — RAG 奠基论文，提出"先检索再生成"范式，是 AI 搜索的核心技术基础 — https://arxiv.org/abs/2005.11401
- **Survey of Hallucination in Natural Language Generation** (Ji et al., 2023) — 幻觉问题的系统性综述，涵盖成因、分类和缓解方法，AI 搜索可靠性问题的理论基础 — https://arxiv.org/abs/2202.03629
- **Perplexity AI** (Perplexity) — AI 搜索品类定义者，开创"对话式搜索 + 引用来源"范式，2026 年估值 $210 亿 — https://www.perplexity.ai/
- **Introducing ChatGPT Search** (OpenAI, 2024) — OpenAI 将搜索能力直接集成到 ChatGPT，标志着基础模型厂商正式进入搜索赛道 — https://openai.com/index/introducing-chatgpt-search/
- **Generative AI in Search** (Google, 2024) — Google AI Overviews 的官方发布，传统搜索巨头被迫 AI 化的标志性事件 — https://blog.google/products/search/generative-ai-search/
- **Kimi** (Moonshot AI / 月之暗面) — 国内深度研究引擎代表，支持 200 万字上下文，适合复杂问题的多步调研 — https://kimi.moonshot.cn/