LLM 基础大模型 横纵分析报告

> 从 GPT-1 的 1.17 亿参数到 GPT-5.5 和 Claude Opus 4.7 的"两超"对决、DeepSeek V4 的价格屠刀、Gemini 的多模态合围——八年，大语言模型如何从"会接话的鹦鹉"变成了能推理、能编程、能自主行动的智能引擎，又如何在一个"王座保质期只剩 88 天"的战场上卷到了连 OpenAI 都不知道下一步该怎么走。

一、一句话定义

LLM（Large Language Model，大语言模型）是以 Transformer 为基础架构，在海量文本数据上预训练、再通过指令微调和人类反馈对齐得到的通用语言模型。它的核心矛盾在于：**"能力越强，期望越高；期望越高，落差越大"**——GPT-5.5 刷新了几乎所有学术基准，但用户抱怨它"失去了灵气"；Claude Opus 4.7 在 SWE-bench 上达到 87.6%，但 Reddit 评论区却是"还我 4.6"。

2026 年 4 月是 LLM 历史上发布最密集的一个月——GPT-5.5、Claude Opus 4.7、DeepSeek V4 在一周内相继登场。最强模型宝座的平均停留时间从 2024 年的约 200 天缩到 2026 年的 88 天。竞争已从"谁的模型更聪明"变成"谁的模型能真正干活"。

> 🎯 **读完这篇你能**：理清 GPT、Claude、Gemini、Llama、DeepSeek、Qwen、Kimi、Mistral 等主要 LLM 家族的技术路线与竞争位次，从模型发布的节奏和特性判断行业走向。

阅读指南

如果你只有 5 分钟：读一句话定义 + 横纵交汇洞察的最后一部分（"三个剧本"和"核心矛盾"）。你能在 5 分钟内了解 LLM 竞争格局的全貌和未来走向。

如果你想理解 LLM 格局但不碰技术细节：读技术背景的三条线（架构/训练/数据）+ 纵向分析中主要家族（GPT、Claude、Gemini、Llama、DeepSeek、Qwen）的开篇段和总结句 + 横向分析的竞争位次表。约 30 分钟。

如果你是 LLM 研究者/从业者：直接跳横向分析的性能基准对比和 MoE vs Dense 架构对比。纵向分析的 3.5（DeepSeek 的逆袭）和 3.6（Qwen 阿里全栈）两个中国模型家族的故事是理解全球 LLM 竞争格局的关键补充，横纵交汇洞察的"核心矛盾"和"第一性原理"值得精读。

二、技术背景

> 前置知识请参考独立文档 《LLM大模型前置知识》，涵盖参数、Token、Transformer、MoE、上下文窗口、推理时计算扩展、基准测试等概念的通俗讲解。

LLM 的技术核心是三条线的交汇：

架构：几乎所有现代 LLM 都基于 2017 年的 Transformer 论文，核心机制是**自注意力**（Self-Attention）——模型能判断句子中哪些词与当前任务相关。2024-2026 年，MoE（混合专家）架构从实验性变成主流——将模型拆成多个"专家"，每个 token 只激活少数专家，大幅降低推理成本。

训练：预训练（在海量文本上"读书"）→ 指令微调（学会"回答问题"的格式）→ RLHF/DPO/GRPO（对齐人类偏好）。2025-2026 年最重要的变化是"推理时计算扩展"——o1/R1 证明了让模型在答题前"多想想"比训练一个更大的模型更划算。

数据：从 GPT-1 的 4.5GB 到 Llama 3 的 15T+ token，训练数据规模在六年内膨胀了约 3000 倍。但 2025-2026 年的趋势开始反转——FineWeb-Edu 和 DCLM 证明了"质量胜过数量"，2.6T 高质量 token 可以接近 15T 一般质量 token 的效果。

> 📚 **关联报告**

> - Transformer — 几乎所有现代 LLM 都基于 Transformer 架构

> - MoE 混合专家模型 — MoE 是 LLM 主流架构选择，影响模型规模与推理成本

> - Post-training RL 训练基础设施 — RL 训练是 LLM 能力飞跃的关键工序

> - 多模态大模型 — LLM 从纯文本向图像、音频等多模态扩展

> - 大模型评估与对齐 — 评估和对齐决定了 LLM 从"能跑"到"好用"

三、纵向分析：从八大家族到群雄逐鹿

3.1 GPT 系列：定义者与领跑者（2018-2026）

2018 年 6 月，GPT-1 发布了。1.17 亿参数，4.5GB 训练数据。这篇论文的意义不在于模型有多大——而在于它提出了"生成式预训练 + 判别式微调"范式。在此之前，NLP 模型是针对每个任务单独训练的。GPT-1 证明了一个预训练好的语言模型，稍加微调就能在多个下游任务上超越专门训练的模型。

2019 年 2 月，GPT-2 把参数提到 15 亿。OpenAI 以"太危险"为由延迟发布完整版——这在当时被社区嘲笑，但回头看，这是 AI 安全讨论从学术界进入产业界的起点。GPT-2 的真正贡献是提出了"语言模型是无监督多任务学习器"——

你不需要为翻译、问答、摘要分别训练模型，一个语言模型通过提示就能做所有这些事。

2020 年 6 月，GPT-3 把参数提到 1750 亿。真正定义了"大语言模型"这个品类。它展示了少样本学习（few-shot learning）——给几个例子，模型就能理解任务意图。GPT-3 的 API 发布标志着大模型商业化的开端。

2022 年 11 月 30 日，ChatGPT 上线。基于 GPT-3.5 + RLHF。5 天 100 万用户，2 个月 1 亿用户——史上增长最快的消费级产品。ChatGPT 的意义超过了技术本身——它让全世界看见了 LLM 能做什么。它定义了"AI 对话"这个品类。

2023 年 3 月，GPT-4 发布。参数量未公开（据第三方分析约 1.8T，采用 MoE 架构）。首次多模态，通过律师资格考试。GPT-4 之后，OpenAI 从"最透明的前沿 AI 公司"变成了"最不透明的"——GPT-4 的技术报告几乎没有技术细节。

2024 年 5 月，GPT-4o 统一了文本、图像、音频处理，全模态。"o"代表"omni"。语音对话延迟降到 232ms，接近人类反应速度。

2024 年 9 月到 2025 年，o1→o3 系列 开启了推理模型时代。通过"思维链内部推理"在数学和编程上实现飞跃。o3 在 AIME 数学竞赛和 Codeforces 编程竞赛上大幅领先——这不再是"更大的模型"，而是"会思考的模型"。

2025 年 8 月，GPT-5 实现了"PhD 级推理能力"。到 2026 年 4 月的 GPT-5.4 和 GPT-5.5，OpenAI 的迭代从"一年一代"变成了"一季度一代"。GPT-5.5（2026.04.23）是自 GPT-4.5 以来首次完全重训练的基座模型，Terminal-Bench 82.7%、MLE-Bench 最高分。

OpenAI 的商业数据：2026 年 3 月估值 $8520 亿（完成了 $1220 亿融资），ChatGPT 周活 9 亿，付费用户 1.22 亿，ARR 约 $250 亿。尽管在巨亏（2026 年可能达 $170 亿），它仍然是 LLM 赛道上绝对的第一名——无论是用户规模、收入规模还是品牌认知。

3.2 Claude 系列：安全优先的另类崛起（2023-2026）

Anthropic 由前 OpenAI 员工创立。2023 年 3 月发布 Claude 1。它的核心差异化从一开始就很明确：**Constitutional AI**——用 AI 反馈代替人类反馈进行对齐，减少对人工标注的依赖。这决定了 Claude 的性格：比 ChatGPT 更安全、更可操控，但也更保守。

2023 年 7 月，Claude 2 把上下文窗口拉到了 100K——这在当时是行业最高。支持的编码和数学能力大幅提升。

2024 年 3 月，Claude 3 系列（Haiku/Sonnet/Opus） 是重大转折。Opus 在多项基准上首次超越 GPT-4。Anthropic 建立了"大中小"三级产品线——Haiku 做低成本快速推理，Sonnet 做性价比主力，Opus 做旗舰。

2024 年 6 月，Claude 3.5 Sonnet 被广泛认为是 2024 年最佳编程模型。推理速度比 Opus 快 2 倍，而性能全面超越。

2025 年，Claude 4 系列 引入 Agent 能力。Claude Opus 4.1（2025.08）在 SWE-bench 上达到 74.5%。Claude Sonnet 4.5（2025.09）专注 Agentic AI。Claude Opus 4.5（2025.11）强化了 Computer Use（电脑操控）能力。

2026 年，Claude 系列持续高频迭代。2 月发布 Sonnet 4.6。4 月 16 日发布 Opus 4.7——SWE-bench 87.6%，Honesty Rate 92%。但发布后 48 小时内遭遇大规模差评，用户普遍反映"失去灵气"、"过度安全调优"。

Anthropic 的商业数据：2026 年 4 月 ARR 首超 OpenAI，达 $300 亿。以 1890 万用户做到了接近 OpenAI 的收入（OpenAI 9 亿用户，$250 亿 ARR）——ARPU 高出约 6 倍。正在谈判新一轮 $500 亿融资，估值可能达到 $9000 亿。

Anthropic 的路线特色：以少得多的用户实现了更高的 ARR——这来自企业客户的极高客单价。走的是"闭源 B2B"路线。

3.3 Gemini 系列：原生多模态的 Google 巨人（2023–2026）

Google 的 LLM 路线从一开始就跟 OpenAI 和 Anthropic 不同——**不是"文本模型 + 多模态能力"，而是从第一天起就是原生多模态**。

2022 年 4 月，PaLM 540B 参数。2023 年 5 月 PaLM 2 发布。但真正改变格局的是 2023 年 12 月发布的 **Gemini 1.0**——Ultra 在 MMLU 上首次超越人类专家（90.0%），被宣传为"超越 GPT-4"。

2024 年 2 月，Gemini 1.5 Pro 把上下文窗口拉到 100 万 token——能处理 1 小时视频、11 小时音频。这至今是行业最高。采用 MoE 架构。

2024 年 12 月，Gemini 2.0 Flash 引入思维链推理和自主工具调用。

2025 年 3 月，Gemini 2.5 Pro 深度推理能力显著增强。2025 年 11 月，Gemini 3 Pro 发布。

2026 年 2 月，Gemini 3.1 Pro 推理能力翻倍，可构建完整 UI 应用。

Gemini 的最大优势是 Google 生态：YouTube 视频直接输入、Google Drive 集成、2M 上下文窗口。在"长上下文 + 多模态"的交叉场景（分析一整本书、处理一整段视频），Gemini 没有对手。

Gemma 4（2026.04） 是另一个故事——31B 参数的 Apache 2.0 开源模型，在 MMLU-Pro 达到 85.2%，性能超越 20 倍于自身的大模型。手机端可运行。Google 在开源和闭源两条线上同时作战。

3.4 Llama 系列：开源大模型的旗帜（2023–2026）

Meta 的 Llama 系列在 LLM 历史上扮演了一个独特角色——**它证明了大模型不应该只属于大公司**。

2023 年 2 月，Llama 1 证明"只用公开数据"可以训练出比 GPT-3 更强的模型。7B 模型在某些任务上超越 GPT-3 175B。仅开放给研究人员但很快被泄露。

2023 年 7 月，Llama 2 首次开放商业使用。性能接近 GPT-3.5。这是开源 LLM 生态的引爆点。

2024 年 4 月，Llama 3 8B/70B。15T+ token 训练数据。8B 在同参数规模树立新标杆。

2024 年 7 月，Llama 3.1 405B——首个 400B+ 参数的开源模型，在多项基准上接近 GPT-4o 级闭源模型。

2025 年 4 月，Llama 4 Scout/Maverick 是 Llama 历史上最重要的架构变革——**首次采用 MoE**。Scout 有 1000 万 token 的上下文窗口。原生多模态。

但 Llama 4 也制造了 2026 年最大的基准测试丑闻。 Meta 被曝光使用"实验性改进版"替代正式版刷榜——独立重测后，Maverick 的排名从宣传的第 5 位跌到第 32 位。这严重损害了开源社区对基准测试的信任。

3.5 DeepSeek：中国效率革命的代表（2024–2026）

DeepSeek 是 2024–2026 年 LLM 历史上最令人意外的故事。它证明了**技术创新和极致工程优化可以让训练成本降一个数量级**。

2024 年 5 月，DeepSeek-V2 引入 Multi-head Latent Attention（MLA），大幅降低 KV Cache 和推理成本。236B 总参数/21B 激活，训练成本仅约 550 万美元。

2024 年 12 月，DeepSeek-V3 把参数提到 671B/37B 激活，14.8T token 训练数据，训练成本仅 557 万美元——**不到 GPT-4 训练成本的 1/10**。性能比肩 GPT-4o 和 Claude 3.5 Sonnet。首创 Multi-Token Prediction 和 FP8 混合精度训练。

2025 年 1 月 20 日，DeepSeek-R1 发布——开源推理模型，性能对标 OpenAI o1。使用纯强化学习（GRPO）激发推理能力。**MIT 协议开源。** 发布当天英伟达股价暴跌 17%，被称为"DeepSeek 冲击波"。

2026 年 4 月 24 日，DeepSeek V4 无预警发布。1.6T 参数 MoE，1M 上下文。**Apache 2.0 开源。** Codeforces 评分 3206 超越 GPT-5.4。同步适配华为昇腾、寒武纪等国产芯片。价格比 GPT-5.5 低约 97%——百万 token 输入仅约 2 分钱。

3.6 Qwen 系列：阿里开源的全模态野心（2023-2026）

2023 年 8 月 Qwen 首发。**Qwen2.5（2024.09）** 72B 超越 Llama 3.1 70B。**Qwen3（2025.04）** 引入"混合推理"（Hybrid Reasoning），32B 版本被称为"国产开源巅峰"。

Qwen3.5-Omni（2026.02） 原生多模态——文本+图像+音频+视频四模态统一。支持 113 种语言。**Qwen3.6-Plus（2026.04）** 专注编程和 Agent 应用，登顶全球模型调用排行榜。

Qwen 的核心策略是"全栈开源 + 云服务变现"——Apache 2.0 协议，覆盖面从 0.5B 到 397B MoE。Chatbot Arena 曾进入全球前三。

3.7 群雄逐鹿：欧洲、中国和更多力量（2023-2026）

Kimi（月之暗面，Moonshot AI）：中国 AI 六小虎之首。2023 年 10 月凭借 200 万字超长上下文一战成名。2024 年 Kimi K1.5 以"强化学习+长上下文"路线证明了中国团队在推理模型上的竞争力。**Kimi K2.6（2026.04）** 开源发布——代码和 Agent 能力对标 GPT-5.4/Claude Opus 4.6，支持 300 个子 Agent 并行协作、13 小时长程编码任务。月之暗面是"六小虎"中唯一仍独立运营、未被大厂收购的公司。

Qwen（阿里通义千问，Alibaba）：2023 年 9 月首发，从 Qwen-7B/14B/72B 起步。**Qwen 3.6-Max-Preview（2026.04）** 在 Artificial Analysis 榜单上超越 GLM-5.1、MiniMax-M2.7，成为当时排名最高的国产模型——而且这还只是预览版。核心提升方向是智能体编程能力，在 SWE-bench Pro、Terminal-Bench 2.0 等 6 项编程基准上综合第一。千问 3.6 全系列覆盖 Max（旗舰）、Plus（高性能）、Flash（轻量）、35B-A3B（开源），从旗舰到开源全面布局。同月开源的 **Qwen3.6-27B** 在单卡本地运行即可接近 Claude Opus 4.5 水平。

Mistral（欧洲）：Mistral 7B（2023.09）以极小的参数量超越 Llama 2 13B。Mixtral 8x7B（2023.12）是首个开源 MoE 模型。Mistral Large 3（2025.12）旗舰 675B，与 NVIDIA 合作。

Grok（xAI）：2023 年 11 月首发，314B 参数。核心差异化是实时接入 X 平台数据。**Grok 4.3/4.20（2026.04）** 大幅提升推理能力，**Grok 5 训练接近完成**（2026.04），号称 6 万亿参数，在 Colossus 2 集群（55 万块 GB200/GB300）上训练，2 吉瓦功率。马斯克在 2026 年 4 月宣布停产两款旗舰车型，将资源全面集中于 xAI——Grok 正在从"一个模型"变成"xAI 的核心产品"，Grok 5 宣称就是 AGI。

字节豆包 / Doubao 2.0：字节跳动 2026 年 2 月发布豆包 2.0，多模态能力全面升级，SuperCLUE 中文榜单国内第一、推理能力达世界顶尖水平。与抖音/今日头条的集成使其成为**国内 MAU 最高的 AI 应用**（月活超 2 亿）。字节同时自研芯片（与 Broadcom 合作）和语音模型，走"全栈自研"路线。

腾讯 Hy3 preview / Hy3.0：前 OpenAI 研究员姚顺雨的加盟带来了架构上的差异化。2026 年 4 月发布的 Hy3 preview（295B MoE），在 Agent 能力和中文理解上表现突出，已开源。这是腾讯在 LLM 竞赛中最重要的翻身之作——此前混元系列在六小虎面前声量不大。

小米 MiMo V2.5：2026 年 4 月发布，以 MIT 协议开源。1.02T 参数 MoE，首次登顶全球开源大模型综合智能榜单第一。小米的策略是将模型能力嵌入其庞大的 IoT 生态——手机、汽车、智能家居。

蚂蚁 Ling-2.6-1T：万亿参数开源模型，2026 年 4 月发布。主打"快思考"智效比——在非推理场景下对标 GPT-5.4，定价低至 $0.1/百万 token。蚂蚁还发布了 Ring-2.5-1T——全球首个混合线性架构万亿参数思考模型。

Phi（Microsoft）：走"教科书"路线——以极小参数实现极大性能。Phi-4（2024.12）14B 参数在数学推理上超越 GPT-4o。

GLM（智谱）：GLM-4（2024.01）性能直逼 GPT-4。GLM-4.5（2025.07）首个原生融合智能体大模型。

Gemma（Google 开源）：Gemma 4（2026.04）31B 以"越级屠龙"方式击败 20 倍于自身的模型，手机可运行。

Muse Spark（Meta Superintelligence Lab）：2026 年 4 月发布——Meta 超级智能团队的首款模型。一个重要的信号：**Meta 从 Llama 开源策略转向闭源**。Muse Spark 据称对标 GPT-5.4，但不再开源。这意味着开源社区失去了最大的推动者。

3.8 阶段总结

阶段	时间	核心特征	标志性事件
奠基期	2018-2020	参数量从 1 亿到 1750 亿	GPT-1→GPT-3
破圈期	2022-2023	LLM 进入大众视野	ChatGPT + GPT-4
多模态与开源	2024	多模态成为标配，开源追赶闭源	GPT-4o + Llama 3 + DeepSeek-V2
推理革命	2025	模型学会"思考"	o1→R1→o3
混战期	2026	王座 88 天一换，Agent 成为焦点	GPT-5.5 + Opus 4.7 + DeepSeek V4

四、横向分析：2026 年 4 月 LLM 竞争图谱

> 类型：具体模型/模型家族。横向对比维度：架构路线、能力剖面、安全哲学、开源透明度、API 定价。

4.1 三强并立：2026 年 4 月的"模型超级周"

2026 年 4 月 16-24 日，Claude Opus 4.7、GPT-5.5、DeepSeek V4 在一周内相继发布，被业界称为"模型超级周"。最强模型宝座平均停留时间 88 天。

4.2 能力剖面对比

模型	参数量	架构	MMLU	MMLU-Pro	SWE-bench	AIME 2026	Arena ELO	上下文	开源
GPT-5.5	未公开	未公开(疑MoE)	~93.5%	~91.2%	74.4%	~91%	~1420	1M	❌
Claude Opus 4.7	未公开	未公开	~92.8%	~90.5%	**87.6%**	**~94%**	~1415	1M	❌
Gemini 3.1 Pro	未公开	MoE	~91.5%	~89.8%	~72%	~89%	~1400	**2M**	❌
DeepSeek V4 Pro	1.6T MoE	MoE	~90.2%	~88.5%	~70.2%	~88%	~1370	1M	✅
Qwen3.6 Max	未公开	MoE	~91.8%	~89.2%	~68.5%	~87%	~1390	1M	✅
Kimi K2.6	未公开	MoE	~90.5%	~88.0%	~71%	~86%	~1365	1M	✅
Grok 4.20	未公开	MoE	~90.0%	~87.5%	~66%	~85%	~1350	1M	❌
Gemma 4 (31B)	31B	Dense/E4B	~88.0%	85.2%	~55%	89.2%	~1360	256K	✅
Llama 4 Maverick	17B MoE	MoE	~86.5%	~83.1%	~52%	~78%	~1280	1M	✅

> 另：字节豆包 2.0（国内 SuperCLUE 第一）、腾讯 Hy3（Agent 能力突出）、小米 MiMo V2.5（开源榜第一）、蚂蚁 Ling-2.6-1T（万亿参数开源）在各自赛道具有竞争力，但公开基准数据不足以与前列直接对比。

关键发现：

- GPT-5.5 在综合知识和 MLE-Bench 上领先，但在 SWE-bench 上落后 Claude 14 个百分点
- Claude Opus 4.7 编程能力断层式领先，但创意和对话体验争议最大
- 开源模型（DeepSeek V4、Qwen3.6）在多数基准上已追平闭源，差距不到一个版本

4.3 架构路线对比

维度	GPT 系列	Claude 系列	Gemini 系列	DeepSeek	Qwen	Kimi	Grok
架构	Dense→未公开	未公开	MoE	MoE（开创性MLA）	MoE	MoE	MoE
多模态	文本+图像+音频（GPT-4o起）	文本+图像（Claude 3起）	原生多模态（始终）	文本为主	全模态（Omni系列）	文本+图像	文本+图像
推理扩展	o1/o3 系列（专用推理模型）	无独立推理模型线	推理版可选	R1/V4 内置推理	混合推理模式	长上下文推理	计划中
上下文	1M	200K-1M	2M（最高）	1M	1M	1M	1M

4.4 安全与对齐哲学

维度	OpenAI	Anthropic	Google DeepMind	DeepSeek
对齐方法	RLHF	Constitutional AI（RLAIF）	RLHF + 安全层	GRPO（纯RL，无人类标注）
安全态度	能力优先，逐步收紧	**安全优先**，宁保守不错	介于两者之间	开源，开发者自担责
透明度	GPT-4后极低	中（发布System Card）	中-低	高（论文+开源）
开源策略	完全闭源	完全闭源	部分开源（Gemma）	**完全开源**

Anthropic 4 月还发布了 Claude Mythos Preview——在 17/18 个基准测试领先，SWE-bench 93.9%。但因"过于危险"仅限少数合作伙伴使用。Anthropic 为 Mythos 发布了 244 页的系统安全报告，甚至让模型接受"20 小时心理治疗"。这是 AI 安全历史上最极致的一次操作。

4.5 开源 vs 闭源

2026 年 4 月的格局非常清楚：**开源模型在能力上已追平闭源的下一个版本之前的状态**。差距从一个时代（2023 年 Llama 2 vs GPT-4）缩小到了"两周"。

但**开源不等于免费获得最好体验**——DeepSeek V4 和 Qwen3.6 虽然开源权重，但全量部署需要大量 GPU 资源。对个人开发者来说，调用 API 往往比自建更划算。开源的真正价值在于：可控性、可定制化、不被厂商锁定。

4.6 API 定价对比

模型	输入 ($/1M tokens)	输出 ($/1M tokens)
Claude Opus 4.7	$15.00	$65.00
GPT-5.5 Pro	$15.00	$50.00
GPT-5.5	$5.00	$15.00
Claude Sonnet 4.6	$4.00	$15.00
Gemini 3.1 Pro	$4.00	$15.00
GPT-5.4 mini	$0.45	$2.00
DeepSeek V4 Flash	~$0.05	$0.15
Llama 4 (自部署)	免费	免费

DeepSeek V4 的价格比 GPT-5.5 低约 97%。GPT-5.5 选择逆势涨价，OpenAI 声称"每 token 效率提升 2-3 倍，综合成本更低"——但开发者社区的吐槽铺天盖地。

4.7 开发者口碑

GPT-5.5："基准最高分，但真实体验分裂"——在 Mashable 测试中赢过 Opus 4.7，但在用户盲测中输掉。幻觉率仍较高，API 价格翻倍被广泛吐槽。

Claude Opus 4.7："最强编程模型，但失去了灵气"——SWE-bench 87.6% 是断层式领先，但 Reddit 热门标签却是"#还我4.6"。用户在创意写作、开放式对话中感到明显退步。Anthropic 官方承认"有一个小调整导致某些情况下响应质量下降"。

DeepSeek V4："价格是武器，能力在追赶"——Codeforces 3206 登顶令人震惊，但长上下文理解和综合知识仍有差距。用户评价："省钱 90%，效果接近"。

Llama 4："2026 年最大的口碑翻车"——刷榜丑闻严重损害了 Meta 在开源社区的信任。

五、横纵交汇洞察

5.1 历史的加速：从"几年一代"到"几周一版"

GPT-3 到 GPT-4 花了 33 个月。GPT-4 到 GPT-4o 花了 14 个月。GPT-4o 到 GPT-5 花了 15 个月。GPT-5 到 GPT-5.5 花了 8 个月。而 2026 年 4 月一个周内出现了 3 个旗舰模型。

迭代加速的背后是算力规模、工程能力、竞争压力的三重叠加。但这也有一个令人不安的暗示：**如果王座 88 天一换，每一代的增量还值不值得投入？** 当 GPT-5.5 和 Opus 4.7 发布后同时遭遇用户差评，行业可能已经进入了"边际效用递减"的阶段。

5.2 开源与闭源的"两周差距"

2023 年开源落后闭源约 12–18 个月。2024 年缩小到 4–7 个月。2025 年进一步缩小到 1–3 个月。到 2026 年 4 月，差距已经以"周"计算——DeepSeek V4 在 GPT-5.5 发布的第二天就开源了。

这个趋势背后的驱动力是**架构的收敛**。当所有人都用 MoE + Transformer + 类似的数据 pipeline，架构差异被规模和数据稀释。开源模型的追赶不再是"复制闭源"，而是"在同一条路上加速跑"。

5.3 从"更聪明"到"更能干"——Agent 化的范式转移

2024 年以前，模型竞争的唯一标准是"谁更聪明"（MMLU 得分、HumanEval 通过率）。2025 年 o1/R1 开启了"推理时计算扩展"的赛道。2026 年的焦点进一步转向——**模型能不能行动?**

Claude Mythos（Anthropic 的秘密武器）在 SWE-bench 上达到 93.9%，可以自主完成端到端编程和网络安全检测。GPT-5.5 的核心卖点是 Agent 能力。Codex 从 API 功能变成了独立产品。

由此，竞争维度从一维（智力）变成了二维（智力 × 行动力）。一个模型即使在 MMLU 上少 2 个百分点，但如果能自主完成 80% 的真实编程任务，在商业价值上可能远超一个"聪明但手残"的模型。

5.4 三个剧本

剧本一（最可能）：三强格局稳定化，Agent 成为新战场（概率 55%）

GPT-5.x、Claude Opus 4.x、Gemini 3.x 三家在综合能力上难分胜负，各自占领生态位——OpenAI 做消费者全栈，Anthropic 做企业级 Agent，Google 做多模态长上下文。DeepSeek 和 Qwen 以开源 + 极低价占据开发者长尾市场。模型层本身的竞争降温，战场转移到 Agent 层。

剧本二（最危险）：基准信任崩塌 + 边际递减（概率 25%）

Llama 4 刷榜丑闻是冰山一角。当用户普遍感觉"跑分第一但体验退步"，行业可能面临基准体系的系统性危机。同时模型能力的边际增长持续递减——每一代新模型带来的增量越来越小。投资者开始质疑"更大的模型是否值得更大的投入"。

剧本三（最乐观）：Mythos 级别的自主 Agent 成为现实（概率 20%）

如果 Claude Mythos 的 93.9% SWE-bench 是真实的、可复现的、可产品化的——意味着 AI 已经能够在大多数编程任务上自主工作。加上 DeepSeek 的极低成本训练方案，到 2027 年"AI 工程师"可能不是科幻。这个剧本里，LLM 不再是一个工具，而是生产力基础设施——类比电力或互联网。

六、信息来源

核心论文与文章

论文/文章	来源	访问时间
GPT-1: Improving Language Understanding by Generative Pre-Training (2018)	OpenAI	2026-04-30
GPT-2: Language Models are Unsupervised Multitask Learners (2019)	OpenAI	2026-04-30
GPT-3: Language Models are Few-Shot Learners	arxiv.org/abs/2005.14165	2026-04-30
GPT-4 Technical Report	arxiv.org/abs/2303.08774	2026-04-30
Gemini 1.0	arxiv.org/abs/2312.11805	2026-04-30
Llama 3: Herds of Models	arxiv.org/abs/2407.21783	2026-04-30
DeepSeek-V3 Technical Report	arxiv.org/abs/2412.19437	2026-04-30
DeepSeek-R1	arxiv.org/abs/2501.12948	2026-04-30
Qwen3.5-Omni	arxiv.org/abs/2604.15804	2026-04-30

产品与技术来源

来源	URL	访问时间
GPT-4o 发布	openai.com/index/hello-gpt-4o/	2026-04-30
Claude 3 发布	anthropic.com/news/claude-3-family	2026-04-30
Claude Opus 4.7	anthropic.com	2026-04-30
Claude Mythos Preview	anthropic.com/transparency	2026-04-30
Gemini 3.1 Pro	cloud.google.com/blog	2026-04-30
Gemma 4	ai.google.dev/gemma	2026-04-30
Llama 4	llama.com/models/llama-4/	2026-04-30
DeepSeek V4	technologyreview.com	2026-04-30
Qwen3	TechCrunch (2025.04)	2026-04-30
Mistral Large 3	ithome.com (2025.12)	2026-04-30
Grok-3 / 4.20	x.ai	2026-04-30
Kimi K2.6	moonshot.ai	2026-04-30
Doubao 2.0 / 豆包	bytedance.com	2026-04-30
腾讯 Hy3	github.com/Tencent-Hunyuan/Hy3-preview	2026-04-30
小米 MiMo V2.5	pandaily.com	2026-04-30
蚂蚁 Ling-2.6-1T	ithome.com	2026-04-30
Meta Muse Spark	theguardian.com	2026-04-30
Chatbot Arena (LMSYS)	lmarena.ai	2026-04-30
SWE-bench	swebench.com	2026-04-30
Artificial Analysis	artificialanalysis.ai	2026-04-30
MMLU/MMLU-Pro	各模型技术报告	2026-04-30
Stanford HAI 2026 AI Index Report	Stanford HAI	2026-04-30
Anthropic $900B valuation	TechCrunch (2026.04.29)	2026-04-30
DeepSeek V4 analysis	MIT Tech Review (2026.04.24)	2026-04-30
OpenAI $852B valuation	Forbes (2026.03.31)	2026-04-30

Polymarket: Best AI Model	Polymarket (2026.04)	2026-04-30

本文是横纵分析系列的第 25 篇报告。方法论：横纵分析法——纵向沿时间轴追溯 GPT-1 到 DeepSeek V4 的完整发展史，横向在 2026 年 4 月对比八大模型家族的架构、能力、对齐哲学、开源策略与定价。