模型合并（Model Merging）前置知识

> 这份文档面向对 LLM 微调和开源模型生态有基本了解的读者。

> 🎯 **读完这篇你能**：理解什么是模型合并、为什么不需要重新训练就能组合模型能力、能说出 TIES/DARE/SLERP 各自做了什么、能判断一个合并模型是怎么做出来的。

一、模型合并是什么？

把两个或多个微调过的 LLM 的权重"加在一起"，生成一个新的模型，同时拥有源模型的各项能力——不需要任何重新训练，不需要任何数据。

直觉类比：你有两个人的技能——一个擅长写代码，一个擅长写小说。模型合并相当于把他们的"大脑"直接融合，造出一个既会写代码又会写小说的人。而且这个融合只花几秒钟，不需要重新训练。

这听起来像魔法。2023 年底社区发现它确实能工作时，整个开源 LLM 社区炸了。

二、为什么能合并？

因为所有微调模型都是从同一个预训练基座（如 Llama 2、Mistral 7B）出发，只走了不同的微调路径。它们在权重空间里都还停留在基座附近，相互之间的"距离"不大。

定义 **Task Vector（任务向量）** = 微调后权重 − 基座权重。合并就是对多个任务向量做某种运算，再把结果加回基座权重。

你可以理解为：基座模型是一个"通用大脑"，微调在上面叠加了"专项技能"。技能之间大部分参数不冲突，可以共存。

三、主要合并方法

3.1 SLERP（球面线性插值）—— 最简单的两个模型合并

在归一化的权重球面上，沿大圆弧插值。比简单线性平均更优雅——保持权重范数不变。

两个模型，一个参数 t 控制比例。t=0.5 表示各取一半。

3.2 TIES-Merging —— 解决"符号冲突"

三个模型以上简单平均时，A 模型的某个参数是 +0.5，B 模型的同一参数是 −0.4——一加就抵消了。TIES 三步解决：

1. **Trim**：扔掉微不足道的参数变化（只留变化大的）
2. **Elect Sign**：多数投票决定每个参数的方向（正 or 负）
3. **Disjoint Merge**：只合并方向一致的参数

3.3 DARE —— 随机丢掉 90% 还是好的

核心发现：微调带来的参数变化极度冗余。随机丢弃 90–99% 的 delta 参数，剩下的 rescale 一下，性能几乎不降。

DARE + TIES 组合（先 DARE 稀疏化，再 TIES 合并）是社区最常用的合并配方。

3.4 Model Stock —— 用 2 个模型逼近 N 个模型的效果

几何方法：用基座模型为原点，两个微调模型定义方向，通过几何投影找到"如果我有 N 个微调模型，它们应该在的位置"。

3.5 进化式合并 —— AI 自己找最优配方

Sakana AI 2024 年提出。把"怎么合并"当作一个优化问题，用进化算法自动搜索——哪层用哪个方法、参数多少、drop rate 多少。在多个 benchmark 上超越了人类手工调参的结果。

3.6 Frankenstein 合并 —— 按层拼装

最野的路子：模型 A 的前几层 + 模型 B 的中间几层 + 模型 C 的后几层，拼成一个新模型。完全不讲道理，但有时候效果惊人。2026 年 4 月社区爆火的 "Qwopus-GLM-18B" 就是这样拼出来的。

四、合并工具

- **MergeKit**（Arcee AI，7k+ stars）：Python 包，YAML 配置，支持所有主流方法，事实标准
- **evolutionary-model-merge**（Sakana AI）：进化搜索最优配方
- **LM-Mixer / Enhanced-LM-Mixer**：社区最早的合并脚本（历史文物）

五、核心矛盾

```
合并很容易（几秒、无需训练）
  vs
合并结果不可预测（同样的配方，换两个模型可能完全不一样）
```

到目前为止，没有理论能精确预测"合并这两个模型会不会好"。所有好用的合并配方都是靠 leaderboard 的即时反馈试出来的。这就是为什么模型合并有时被称为"新型炼丹术"。

参考来源

- TIES-Merging (Yadav et al., NeurIPS 2023) — https://arxiv.org/abs/2306.01708
- DARE / Language Models are Super Mario (Yu et al., ICML 2024) — https://arxiv.org/abs/2311.03099
- Task Arithmetic (Ilharco et al., ICLR 2023) — https://arxiv.org/abs/2212.04089
- MergeKit — https://github.com/arcee-ai/mergekit
- Evolutionary Model Merging (Akiba et al., 2024) — https://arxiv.org/abs/2403.13187
- Maxime Labonne "Merge LLMs with mergekit" — https://mlabonne.github.io/blog/