模型合并 横纵分析报告

> 两三个微调模型的权重加在一起，得到一个同时会写代码和写小说的新模型——不需要数据、不需要 GPU、几秒钟完成。开源社区 2023 年底偶然发现了这件事，然后论文在半年后才追上来解释"为什么它不应该能工作却偏偏能"。模型合并可能是 AI 社区史上"实践倒逼理论"最极致的案例。

一、一句话定义

模型合并（Model Merging）是在不重新训练的情况下，将多个从同一基座微调而来的 LLM 权重通过算法组合成一个新模型的技术。核心操作单元是**任务向量**（Task Vector）= 微调后权重 − 基座权重——所有的合并方法本质上都是在做"如何安全地把多个任务向量加回基座权重"。

> 🎯 **读完这篇你能**：理解模型合并为什么能工作、TIES/DARE/SLERP/Evolutionary 各自解决什么问题、能判断一个合并模型用了什么配方、理解从"社区炼丹"到"学术化"的全过程。

阅读指南

5 分钟：一句话定义 + 阶段 3.4（转折点）+ 横纵交汇（三个剧本）

25 分钟：加技术背景 + 纵向分析各阶段开头 + 横向对比表 + 著名合并模型表

专业：全文

二、技术背景

> 前置知识请参考 《模型合并前置知识》

所有微调模型共享同一个预训练基座。从权重角度看，它们都在基座附近的参数空间里——距离基座通常在数百到数千的 L2 范数，而基座权重本身的范数在百万级别。这意味着微调只改变了参数空间中极小的一块，且不同微调的改变之间大部分不重叠。

这解释了为什么合并能工作：**多个任务向量叠加时，它们之间的冲突（同一参数被不同方向拉扯）远少于直觉预期。** 但冲突确实存在。所有"高级"合并方法——TIES、DARE、Model Stock——本质上都在解决同一个问题：怎么处理那些被多个任务向量"往不同方向拉"的参数。

📚 **关联报告**

- PEFT 参数高效微调 — LoRA 微调是模型合并的主要源模型生产方式

- LLM 应用框架 — MergeKit 是模型合并的事实标准工具

三、纵向分析：从偶然发现到学术显学

3.1 学术前史（2021–2023.06）

社区发现模型合并之前，学术界已经有零星探索，但都在视觉模型上，LLM 社区完全没注意到。Model Soups (Wortsman et al., ICML 2022) 证明了同一基座的不同微调模型简单平均能提升 CLIP/ViT 精度。Task Arithmetic (Ilharco et al., ICLR 2023) 提出了"任务向量"的代数框架。TIES-Merging (Yadav et al., NeurIPS 2023) 从数学上解释和解决了合并中的参数冲突问题。

这些论文后来成为模型合并的理论基石——但它们在发表时，对 LLM 社区的影响力几乎为零。

3.2 社区"偶然发现"（2023.09 – 2023.12）

2023 年 7 月 Llama 2 开源，社区开始大量微调。到 9–10 月，HuggingFace 上有了几十个针对不同用途微调的 Llama 2 变体。

LostRuins（koboldcpp 作者）写了第一个通用 LLM 权重合并脚本 LM-Mixer。**Digitous** 在此基础上加了 SLERP。**Undi95** 写了 SLERP-MergeTest 专门测试。Reddit r/LocalLLaMA 是核心传播阵地，HuggingFace Open LLM Leaderboard 提供了即时验证——合并完立刻跑 benchmark 看分数。

2023 年 11 月，**Goliath-120B**——两个 Llama 2 70B 拼成的 frankenmerge——轰动社区。它没有什么理论基础，就是"把模型拼起来"，但结果让人震惊。

同月，阿里巴巴达摩院发表了 DARE / "Language Models are Super Mario"——第一个专门针对 LLM 合并的论文。论文发现随机丢弃 90%+ 的 delta 参数，合并后性能不降反升。这说明微调产生的参数变化极度冗余。

3.3 工具化爆发（2024.01 – 2024.03）

Charles Goddard 创建了 mergekit，统一了所有社区合并方法到一个 Python 包。

2024 年 1 月 8 日，Maxime Labonne（mlabonne）发表了博客 "Merge Large Language Models with mergekit"。这篇博客用清晰可复现的代码教会了整个社区怎么合并模型。Labonne 同时发布了 Marcoro14-7B-slerp，成为最早在 Leaderboard 上引发关注的合并模型。

2024 年 3 月是转折月。 3 月 19 日，Arcee AI 收购 mergekit，Charles Goddard 加入 Arcee。同日，MergeKit 论文和 Sakana AI 的 Evolutionary Model Merging 论文同时上线 arxiv。这标志着模型合并从"社区炼丹"正式进入"有论文

支撑的学术范式"。

Evolutionary Merging 的发现尤其惊人：用进化算法自动搜索最优合并配方，在多个 benchmark 上超越了人类手工调参的最好结果。这意味着——**连"怎么合最好"这件事，AI 也能比人做得好。**

3.4 学术化与主流化（2024.08 – 2026）

2024 年 8 月首个全面综述论文出现，整理了近 100 种合并方法。NeurIPS 2024 正式设立 LLM Merging Competition。2025 年安全合并、多模态合并、遗忘合并等新方向爆发。Sakana AI 的 M2N2（2025.08）引入"竞争与吸引"机制。2026 年 ICLR 收录多个合并论文。

3.5 阶段总结

阶段	时间	核心特征	标志事件
学术前史	2021–2023.06	视觉模型探索，LLM社区不知	Model Soups, TIES–Merging
社区爆发	2023.09–12	偶然发现，全民炼丹	Goliath–120B, DARE论文
工具化	2024.01–03	mergekit统一，学术化转折	Labonne博客, Arcee收购, 进化合并
主流化	2024.08–2026	综述、竞赛、多模态	NeurIPS竞赛, M2N2, 安全合并

四、横向分析：合并方法对比

4.1 总览表

方法	提出	核心思路	需要数据?	计算开销	合并质量	工具
Linear Soup	2023.Q3	权重直接平均	否	极低	中	MergeKit
SLERP	2023.Q4	球面大圆弧插值	否	低	中–高	MergeKit
Task Arithmetic	2022.12	任务向量加减	否	低	中	MergeKit
TIES	2023.06	Trim→Elect→Disjoint	否	中	高	MergeKit
DARE	2023.11	随机丢弃90%+delta, rescale	否	低–中	高	MergeKit
DARE–TIES	2024.Q1	DARE稀疏化后再TIES	否	中	**极高**	MergeKit
Model Stock	2024.03	几何投影法,2模型逼N模型	否	中	高	MergeKit
Evolutionary	2024.03	进化算法自动搜索配方	是(评估数据)	极高	**最高**	Sakana
Frankenstein	2023.11	按层拼装不同模型	否	极低	极不稳定	MergeKit

4.2 关键发现

DARE-TIES 是社区最常用的生产级配方。 DARE 先稀疏化消除 delta 冗余，TIES 再消解符号冲突。HuggingFace Leaderboard 上绝大多数高分合并模型都采用这一组合。

Evolutionary Merging 是质量上限最高的方法，但计算开销让大多数人望而却步。 需要多轮进化评估。

合并的质量高度依赖"选对源模型"。 方法差异的影响远小于源模型质量差异。社区经验的共识："garbage in, garbage out."

4.3 著名合并模型

模型	时间	方法	意义
Goliath-120B	2023.11	Frankenstein	第一个轰动社区，120B
Marcoro14-7B-slerp	2024.01	SLERP	第一个 Leaderboard 热门
Beyonder-4x7B-v2	2024.Q1	frankenMoE	4个7B拼成MoE
Daredevil-8B	2024	DARE-TIES	Llama 3 多微调版合并
Qwopus-GLM-18B	2026.04	Frankenstein	跨家族三合一，能力惊人

五、横纵交汇洞察

5.1 "为什么它不应该能工作，却偏偏能？"

回看整个纵向线，最诡异的地方在于：2023 年底社区狂热地合并模型时，没有一篇论文能解释为什么这能工作。学术界的 TIES-Merging 已经提出了参数冲突理论，但社区根本不知道这篇论文——他们纯粹是自己试出来"这样能行"的。

DARE 论文 2023 年 11 月才上线。社区在那之前几个月已经在大规模合并了。换句话说：**社区用"先干了再说"的方式，验证了后来论文才会解释的现象。**

5.2 合并正在从"技术"变成"产品"

Arcee AI 收购 mergekit，把模型合并嵌入企业产品线。Sakana AI 把进化合并发在 Nature Machine Intelligence。HuggingFace 上每天都有新的合并模型产生。模型合并正在从一种"开源社区的奇怪行为"变成"AI 工具链的标准一环"。

5.3 三个剧本

剧本一（55%）：合并成为微调后的标准后处理。微调完自动做 DARE-TIES 合并来组合能力，工具链全自动化。

剧本二（30%）：跨家族合并突破。目前所有方法都要求同基座。如果有方法能可靠地跨家族合并（Llama + Mistral + DeepSeek），格局会彻底改变。

剧本三（15%）：合并被下一代微调方法取代。如果 LoRA 的进化版天生支持多任务动态组合，就不需要合并了。

六、信息来源

论文/来源	URL	发表时间
TIES-Merging (NeurIPS 2023)	arxiv.org/abs/2306.01708	2023.06
DARE / Super Mario (ICML 2024)	arxiv.org/abs/2311.03099	2023.11
Model Soups (ICML 2022)	arxiv.org/abs/2203.05482	2022.03
Task Arithmetic (ICLR 2023)	arxiv.org/abs/2212.04089	2022.12
Model Stock (ECCV 2024)	arxiv.org/abs/2403.19522	2024.03
Evolutionary Model Merging	arxiv.org/abs/2403.13187	2024.03
MergeKit paper	arxiv.org/abs/2403.13257	2024.03
Model Merging Survey	arxiv.org/abs/2408.07666	2024.08
MergeKit GitHub	github.com/arcee-ai/mergekit	2023.12
Maxime Labonne blog	mlabonne.github.io	2024.01
Sakana AI evolutionary-model-merge	github.com/SakanaAI/evolutionary-model-merge	2024.03

本文是横纵分析系列的第 39 篇报告。