RoPE 旋转位置编码 横纵分析报告

> 一个没有 PhD 的中国独立研究者，一篇发布在个人博客上的文章，一个业余时间推导的数学公式——然后被 Meta 的 LLaMA 团队注意到，成为 GPT-NeoX、Falcon、Mistral、Qwen、DeepSeek、Gemma 几乎所有现代 LLM 的标配。RoPE 可能是 AI 时代"好想法来自任何地方"最有力的证明。

一、一句话定义

RoPE（Rotary Position Embedding，旋转位置编码）是苏剑林 2021 年提出的一种位置编码方法——将 Q、K 向量的维度对在复数空间旋转与位置成正比的角，使 Attention 内积自然只依赖相对距离。它形式上像绝对位置编码一样方便（直接作用在向量上），数学上等价于相对位置编码（内积只依赖位置差）。到 2026 年，几乎所有主流 LLM 都使用 RoPE 或其变体。

> 🎯 **读完这篇你能**：理解 RoPE 为什么"一个人一篇博客就能穿透行业"，能画出位置编码的完整族谱，能说出 PI/NTK/YaRN/LongRoPE 各自解决了什么问题，能判断下一个位置编码的方向。

阅读指南

5 分钟：一句话定义 + 阶段 3.3（LLaMA 转折点）+ 横纵交汇（三个剧本）

25 分钟：加技术背景 + 纵向各阶段开头 + 横向对比表

专业：全文

二、技术背景

> 前置知识请参考 《RoPE 前置知识》

位置编码的核心矛盾：**绝对位置编码方便但无法外推，相对位置编码可外推但实现复杂。** RoPE 的优雅在于用一个旋转操作同时实现了两者的优势。

RoPE 的数学关键：高维空间的旋转可以分解为多个独立的 2D 平面旋转。Q 和 K 向量的每两个连续维度看作一个 2D 向量，按频率 $\theta_d = \text{base}^{(-2d/D)}$ 旋转。不同频率分量捕获不同尺度的位置依赖——高频（旋转快）捕获近距离，低频（旋转慢）捕获远距离。旋转后的 Q、K 内积只依赖位置差 $(m-n)$，形成自然的相对位置编码。

📚 **关联报告**

- LLM 大模型 — RoPE 是现代 LLM 架构的标准组件

- Transformer — RoPE 是对 Transformer 原始位置编码的改进

- 长上下文技术 — PI/NTK/YaRN 是长上下文扩展的核心技术

三、纵向分析：一个人，一篇博客，一个行业标准

3.1 前史（2017–2020）三种方案各有短板

- **Sinusoidal PE**（Vaswani et al., 2017）：固定正弦/余弦。理论上可外推，实践中差
- **Learned PE**（BERT/GPT, 2018）：可学习但长度固定
- **Relative PE**（Shaw et al., 2018; T5, 2019）：可外推但计算复杂

三角矛盾持续到 2021 年。

3.2 苏剑林与 RoPE（2021.04）

苏剑林追一科技的 NLP 研究员，个人博客"科学空间"已写了十年。从复数乘法和 2D 旋转矩阵出发，推导出了一个同时满足"绝对形式的便利 + 相对形式的自然外推"的位置编码方案。

2021 年 4 月，他把推导过程发表在博客上，同时上传 arxiv 论文 "RoFormer: Enhanced Transformer with Rotary Position Embedding" (2104.09864)。论文里的模型只有几亿参数——他没有大 GPU 集群。但这不影响想法的质量。

6 月 HuggingFace 合并了 RoFormer，7 月 EleutherAI 发表介绍博文 "Rotary Embeddings: A Relative Revolution"，8 月 GPT-NeoX-20B 成为第一个大规模采用 RoPE 的模型。

同月，Press et al. 发表了 ALiBi。ALiBi 更简单——一行代码，零参数，天然外推。2022 年 BLOOM-176B 用了 ALiBi。此时 RoPE 和 ALiBi 的竞争还不明朗。

3.3 LLaMA 的选择（2023.02）——转折点

Meta 在设计 LLaMA 时对比了多种 PE 方案，选了 RoPE。

LLaMA 的成功让 RoPE 产生了不可逆的网络效应。所有基于 LLaMA 微调和衍生的模型自动继承 RoPE。FlashAttention、vLLM、llama.cpp 对 RoPE 做了极致优化——用 RoPE 意味着免费获得这些优化。

ALiBi 最大的背书 BLOOM 性能远不如同期模型。ALiBi 在之后的新模型设计中几乎绝迹。

3.4 扩展方案爆发（2023.06–2025）

原版 RoPE 在训练长度外推理退化严重。一系列扩展方案密集出现：

- **PI**（Meta, 2023.06）：等比例缩小所有旋转角
- **NTK-aware**（社区, 2023.07）：高频少缩、低频多缩，社区驱动的天才优化
- **Dynamic NTK**（社区, 2023.07）：根据当前长度动态调整
- **YaRN**（2023.09, ICLR 2024）：PI + NTK + 温度调优，当前主流
- **LongRoPE2**（微软, 2025.02, ICML 2025）：进化搜索最优频率，近乎无损 128K+

这些方案最有趣的特点是——NTK-aware 和 Dynamic NTK 完全来自社区（Reddit 帖子、llama.cpp 讨论），没有论文。

3.5 未来可能：NoPE 与混合方案

2024 年 NoPE（无位置编码）论文发现 Causal Attention 本身就包含隐式位置信息。2025 年 NeurIPS 提出 RoPE/NoPE 混合——浅层用 NoPE 捕获长程依赖，深层用 RoPE 精细区分位置。2025 年 Transformer 原作者团队尝试完全丢弃位置编码预训练。RoPE 可能不是位置编码的终点。

四、横向分析

4.1 位置编码完整谱系

方法	时间	类型	有参数?	外推	代表模型	现状
Sinusoidal	2017	绝对	否	有限	Transformer	历史
Learned	2018	绝对	是	无	BERT, GPT	GPT 系列仍用
Relative (Shaw/T5)	2018–19	相对	是	有限	T5	编码器模型
ALiBi	2021.08	相对	否	**优秀**	BLOOM, MPT	基本被淘汰
RoPE	2021.04	绝对+相对	否	中→强(带扩展)	**几乎所有现代LLM**	**事实标准**
NoPE	2024	无	否	有限	实验性	前沿探索

4.2 RoPE 扩展方案对比

方案	时间	扩展倍数	需微调?	当前地位
PI	2023.06	2–4x	推荐	基础方案
NTK-aware	2023.07	2–4x	否(零样本)	社区首选

Dynamic NTK	2023.07	4–8x	否	Qwen/DeepSeek 采用
YaRN	2023.09	8–16x	推荐(少量)	**当前主流**
LongRoPE2	2025.02	32–128x	需微调	学术前沿

4.3 谁用 RoPE？（2026 年 5 月）

用：LLaMA 1/2/3/4, Mistral 全系, Qwen 全系, DeepSeek 全系, Gemma, Falcon, Yi, GPT–NeoX, Grok–1, Claude

不用：GPT–3/4（Learned PE）, BLOOM/MPT（ALiBi）, T5（Relative Bias）, RWKV（非 Transformer）

2023 年之后训练的大模型几乎全部 RoPE。

五、横纵交汇洞察

5.1 一个人的论文，一条不可逆的网络效应

RoPE 的成功路径：个人博客 → arxiv → EleutherAI 背书 → GPT–NeoX 采用 → LLaMA 采用 → **临界点**。每一步升级都是社区"主动选择"的——苏剑林自己没有去游说 Meta。用他的话说："RoPE 被大规模采用，主要是 LLaMA 的功劳。"

这反过来也说明：在 2023 年后的 LLM 生态里，**位置编码的选择已经不是一个独立的技术决策，而是生态绑定**——选 RoPE 意味着所有推理框架零成本支持；选别的就得自己写 kernel。

5.2 ALiBi 的反面教材

ALiBi 的问题是：它确实简单，但过于简单了。一个自由度的固定线性惩罚，表达力上限太低。BLOOM 选 ALiBi 是 2022 年的合理判断（当时 RoPE 只在小模型验证过），但 BLOOM 自己没成功，ALiBi 失去了最有力的背书。到 2024 年 RoPE + YaRN 能把上下文扩到 128K 且质量几乎不损失时，ALiBi 的"免费外推"优势也不复存在。

5.3 三个剧本

剧本一（60%）：RoPE + YaRN/LongRoPE2 继续统治。生态惯性太大。

剧本二（25%）：RoPE + NoPE 混合成为新标准。NeurIPS 2025 方向进一步验证。

剧本三（15%）：新架构（SSM/线性注意力）不需要位置编码——因为本身状态空间就包含了位置。

六、信息来源

来源	URL	访问时间

苏剑林博客：旋转式位置编码	spaces.ac.cn/archives/8265	2026-05-03
RoFormer 论文	arxiv.org/abs/2104.09864	2026-05-03
EleutherAI: Rotary Embeddings	blog.eleuther.ai	2026-05-03
ALiBi 论文	arxiv.org/abs/2108.12409	2026-05-03
LLaMA 论文	arxiv.org/abs/2302.13971	2026-05-03
PI 论文	arxiv.org/abs/2306.15595	2026-05-03
YaRN 论文	arxiv.org/abs/2309.00071	2026-05-03
LongRoPE2 论文	arxiv.org/abs/2502.20082	2026-05-03
NoPE 论文	arxiv.org/abs/2404.12224	2026-05-03
Rope to Nope and Back (NeurIPS 2025)	arxiv.org/abs/2501.18795	2026-05-03

本文是横纵分析系列的第 40 篇报告。