大模型 AI 芯片格局前置知识

> 写给完全零基础的读者——读完这篇，你就能看懂横纵分析报告的主体内容。

> 🎯 **读完这篇你能**：说清 GPU 和 TPU 的核心区别，理解训练芯片 vs 推理芯片的不同设计取舍，记住 TFLOPS / HBM 带宽 / 互联带宽三个关键指标，并列出当前 AI 芯片市场的主要玩家（NVIDIA、AMD、Google、华为等）及其竞争关系。

---

1. GPU 和 CPU 有什么区别?

CPU（中央处理器） 就像一个大厨——他什么菜都会做，但一次只能做几道菜，做的过程很精细。

GPU（图形处理器） 就像一千个帮厨——每个人只会做切菜这一件事，但一千个人同时切，速度比大厨一个人快得多。

AI 训练的核心是"做几万次简单的数学运算（矩阵乘法）"，所以 GPU 比 CPU 快 100–1000 倍（社区估算）。

矩阵乘法（Matrix Multiplication）是什么?

AI 芯片的所有讨论都离不开这四个字。神经网络的每一层本质上就是一次矩阵乘法。

矩阵是什么? 想象一个 Excel 表格——行和列组成的数字网格。3 行 4 列的数字就是一个 3×4 矩阵。

矩阵乘法是什么? 把两个"数字表格"按规则相乘，得到一个新表格。位置 (i,j) 的值 = 第一个矩阵第 i 行逐个数 × 第二个矩阵第 j 列逐个数，再全部加起来。

为什么它是 AI 的核心? 神经网络的一层就是：输入数据（矩阵A）× 权重（矩阵B）= 输出（矩阵C）。堆 100 层就是做 100 次矩阵乘法。大模型的本质就是海量矩阵乘法。

为什么 GPU 擅长这个? 矩阵乘法里几十万个乘法互不依赖——可以全部同时算。GPU 有几千个小核心专干这个，CPU 只有几个大核心。就像一千个人同时算小九九，比一个人挨个算快几百倍。

一句话：AI 训练/推理 90%+ 的计算量都是同一种运算——**GEMM（通用矩阵乘法，General Matrix Multiply）**（社区估算）。芯片厂商拼的核心指标，就是一次能做多快、做多少个 GEMM。

训练（Training）和推理（Inference）有什么区别?

训练 = 做练习题。模型看一道题，算答案，然后对答案——错的地方回头改（这个过程叫反向传播）。训练要记住中间每一步的计算结果（梯度），极其消耗算力和内存。

推理 = 考试。模型只往前算，不看答案，不需要回头改。计算量和内存需求远小于训练。

两种场景对硬件要求完全不同：

- **训练芯片**要同时存模型参数、梯度、优化器状态。训练一个 70B 参数的模型需要几百 GB 显存。代表：H100、B200、TPU v8t。
- **推理芯片**重在便宜、省电。可以只用几个 GB 显存跑小模型。代表：L40S、TPU v8i。

2. TPU 又是什么？和 GPU 有什么区别？

TPU（Tensor Processing Unit，张量处理单元）是 Google 专门为 AI 计算设计的芯片（Jouppi et al., 2017）。

如果 GPU 是一千个帮厨（能做各种简单任务），TPU 就是一千个只切土豆丝的帮厨——做的事情更少，但切得更快、功耗更低。

所以 TPU 在 AI 推理场景下比 GPU 更省电、更便宜。但它的缺点是"只擅长 AI 计算"——干不了渲染、科学计算等其他活。

3. TFLOPS 是什么？

TFLOPS（Tera FLOPs，万亿次浮点运算/秒）是衡量芯片算力的单位。1 TFLOPS 就是一秒钟运算一万亿次。

补充：浮点数（Floating Point）是什么？ "浮点" = 小数点可以"浮动"，能表示很大和很小的数。类比科学计数法：3.0×10^8（简洁），而不是 300000000（冗长）。FP32 用 32 个二进制位记一个数，FP16 用 16 位，FP8 用 8 位，FP4 用 4 位。位数越少 = 记得越模糊（四舍五入误差越大），但算得越快、功耗越低。大模型推理时 FP8/FP4 精度已经足够，就像用 π=3.14 算圆面积对绝大多数场景绰绰有余。

但注意：**数字大不一定代表更好。** 因为不同精度下测出来的 TFLOPS 完全不同：

- FP32（32位浮点）：精度最高，但算力最低
- FP16/BF16（Float Point 16-bit/Brain Float 16，16位浮点）：精度适中，算力提高约 2 倍
- FP8（8位）：精度较低，算力再高约 2 倍
- FP4（4位）：精度最低，算力再高约 2 倍

所以一个标称 1000 TFLOPS (FP16) 的芯片，在 FP32 精度下可能只有 125 TFLOPS。厂商通常报自己最强的那个数字。

4. Tensor Core 是用来做什么的？

Tensor Core 是 NVIDIA 2017 年在 GPU 里加入的专门硬件单元，用来加速深度学习中最频繁的计算——**矩阵乘法**。

普通 CUDA（Compute Unified Device Architecture） Core 一次算 1 个乘加运算，Tensor Core 一次算 16 个（4x4 矩阵乘法）。效率差了 16 倍（社区估算）。

这个区别可以用一个比喻理解：

- **CUDA Core** = 一个人用手算加减乘除
- **Tensor Core** = 一台小计算器，按一下就算出一整张表

5. HBM（High Bandwidth Memory，高带宽内存）是什么？

HBM（High Bandwidth Memory，高带宽内存）是 AI 芯片使用的一种特殊内存，堆叠在芯片旁边，通过微小通道高速传输数据。

想象一下：你有一个超快的计算器（GPU），但它要从一个超慢的文件柜（普通内存）里找数据——算得再快也没用，因为大部分时间在等数据送来。

HBM 就是把文件柜搬到计算器旁边，用几十条高速公路连起来。数据送达速度从"骑自行车"变成了"坐高铁"。

HBM 的规格（HBM2、HBM3、HBM3e）也决定了带宽——HBM3e 比 HBM3 快约 40%（社区估算）。

6. NVLink 和互联技术

当你用几千块 GPU 一起训练一个模型时，它们需要频繁地相互通信。"每块 GPU 的计算速度"不是瓶颈，"GPU 之间的通信速度"才是。

NVLink 是 NVIDIA 的私有互联技术，专门解决这个问题：

- H100 的 NVLink 4：900 GB/s（NVIDIA, 2022）
- B200 的 NVLink 5：1.8 TB/s（NVIDIA, 2024）

这个速度的意义：PCIe 4.0 x16 的带宽只有 32 GB/s（社区估算）。NVLink 比它快 30–60 倍。

7. 什么是 CUDA？为什么它这么重要？

CUDA 是 NVIDIA 在 2007 年推出的 GPU 编程平台，让开发者可以用代码控制 GPU 做通用计算（不只是渲染画面）。

CUDA 的重要性不在于技术，而在于**生态**。经过近 20 年积累：

- 400 万 + 开发者用 CUDA 写过代码（社区估算）
- 所有 AI 框架（PyTorch、TensorFlow、JAX）底层都调 CUDA
- 大量优化库（cuDNN、cuBLAS、TensorRT）只有 CUDA 版本

cuDNN（Chetlur et al., 2014）是其中最关键的库——专为深度学习优化的 GPU 加速库。所有主流框架的 GPU 加速层都基于 cuDNN 构建。它的战略意义在于：开发者写的 PyTorch 代码底层全是 cuDNN 调用，换成 AMD 的 ROCm 就得重新适配。

这就导致了"CUDA lock-in"——你想换 AMD 的 ROCm，但你的代码库里全是 CUDA 调用，迁移成本极高。行业里有一句话："CUDA is not just a moat, it's an ocean."

7.5 MIG（多实例 GPU）

MIG（Multi-Instance GPU）是 NVIDIA 从 A100 开始引入的技术，把一块物理 GPU 切分成最多 7 个独立实例（社区估算）。每个实例拥有独立的内存和计算资源，互不干扰。

意义：云厂商可以像卖虚拟机一样卖 GPU 切片。你不需要租一整块 H100（每月数千美元），可以只租 1/7 块做小模型推理。这大大降低了 GPU 云服务的使用门槛。

8. 什么是 Chiplet?

传统芯片是把所有功能做在一大块硅片上（monolithic die）。Chiplet 是把芯片拆成几个小块，用高速互联组装起来。

好处：

- 每小块良品率更高（大芯片面积越大、良品率越低）
- 不同小块可以用不同制程（计算部分用 3nm，I/O 部分用 7nm 更省钱）
- 设计复用（可以换不同小块来组合出新芯片）

B200 就是双 chiplet 设计（两个计算 die 通过 NV-HBI 互联，带宽 10 TB/s，NVIDIA, 2024）。

9. ASIC 是什么?

ASIC（Application-Specific Integrated Circuit，专用集成电路）是"为特定任务设计的芯片"。

把市面上所有芯片放一个谱系上：

- **CPU**（最通用，什么都能做，但效率最低）
- **GPU**（通用性中，图形+计算两用，效率中等）
- **ASIC**（最专用，只能做一件事，但效率最高）

TPU 就是 ASIC。它的优势是推理时效率极高（Midjourney 切到 TPU 后成本降低了 65%，社区估算），劣势是"不能做别的"。

10. 出口管制如何影响 AI 芯片?

2022 年 10 月起，美国禁止向中国出口高端 AI 芯片（A100/H100）。这带来了几个连锁反应：

- **NVIDIA 推出降级版**：H800（降互联带宽）→ H20（大幅降级）→ 最终也被禁
- **中国被迫自己造**：华为昇腾 910B 成为替代方案，但性能差距明显
- **"两个生态"正在形成**：西方用 NVIDIA/AMD/TPU，中国用昇腾等国产芯片

11. 关键术语速查

术语	一句话解释
TFLOPS	芯片每秒能算多少万亿次浮点运算
HBM	高带宽内存，AI 芯片的"数据高速公路"
NVLink	NVIDIA 的 GPU 高速互联技术
Tensor Core	GPU 里的专用矩阵乘法加速器
CUDA	NVIDIA 的 GPU 编程平台（行业标准）
ROCm	AMD 的 CUDA 替代方案（开源）
Chiplet	用小芯片组装大芯片的设计方法
ASIC	专为特定任务设计的芯片
CoWoS	台积电的先进封装技术，用于整合 chiplet
InfiniBand	超算和 AI 集群用的高性能网络，万卡 GPU 集群的通信基石（Mellanox 公司）
cuDNN	NVIDIA 专为深度学习优化的 GPU 加速库，所有 AI 框架的基础
MIG	多实例 GPU，一块物理 GPU 切成多个独立小 GPU
TDP	芯片最大功耗（瓦特），决定散热需求
Die	芯片的最小物理单元（从晶圆上切下来的一小块）

NVIDIA 芯片进化简史

NVIDIA 保持每年一代的迭代节奏：

架构	年份	代表 GPU	关键突破
Volta	2017	V100	首个 Tensor Core
Ampere	2020	A100	MIG 多实例、FP16
Hopper	2022	H100	Transformer Engine、FP8（NVIDIA, 2022）
Blackwell	2024	B200	双 die 封装、FP4、NVLink 5（1.8 TB/s）（NVIDIA, 2024）
Rubin	2026	VR200	首款 HBM4 GPU（288GB）、50 PFLOPs 算力（社区估算）
Feynman	2028	—	HBM5、首次堆叠逻辑晶圆（社区估算）

Triton

OpenAI 开源的 GPU 编程语言（Python-level）。写一次 Triton kernel 就能在 NVIDIA/AMD/Intel 上跑——不需要学 CUDA。Triton + MLIR + JAX 正在逐步降低 CUDA 的锁定效应，被视作"打破 NVIDIA 垄断"的三驾马车之一。

本文是 AI 芯片格局系列的前置知识篇，读完它再阅读主报告。

参考来源

- **In-Datacenter Performance Analysis of a Tensor Processing Unit** (Jouppi et al., 2017) — Google TPU v1 架构首次公开，奠定了专用 AI 推理芯片的设计范式 — https://arxiv.org/abs/1704.04760
- **cuDNN: Efficient Primitives for Deep Learning** (Chetlur et al., 2014) — NVIDIA 专为深度学习优化的 GPU 加速库，所有主流 AI 框架的底层基础 — https://arxiv.org/abs/1410.0759
- **NVIDIA H100 Tensor Core GPU Architecture Whitepaper** (NVIDIA, 2022) — Hopper 架构官方白皮书，详述 Transformer Engine、FP8、NVLink 4 等关键特性 — https://resources.nvidia.com/en-us-tensor-core/gtc22-whitepaper-hopper
- **NVIDIA Blackwell Architecture Technical Overview** (NVIDIA, 2024) — Blackwell/B200 双 die 封装、FP4、NVLink 5（1.8 TB/s）官方技术文档 — https://resources.nvidia.com/en-us-blackwell-architecture
- **AMD ROCm Open Software Platform** (AMD) — AMD 开源 GPU 计算平台，CUDA 的主要替代方案，支持 PyTorch/TensorFlow — https://www.amd.com/en/products/software/rocm.html