AI 芯片格局：大模型算力的"军火商"之战

> **副标题：从 CUDA 到万卡集群，谁在决定 AI 的算力天花板？**

一、一句话定义

AI 芯片是专门为深度学习训练和推理设计的加速器——GPU、TPU、NPU 的总称。2026 年，全球 AI 芯片市场规模突破 1500 亿美元，NVIDIA 以约 80% 的份额统治这个赛道，但 AMD、Google TPU、华为昇腾正在从不同方向发起挑战。

> 🎯 **读完这篇你能**：理解算力、内存带宽、互联带宽三个核心指标如何构成 AI 芯片的不可能三角，能分析 NVIDIA 的护城河到底在哪里以及谁能真正挑战它。

二、技术背景

AI 芯片和普通 CPU 的区别用一句话就能说清：**CPU 是"通才"——什么都能做，但一次只能做几件事；AI 芯片是"专才"——只会做矩阵乘法，但一次能做几万件事。**

深度学习的核心计算是矩阵乘法（更具体地说，是 General Matrix Multiply, GEMM）。一个 7B 参数的模型，每一次前向传播需要执行数十亿次矩阵乘法。如果让 CPU 来做，速度会慢 100–1000 倍。

三个决定芯片性能的核心指标

1. **算力（Compute）**：单位时间内能执行多少次计算，以 TFLOPS（万亿次浮点运算/秒）衡量。注意精度不同数值天差地别——FP32 和 FP4 的峰值算力可以差 4–8 倍。
2. **内存带宽（Memory Bandwidth）**：芯片读/写内存的速度，以 GB/s 衡量。大模型推理时，瓶颈往往不是算力，而是"把参数从内存搬到计算单元"的速度。
3. **互联（Interconnect）**：多卡集群时芯片之间的通信速度，以 GB/s 衡量。万卡集群的扩展效率，90% 取决于互联技术。

这三个指标构成了 AI 芯片的"不可能三角"——追求任意一个指标都会牺牲另一个。NVIDIA 的厉害之处在于，它在三个指标上都做到了行业领先。

Tensor Core 是什么？

2017 年 Volta 架构引入的专门硬件单元，一次可以执行 4x4 矩阵乘法——相比普通 CUDA Core 的单个乘加操作，效率提升 8–16 倍。到 2026 年的 Blackwell，Tensor Core 已进化到第 5 代，支持 FP4/FP6/FP8/BF16 多种精度。

为什么精度越来越低?

FP32（32 位浮点）→ FP16（16 位）→ FP8（8 位）→ FP4（4 位）。规律很明显：**精度越低，计算越快，显存占用越少。** 关键是训练和推理算法的进步让低精度计算也能保持足够准确度。NVFP4 的 4–bit 训练可以匹配 16–bit 训练的准确度——这在 2022 年还是不可能的事。

> 📚 **关联报告**

> – Transformer — 理解芯片为什么专注矩阵乘法：Attention 和 FFN 的计算本质

> – 大模型训练 — 万卡集群如何把芯片的算力"组装"起来

> – 模型压缩 — 量化/蒸馏如何降低对高端芯片的依赖

> – 大模型推理部署 — 推理芯片需求与训练截然不同

> – 前置知识 — 理解 GPU/CPU 区别、矩阵乘法和三个核心指标的基础概念

三、纵向分析：十八年，从图形渲染到 AI 引擎

3.1 史前时期（2006–2011）：CUDA 的诞生

2006 年的 GPU 还只干一件事：给显示器渲染画面。NVIDIA 那年的 GeForce 8800 GTX（代号 G80）发布时，谁也没想到它会在十年后成为 AI 革命的引擎。

关键人物：Ian Buck。 这位斯坦福博士生在 2004 年之前做了 Brook 项目——一种让 GPU 做通用计算的编程语言。NVIDIA 创始人黄仁勋看到了这个项目的潜力，把 Ian Buck 招入公司。他和 John Nickolls 一起，在 G80 硬件上构建了 CUDA（Compute Unified Device Architecture），2007 年 2 月正式发布第一个 SDK。

这个决策在当时极其冒险。CUDA 的开发耗费了 NVIDIA 数亿美元，而最初的几年几乎没有应用场景——开发者习惯了 CPU 编程，GPU 编程的学习曲线陡峭，市场反应冷淡。NVIDIA 内部也有质疑声：为什么要花这么多资源做一个看起来没有市场的东西?

黄仁勋后来的解释很简单：**"我们赌的是计算终将需要并行化。"**

3.2 引爆点（2012）：AlexNet 改变一切

2012 年，多伦多大学的 Alex Krizhevsky 用两块 NVIDIA GTX 580（Fermi 架构，512 CUDA 核心）训练了 AlexNet，在 ImageNet 竞赛中将图像识别错误率从 26% 降到 15%，大幅领先第二名。

这个实验结果的意义远超计算机视觉领域——它证明了 GPU 大规模并行计算能力对深度学习的巨大价值。在此之前，AI 研究者主要用 CPU 训练模型，一个模型跑几天是家常便饭。GPU 把这个时间缩短到了几小时。

但 AlexNet 的意义不止于此。它开启了一个正反馈循环：**AI 越热 → GPU 卖得越多 → NVIDIA 收入越高 → 研发投入越大 → GPU 越适合 AI。** 这个循环到今天仍在运转。

3.3 生态奠基（2014–2016）：cuDNN + TPU 的出现

2014 年，NVIDIA 发布了 cuDNN——专门为深度学习优化的 GPU 加速库。cuDNN 提供了高度优化的卷积、池化、归一化等操作原语。所有主流深度学习框架（Caffe、TensorFlow、PyTorch）都基于 cuDNN 构建 GPU 加速层。

cuDNN 的战略意义后来才被看清：**它不是让开发者选择 NVIDIA，而是让开发者无法选择别的芯片。** 写了三年的 PyTorch 代码，底层全是 cuDNN 调用——换成 AMD 的 ROCm 就得重新适配，性能还不能保证。

2016 年对 NVIDIA 来说是另一个里程碑：Pascal 架构的 P100 是首个使用 HBM2 内存的数据中心 GPU，NVLink 1.0 提供了 160 GB/s 的 GPU 互联带宽。这两个特性让多卡训练成为可能——HBM 解决了"内存墙"，NVLink 解决了"通信墙"。

同年 5 月，Google 在 I/O 大会上公开了 TPU v1——一个纯推理 ASIC，运行 Google 搜索的 RankBrain、照片分类和 AlphaGo。这个芯片不卖，只在 Google 内部使用，也没有引起 NVIDIA 的警惕。事后看，这是"专用路线 vs 通用路线"的第一次公开对阵。

3.4 黄金时代（2017–2020）：Transformer + Tensor Core + Mellanox

2017 年发生了两件改变 AI 芯片格局的事。

第一件：Google 发表 "Attention Is All You Need"。 Transformer 架构对计算的需求和之前的 CNN/RNN 完全不同——它的自注意力机制需要大量并行矩阵乘法，对算力和内存带宽的需求远高于之前的模型架构。Transformer 的兴起直接拉动了 GPU 需求。

第二件：NVIDIA 发布 Volta V100，内置 640 个 Tensor Core。 这是芯片历史上第一次出现专门为 AI 设计的计算单元。Tensor Core 一次执行 4x4 矩阵乘法，效率是普通 CUDA Core 的 8 倍。V100 成为 2017–2020 年训练 AI 模型的标配硬件。

2019 年 3 月，NVIDIA 以 69 亿美元收购 Mellanox——一家以色列网络设备公司。这笔收购当时让很多人看不懂：一个 GPU 公司买网络公司干什么？

后来的故事回答了这个问题。Mellanox 的 InfiniBand 技术成为构建万卡 GPU 集群的网络基石。当 OpenAI 训练 GPT-3 时，10000 块 GPU 之间的通信瓶颈——通过 Mellanox 的 InfiniBand 交换机解决。**今天 NVIDIA 的垄断，不只是 GPU 的垄断，更是"GPU + 网络 + 软件"全栈的垄断。** 而 Mellanox 是这个拼图里缺失的那一块。

2020 年 5 月，Ampere A100 发布。MIG（多实例 GPU）技术让一块 GPU 可以被切分为最多 7 个独立实例，分别服务不同用户。这直接降低了 GPU 云服务的成本——云厂商可以像卖虚拟机一样卖 GPU 切片。

3.5 供不应求（2022–2023）：H100 和 ChatGPT 的时代

2022 年 3 月，Hopper H100 发布。Transformer Engine 支持 FP8 精度训练，NVLink 4.0 带宽提升到 900 GB/s，HBM3 内存带宽 3.35 TB/s。H100 是所有指标的"天花板"。

但真正让 H100 封神的是 2022 年 11 月发布的 ChatGPT。ChatGPT 引爆的生成式 AI 浪潮，让 GPU 需求在几个月内暴增。

2023 年的 GPU 市场处于一种前所未有状态：**H100 单价 25,000–30,000 美元，eBay 上炒到 40,000+，仍然一卡难求。** 创业公司买不到 GPU，云厂商要等 6–12 个月的交付期。NVIDIA 的市值从 2023 年初的 3600 亿飙升至 2024 年中的 3.3 万亿美元——超越 Microsoft 和 Apple，成为全球市值最高的公司。

这段时间，AMD 也没闲着。MI300X 在 2023 年 12 月发布，192GB HBM3 显存容量超过了 H100 的 80GB，FP16 算力 1.3 PFLOPS 也超过了 H100 的 990 TFLOPS。但 AMD 的软件生态 ROCm 远不如 CUDA 成熟——开发者可以在 H100 上"开箱即用"，在 MI300X 上却要花几周适配。

3.6 地缘政治重塑格局（2022–2026）：出口管制改变了一切

2022 年 10 月，美国商务部工业安全局（BIS）发布了对华 AI 芯片出口管制——禁止向中国出口 A100/H100。这是 AI 芯片格局的第一个"地震"。

NVIDIA 的应对很"灵活"：快速开发了降级版 A800/H800，将互联带宽砍掉一截以符合管制阈值。但 2023 年 10 月，新规进一步收紧，连 A800/H800 也被禁。NVIDIA 再推出 H20——性能大幅降级，互联带宽腰斩。

到 2026 年初，出口管制已进入博弈新阶段：特朗普政府实施了"逐案审查"机制，H200 获得出口许可后被中国海关阻止入境。中国则限制镓/锗出口作为反制。

这场管制的一个关键影响是：**它意外催生了中国国产 AI 芯片的"被迫崛起"。** 华为昇腾 910B 成为替代 A100 的主要选项，2026 年初 DeepSeek 被报转向华为昇腾。中国国产 AI 芯片市场份额预计到 2026 年底达到 50%。

3.7 白热化（2024–2026）：Blackwell、Rubin、TPU v8

2024–2026 年是 AI 芯片竞争最激烈的三年。

NVIDIA Blackwell 到 Rubin 的加速迭代。 2024 年 3 月发布的 B200 是双 die 封装（2080 亿晶体管），NV-HBI 10 TB/s，FP4 9 PFLOPS，NVLink 5.0 1.8 TB/s。Blackwell 初期遭遇 CoWoS-L 封装缺陷和液冷系统泄漏导致出货推迟，但到 2025 年已全面上量，TrendForce 预计 2026 年 Blackwell 占 NVIDIA 高端 GPU 出货超 71%。Blackwell Ultra 在 GTC 2025 公布，配备 GB300/GB300 NVL72 机架方案。

Rubin 的节奏比预期快得多。 2025 年 9 月 NVIDIA 已向客户发送 Rubin VR200 首批样品；CES 2026 黄仁勋正式发布 Vera Rubin——首款 HBM4 GPU（288GB HBM4, 22TB/s 带宽），单芯片 50 PFLOPs AI 算力，搭载 88 核 Vera CPU，宣称相较 Blackwell 有 5 倍性能提升。2026 年下半年全面投产，NVL72 整机柜方案推出。GTC 2026 进一步更新路线图到 2028 年——**Feynman**（HBM5, 首次堆叠逻辑晶圆）和下一代 CPU **Rosa**。NVIDIA 的迭代节奏从"两年一代"变成了"一年一代"。

2026 年 1 月，NVIDIA 以约 200 亿美元收购 Groq——这家 LPU 推理芯片初创公司此前被视为 NVIDIA 在推理市场上的最大威胁。收购以"知识产权许可 + 人才"模式完成。Groq 3 LPU 在 GTC 2026 上已集成展示。这被评价为"推理时代的战略布局"。

GTC 2026 还发布了两个关键战略转向：NVLink Fusion 和 CPO 硅光子。 NVLink Fusion 允许第三方 CPU 和 ASIC 通过 NVLink 协议连接 NVIDIA 硬件——从封闭走向半开放，AWS 已宣布 Trainium 4 将集成 NVLink Fusion。

Quantum 3400 CPO 交换机发布，定调"光铜并行"策略（短距铜缆、长距硅光），NVIDIA 投资 Marvell 20 亿美元合作。

Google TPU v7 Ironwood（2025.04） 在第 7 代实现了关键突破——每芯片 192GB 内存，Pod 内可达 42.5 Exaflops 算力，专门为推理模型优化，传言订单达 100 万颗。接着的 **TPU v8（2026.04）** 是一个标志性事件——Google 首次将训练和推理拆分为两条产品线：v8t（训练）峰值 12.6 FP4 PFLOPS，9600 芯片超算；v8i（推理）288GB HBM3e。数据震撼：Midjourney 切到 TPU 后推理成本从月 210 万美元降到 70 万美元以下（降 65%），Anthropic 计划到 2027 年扩展到 100 万 TPU。

AMD MI350X： 2025 年 6 月 AMD Advancing AI 大会正式发布，3nm 制程（TSMC N3P），推理性能比 MI300X 提升高达 35 倍——这个数字主要是 4-bit 量化推理场景。搭配 Samsung/Micron HBM3E，同期发布 ROCm 7.0（推理性能是 ROCm 6 的 3.8 倍）。MI400（2026 年出货，432GB HBM4），MI450（已获 Anthropic 大单），MI500（2027 年，2nm，CDNA 6）。AMD 还推出了 Helios 机架级别 AI 解决方案，双宽机架对标 NVIDIA NVL72。

3.8 阶段总结

AI 芯片发展的十八年可划分为五个阶段：

阶段	时间	核心特征	关键事件
萌芽期	2006–2011	CUDA 从 0 到 1，但场景不明	CUDA 发布、G80 架构
引爆期	2012–2016	GPU 被证明适合深度学习	AlexNet、cuDNN、TPU v1
黄金期	2017–2020	Transformer + Tensor Core 双击	V100、A100、Mellanox 收购
爆发期	2022–2023	ChatGPT 引爆，一卡难求	H100、市值 3.3T、出口管制
混战期	2024–2026	NVIDIA 全栈 + 自研 ASIC 围剿	Blackwell→Rubin、NVIDIA 200亿收 Groq、TPU v7/v8、Maia 200、华为 50%中国份额

四、横向分析：2026 年的竞争图谱

> **场景判断：该领域竞品充分（场景 C）。** 以下按梯队划分展开分析。

4.1 第一梯队：NVIDIA

核心优势：全栈垄断

NVIDIA 的垄断不是"GPU 硬件"的垄断，而是一个覆盖了硬件、互联、网络、软件的全栈生态系统：

- **硬件**：从 H100（2022）到 B200（2024）到 Rubin（规划中），每年一代的迭代节奏
- **互联**：NVLink 5.0（1.8 TB/s）+ NVSwitch，构建了私有但极其高效的 GPU-to-GPU 通信
- **网络**：Mellanox InfiniBand，万卡集群的基石
- **软件**：CUDA（400 万 + 开发者）、cuDNN、TensorRT、NeMo、Megatron-LM

H100（700W，80GB HBM3，990 TFLOPS FP16）至今仍是部署最广泛的 AI 训练 GPU。B200（1000W，192GB HBM3e，2.25 PFLOPS FP16）2025 年产能已全部售罄。

致命短板：

太贵，且供不应求。2025 财年 NVIDIA 数据中心营收 2159 亿美元——一条产品线比 AMD 整个公司还大。但这种"印钞机"式的利润正在激发全行业的反抗：Google、AWS、Microsoft 三家最大的云厂商同时自研芯片，AMD 和 Intel 在加速追赶。

开发者口碑：

CUDA 的开发者体验是行业标杆——文档完善、Nsight 调试工具是标杆级产品。社区里有一句经典描述："CUDA is not just a moat, it's an ocean." 但 vendor lock-in 和闭源策略也积累了越来越多的不满。

4.2 第二梯队：AMD + Google TPU

AMD：追赶者的两难

MI300X（2023）和 MI350X（2025）在硬件规格上已经能跟 NVIDIA 对标——MI350X 的 288GB HBM3e 和 2.39 PFLOPS FP16 甚至在某些指标上超过 B200。ROCm 是全开源的，HIP 兼容层可以让 CUDA 代码在 AMD GPU 上编译运行。

AMD 面临的核心问题是「硬件好但不好用」。ROCm 虽然开源，但对 CUDA 的新特性跟进通常慢 6-12 个月。开发者写一个自定义 kernel，CUDA 生态里有 10 年积累的优化经验和成熟的 debug 工具链，ROCm 上得自己从零摸索。

2024 年 AMD 数据中心 GPU 营收约 50 亿美元——不到 NVIDIA 的 5%。但这个数字在快速增长，TrendForce 预测 2025 年 AMD 市场份额会提升到 10-15%。

Google TPU：自研芯片的样板

TPU 是"自研芯片"这条路线最成功的案例。到 2026 年，Google 在训练中使用了约 30% TPU、在推理中使用了约 50% TPU——Google 已经是 NVIDIA 之外最大的 AI 芯片用户。

TPU vs GPU 的核心优势是**能效和成本**：

- TPU 每卡约 300W（GPU 700W+）
- 推理能效比低 60-65%
- 按需价格低至 $1.38/小时，承诺折扣价 $0.39-0.55/小时

数据最能说明问题：Midjourney 切换到 TPU 后成本降了 65%。Anthropic 计划到 2027 年使用 100 万 TPU。

但 TPU 有好几个限制：只能用 GCP 云服务（不卖芯片），深度绑定 JAX 框架（PyTorch 支持不如 CUDA），大规模训练场景下的灵活性不如 GPU。

4.3 第三梯队：华为 + 云厂商自研 + 初创公司

华为昇腾：国产替代的绝对主力，三年路线图首次公开

2025 年 9 月，华为首次在联接大会公布昇腾 AI 芯片的三年路线图——这在国产芯片领域是前所未有的事：

型号	时间	关键特性
昇腾 910C	2025	升级版
昇腾 950PR	2026 Q1	自研 HBM 内存，单卡算力达 H20 的 2.87 倍，支持 FP4
昇腾 960	2026 H2	持续迭代
昇腾 970	2027	下一代架构

同期推出 CloudMatrix 384 超节点——"全球最强超节点"。华为还首次公布了自研 HBM 内存。瑞穗证券估计 2025 年华为昇腾出货约 70 万颗。

软件生态仍是最大短板（CANN + MindSpore 远不如 CUDA 成熟），SMIC 拿不到 EUV 也限制了制程进步。但在"国产替代"政策驱动下，中国互联网大厂已批量采购，DeepSeek 被报道转向昇腾。

市场数据更新——中国 AI 芯片格局剧变：

Bernstein Research 预测 2026 年华为将占中国 AI 芯片市场 **50%** 份额，NVIDIA（受出口管制影响）将降至 **8%**。IDC 2025 年数据显示中国 AI 芯片总出货约 400 万张，NVIDIA 占约 55%，国产厂商合计约 41%。9 家国产 AI 芯片公司出货超万卡。寒武纪思元 590 出货强劲，计划 2026 年产能翻倍至约 5 万张。

这个数据的含义很清楚：**在全球市场 NVIDIA 80% 份额保持稳定的同时，中国市场正在快速独立化——两个生态的分离不是"趋势"而是"已完成的事实"。**

云厂商自研芯片

AWS Trainium 2/3/4、Microsoft Maia 100/200、Meta MTIA、百度的昆仑芯 2、阿里的含光 800——几乎所有大型云厂商都在自研芯片。

2025–2026 年，云厂商自研芯片从"谈判筹码"变成了"实质威胁"：

AWS Trainium： Trainium 2 已部署至 Project Rainier（约 50 万颗，2025.11 上线用于 Anthropic 训练）。Trainium 3（Trn3 UltraServers, 2025.12）已一般可用。Trainium 4 已公布，将集成 NVIDIA NVLink Fusion。CEO Andy Jassy 称芯片业务独立估值 500 亿美元，考虑对外销售。AWS 暂停 Inferentia 推理芯片，聚焦 Trainium。

Microsoft Maia 200（2026.01）： 3nm 工艺，算力超 10 PFLOPS，宣称性能超越 Google TPU v7。但曾因延迟（从 2025 推至 2026）导致第三代推迟至 2028 年后。

Meta MTIA（2026.03）： 一次性推出四款芯片（两年四代），RISC-V 核心。3 月先推推理芯片，训练芯片正与台积电测试。2026.04 与 Broadcom 达成数 GW 级定制芯片合作，协议延至 2029 年。

多家分析机构将 2026 年称为"定制芯片转折点"（Custom Silicon Inflection Point）。Introl、TrendForce、Wedbush 一致认为：自研 ASIC 是 NVIDIA 面临的最大威胁——不是 AMD，不是 Intel。博通作为 ASIC 设计商被认为是 NVIDIA 最大潜在对手。但现实是：这些芯片仍以内用为主，它们对 NVIDIA 的威胁是"减少需求"而非"抢占份额"。

初创公司

Cerebras（晶圆级芯片，2026.04 再次冲刺 IPO，估值约 20 亿）、Groq（LPU 推理芯片，2026.01 被 NVIDIA 以约 200 亿美元收购）、SambaNova（SN50 RDU 芯片，声称比 B200 更快）、d-Matrix（3D DRAM 突破，推理速度比 HBM4 快 10 倍）、Unconventional AI（Naveen Rao 创立，4.75 亿美元种子轮）。这些初创公司在特定场景有优势，但除 Cerebras 外，大多已被收购或仍处于早期阶段。

4.4 关键参数对比

芯片	发布时间	制程	算力(FP16)	内存/带宽	互联	TDP	软件生态	开源
NVIDIA H100	2022-03	4nm	990 TFLOPS	80GB HBM3 / 3.35 TB/s	NVLink 4 900 GB/s	700W	CUDA	❌
NVIDIA B200	2024-03	4NP	2.25 PFLOPS	192GB HBM3e / 8 TB/s	NVLink 5 1.8 TB/s	1000W	CUDA	❌
NVIDIA Rubin	**2026H2**	**3nm**	**~50 PFLOPS(FP4)**	**288GB HBM4 / 22 TB/s**	**NVLink 6**	**—**	CUDA	❌
AMD MI300X	2023-12	5nm	1.31 PFLOPS	192GB HBM3 / 5.3 TB/s	Infinity Fabric	750W	ROCm	✅
AMD MI350X	2025-06	3nm	2.39 PFLOPS	288GB HBM3e / 8 TB/s	Infinity Fabric	1000W	ROCm	✅
Google TPU v7 Ironwood	2025-04	—	—	192GB / —	ICI	—	JAX/XLA	❌
Google TPU v8t	2026-04	—	12.6 PFLOPS(FP4)	216GB HBM3e / 6.5 TB/s	Boardfly	—	JAX/XLA	❌
华为昇腾 950PR	2026-Q1	—	2.87× H20	自研 HBM	HCCS	—	CANN	❌
MS Maia 200	**2026-01**	**3nm**	**>10 PFLOPS**	**—**	**—**	**—**	Azure	❌
AWS Trainium 3	2025-12	—	—	—	—	—	Neuron	❌
Intel Gaudi 3	2024	7nm	—	128GB HBM2e / 3.7 TB/s	24x100GbE	600W	SynapseAI	❌

4.5 市场格局

NVIDIA 约 80% 的 AI 加速器市场份额短期内难以撼动。但我看到了三个结构性变化正在发生：

第一，**推理正在取代训练成为主战场。** 2023 年推理占 AI 计算约 33%，2026 年预计将占三分之二。推理场景对延迟和成本更敏感，这给了低成本芯片（TPU、定制 ASIC）机会。Gartner 预测到 2030 年，在 1 万亿参数 LLM 上执行推理的成本将比 2025 年降低 90% 以上——这个降幅的大部分来自芯片创新。

第二，**CUDA 护城河正在变浅，但 NVIDIA 在主动加深。** OpenAI Triton、MLIR、JAX 正在逐步解除开发者对 CUDA 的绑定。NVLink Fusion 则是 NVIDIA 反向操作——允许第三方 CPU/ASIC 接入 NVLink，用"半开放"应对开放生态的挑战。

第三，**中国市场正在成为独立的 AI 芯片生态。** Bernstein 预测 2026 年华为中国 AI 芯片份额达 50%、NVIDIA 降至 8%——这与全球 80% 的 NVIDIA 份额形成极端反差。两个生态的分离不是"趋势"而是"已完成的事实"。

4.6 核心趋势

1. **低精度计算成为新战场**：FP4/FP8 训练从实验走向主流。Blackwell 的 NVFP4 可以用 4-bit 精度匹配 16-bit 的训练准确度——由此，未来同样规模的芯片可以跑 4 倍大的模型。
2. **互联技术进入"光铜并行+标准大战"**：NVLink 5.0 1.8 TB/s 和 Google Boardfly 代表"私有高带宽 vs 灵活可编程"两种路线。2025-2026 新增变量——NVLink Fusion（NVIDIA 半开放，第三方 CPU/ASIC 可接入 NVLink）、UALink 联盟（AMD/Intel/Google/Microsoft/Meta 的开放 scale-up 互联标准，对标 NVLink）、Ultra Ethernet 1.0（以太网已正式成为 AI scale-out 网络主流，规模是 InfiniBand 的两倍以上）、CPO 硅光子（NVIDIA Quantum 3400 交换机发布，短距铜缆、长距硅光）。
3. **HBM 是战略瓶颈**：2026 年 HBM 需求同比增长约 70%，SK hynix 和 Micron 的产能已完全预订。AI 数据中心消耗了约 70% 的高端内存生产——制约 AI 芯片出货的不只是芯片本身，更是配套的 HBM 内存。
4. **Chiplet 成为标准设计范式**：Blackwell 的双 die 设计只是开始，Rubin 规划 3+ die，AMD 的 chiplet 架构也在迭代。2026 年将是 chiplet 设计成熟之年。
5. **云厂商自研不可逆**：虽然 NVIDIA 霸权短期内不会动摇，但 Google TPU 的成功案例让所有大厂都看到了自研芯片的价值——就算不是为了替代，也是为了谈判。

五、横纵交汇洞察

5.1 历史的锁扣

第一条链：CUDA 的"时间差"护城河

2007 年 CUDA 发布时，没人想到这个投资数亿美元、最初没有市场的项目，会在十几年后成为 NVIDIA 最坚固的壁垒。

回看这段历史，最让我惊叹的不是 NVIDIA 做对了什么，而是**它在一个没有市场的时候就开始布局。** 2012 年 AlexNet 引爆深度学习时，NVIDIA 已经为 GPU 计算积累了 5 年的技术和社区基础。2016 年 cuDNN 让 TensorFlow 和

PyTorch 深度绑定 CUDA 时，开发者都没有意识到这个选择的长期后果——直到想换 AMD 的时候，才发现代码库里全是 cuDNN 调用。

这就是我能看到的最核心的「历史锁扣」：**当 AI 爆发的瞬间到来时，NVIDIA 已经在基础设施层卡好了位置。** 这种做法不是巧合——黄仁勋在多次采访中说过，"我们不是在预测 AI 会来，我们是在建造 AI 需要的基础设施"。

第二条链：专用与通用的永恒辩论

AI 芯片的历史，也是一场"专用 vs 通用"的反复拉锯。

Google TPU 是"专用派"的极致——做了个只能跑神经网络推理的 ASIC，面积小、功耗低、效率高。NVIDIA GPU 是"通用派"——什么都能跑（训练、推理、渲染、加速计算），但每个场景都不是最优。

2026 年，我看到了一个有趣的趋同：NVIDIA 的 GPU 越来越"专用"——Tensor Core 是专用矩阵乘法器，Transformer Engine 是专为 Transformer 设计的，NV-HBI 是专用芯片互联。而 Google TPU 越来越"通用"——v8t/v8i 拆分突破了"仅推理"的限制，v8i 甚至加入了更多 SRAM 来支持复杂推理模式。

这个趋同的背后有一个更深的规律：当市场规模足够大时，专用就会战胜通用。 未来 AI 芯片的竞争将不再是 GPU vs ASIC，而是"专有全栈"（NVIDIA 模式）vs "开放标准"（AMD + UALink 联盟 + 开放软件生态）。

第三条链：地缘政治正在制造"两个 AI 世界"

出口管制对 AI 芯片格局的影响，可能比任何技术突破都要深远。

我看到了一个正在形成的格局：一个"西方生态"（NVIDIA + AMD + Google TPU，CUDA/Triton/ROCm 互通），和一个"中国生态"（华为昇腾 + 寒武纪 + 海光，CANN + 自研框架）。两个生态在底层硬件上完全隔离，但在上层应用层通过 PyTorch 等框架保持一定的兼容性。

长期来看，这会带来一个后果：**中国 AI 芯片在缺少 EUV 光刻机的情况下，被迫在算法优化和系统效率上走一条自己的路。** DeepSeek 用 512 块 H800 训练出 R1 证明了"算法可以部分替代算力"。如果这种趋势持续，中国 AI 可能会走出一条"低算力 + 高算法效率"的发展路径——这跟西方"堆算力"的路线完全不同。

5.2 三个剧本

剧本一（最可能）：NVIDIA 继续主导，但份额缓慢下降

未来 2-3 年，NVIDIA 仍将以 60-80% 的市场份额主导 AI 芯片市场。CUDA 生态的惯性太大，AMD 和自研芯片短期内无法撼动。B200/Rubin 迭代保持硬件领先，但推理市场占比提升会稀释 NVIDIA 的统治力（推理场景更多使用低成本芯片）。Google TPU 继续扩大自用比例并向第三方开放，AMD 份额缓慢爬升到 15-20%。国内昇腾在政策驱动下占据中国市场的大头，但全球份额有限。

剧本二（最危险）：AI 芯片供应瓶颈扼制行业发展

HBM 产能瓶颈持续恶化，加上 Blackwell 级别的先进封装产能不足，AI 芯片供应跟不上需求增长。创业公司因为买不到 GPU 而倒闭，中美芯片脱钩导致全球供应链效率下降。AI 行业增速放缓，模型进化速度下降，泡沫破灭。这个剧本的可能性不低——2026 年 HBM 产能已完全预订，台积电 CoWoS 产能也长期紧张。

剧本三（最乐观）：架构突破打破 NVIDIA 垄断

光互联 + Chiplet + 开放软件生态的三重突破，让 AI 芯片成本大幅下降、供应量大幅上升。光子计算从实验室进入商用，一个 1000 美元的 AI 芯片可以达到今天 B200 的水平。推理成本下降 90%+，AI 应用爆发。CUDA 的锁定被

Triton/MLIR 打破，开发者可以自由选择任何芯片。华为通过算法优化在受限硬件上做出竞争力。这个剧本的关键前提是：光互联或类似架构突破从规模上验证——这可能需要 3–5 年。

六、信息来源

核心论文与文章

论文/文章	来源	访问时间
Attention Is All You Need	arxiv.org/abs/1706.03762	2026–04–30
TPU v1: In–Datacenter Performance Analysis of a Tensor Processing Unit (ISCA 2017)	dl.acm.org/doi/10.1145/3079856.3080246	2026–04–30
ImageNet Classification with Deep Convolutional Neural Networks (AlexNet)	2012	2026–04–30

产品与技术来源

来源	URL	访问时间
NVIDIA H100 Whitepaper	https://nvdam.widen.net/content/tdwwiwotwr/original/gtc22-whitepaper-hopper.pdf	2026-04-30
NVIDIA Blackwell Technical Brief	https://resources.nvidia.com/en-us-blackwell-architecture	2026-04-30
NVIDIA CUDA Wikipedia	https://en.wikipedia.org/wiki/CUDA	2026-04-30
NVIDIA Tesla Wikipedia	https://en.wikipedia.org/wiki/Nvidia_Tesla	2026-04-30
Wikipedia: Hopper Microarchitecture	https://en.wikipedia.org/wiki/Hopper_(microarchitecture)	2026-04-30
Wikipedia: Blackwell Microarchitecture	https://en.wikipedia.org/wiki/Blackwell_(microarchitecture)	2026-04-30
Google TPU Wikipedia	https://en.wikipedia.org/wiki/Tensor_Processing_Unit	2026-04-30
AMD Instinct Wikipedia	https://en.wikipedia.org/wiki/AMD_Instinct	2026-04-30
AMD ROCm Wikipedia	https://en.wikipedia.org/wiki/ROCm	2026-04-30
Huawei Wikipedia	https://en.wikipedia.org/wiki/Huawei	2026-04-30
Gartner AI Inference Market Forecast (March 2026)	Gartner	2026-04-30
Grand View Research: AI Inference Market 2030	Grand View Research	2026-04-30
Jon Peddie Research: GPU Market Q1 2025	Jon Peddie Research	2026-04-30
The Guardian: China blocks NVIDIA H200 (2026-01)	https://www.theguardian.com/technology/2026/jan/17/china-blocks-nvidia-h200-ai-chips-that-us-government-cleared-for-export-report	2026-04-30
SemiAnalysis: China AI Chips	https://www.semianalysis.com/p/nvidias-new-china-ai-chips-circumvent	2026-04-30

Forbes: AI chip market analysis	Forbes	2026-04-30
CNBC: Cerebras S-1 filing (2026-04)	CNBC	2026-04-30
Data Center Dynamics: Blackwell delay analysis	Data Center Dynamics	2026-04-30
East Asia Forum: US-China chip export controls	East Asia Forum	2026-04-30
NVIDIA GTC 2026 Keynote	Rubin/Feynman/NVLink Fusion/CPO	2026-04-30
NVIDIA CES 2026 Keynote	Vera Rubin official launch	2026-04-30
NVIDIA 收购 Groq	Fortune, Yahoo Finance (2026-01)	2026-04-30
TrendForce: Blackwell/Rubin出货占比预测 (2026-04)	TrendForce	2026-04-30
Google TPU v7 Ironwood 发布	Google Cloud Next (2025-04)	2026-04-30
AWS Trainium 3 re:Invent 发布 (2025-12)	AWS	2026-04-30
Microsoft Maia 200 发布	Microsoft Official Blog (2026-01-26)	2026-04-30
Meta MTIA 四款芯片	CNBC, The Register (2026-03)	2026-04-30
华为昇腾三年路线图	华为全联接大会 (2025-09)	2026-04-30
Bernstein Research: 中国AI芯片市场份额预测 (2026)	Bernstein Research	2026-04-30
Ultra Ethernet Consortium Spec 1.0 发布	Ultra Ethernet Consortium	2026-04-30
UALink Consortium 成立	AMD/Intel/Google/Microsoft/Meta	2026-04-30

Dell'Oro: 以太网 AI scale-out 规模超 InfiniBand 两倍 (2026-01)	Dell'Oro	2026-04-30

> **方法论说明**：本报告采用横纵分析法（Horizontal-Vertical Analysis），由数字生命卡兹克提出。纵向部分追溯 AI 芯片从 2006 年 CUDA 到 2026 年 TPU v8 的完整演进史；横向部分对比当前主要 AI 芯片厂商的竞争格局；横纵交汇部分给出综合性判断和未来推演。

> 报告生成时间：2026 年 4 月 30 日

本文是横纵分析系列的第 3 篇报告。方法论：横纵分析法——纵向沿时间轴追溯技术演进，横向对比当下竞争格局。