大模型强化学习（RL）前置知识

> 面向零基础读者，用比喻和例子讲清楚 RL 在 LLM 中的核心概念。

一、什么是强化学习?

强化学习（Reinforcement Learning, RL）是机器学习的一种范式：**一个 Agent 在环境中尝试动作，根据得到的奖励来学习"什么动作在什么情况下最好"。**

用训狗来比喻：你教狗坐下——它乱跑（动作），你说"不对"（负奖励）；它坐下了（动作），你给零食（正奖励）。狗不需要你告诉它"怎么坐"，它只需要知道"坐下有零食"。RL 完全一样——你不需要告诉模型"怎么做"，只需要告诉它"做对了没有"。

这与监督学习（SFT）的根本区别：

- **SFT**：给模型看"标准答案"，让它模仿
- **RL**：让模型自己探索，根据奖励学习最优策略

二、RL 在 LLM 中的角色演变

RLHF（2022）– 让模型"说人话"

RLHF = Reinforcement Learning from Human Feedback（基于人类反馈的强化学习）。

三阶段流程：

1. **SFT**：人类标注员写示范回答，模型学会"问答"格式
2. **RM 训练**：人类对不同回答排序，训练一个"奖励模型"来预测人类的偏好
3. **PPO 优化**：用奖励模型打分，通过 PPO 算法更新模型参数

关键是第 3 步要同时加载 4 个模型：策略模型（要训练的）、参考模型（防止跑偏）、价值模型（估计当前状态好坏）、奖励模型（打分）。工程代价巨大。

DPO（2023）– 不需要奖励模型了

Direct Preference Optimization 的核心洞察：偏好数据中蕴含的对比信息可以直接优化策略，不需要先训练一个单独的奖励模型。

效果：训练中从 4 个模型降到 2 个模型，GPU 需求从 8 张降到 2 张。个人开发者也能做对齐了。

但 DPO 是**离线**的——只在已有偏好数据上优化，无法发现比数据中更好的回答。

GRPO（2024）– 连价值模型也不要了

Group Relative Policy Optimization 做了最优雅的减法：去掉价值模型（critic）。

怎么做到的？对同一个 prompt 生成多个回答（比如 4 个），用这个 group 内的**相对分数**来替代绝对价值估计。"比其他答案更好"= 好，"比其他答案更差"= 差。不需要知道"4.3 分"这个绝对值。

DeepSeek-R1 的成功证明：去掉 critic、去掉 reward model，只用 GRPO + 可验证奖励（对/错），模型就能自己学会推理。

RLVR（2025-2026）– 打破数据瓶颈

RLVR = RL with Verifiable Rewards（可验证奖励的强化学习）。

前面的方法都依赖人类来判断"好不好"——这是瓶颈，因为人工标注贵且慢。RLVR 的突破在于：**用可自动验证的规则替代人类判断。**

哪些是可以自动验证的？

- 数学题：答案对还是错 → 自动判断
- 代码：测试用例是否通过 → 自动判断
- Agent 任务：任务完成与否 → 自动判断

RLVR 让 RL 训练可以 24×7 无人值守、无限规模化。

三、关键概念速查

概念	一句话	重要性
Policy（策略）	模型本身——给定输入，输出什么	核心
Reward（奖励）	对输出的评价信号——好还是坏	核心
Rollout（展开）	训练中让模型生成回答的过程	高
Critic（价值网络）	估计"当前状态有多好"的辅助模型	中（GRPO 去掉了）
Reward Model（奖励模型）	预测人类偏好的辅助模型	中（DPO 去掉了）
On-Policy	用模型自己生成的数据来训练	高
Off-Policy	用预先收集的数据来训练	高
KL Penalty	约束——防止模型"放飞自我"偏离太远	高
Reward Hacking	模型学会了"骗取高分"而非"真正做好"	警惕

四、延伸阅读

- Post-training / RL 训练基础设施 — RL 训练框架与工程实现的更多细节
- 大模型评估与对齐 — 奖励 hacking 与对齐 tax 的深入分析