大模型技术演进全史

> 2017–2026，十年，从"Attention Is All You Need"到 GPT-5.5 的 88 天一换的王座争夺战——这不是 35 个孤立主题的堆砌，而是一张紧密交织的技术之网。本篇把 35 篇横纵分析报告中的所有关键事件按时间线串联，标注每个事件属于哪个主题、影响了哪些后续发展。

阅读说明

每个条目格式：**时间 · 事件** — [所属主题] → 影响了什么

时间跨度：2017（Transformer 诞生）→ 2026 年 5 月（当前）

2014–2016：AI 觉醒前夜

```
2014 · GAN 提出（Goodfellow）
```

— [AI图像生成] [AI视频生成]

生成对抗网络——生成器和判别器互相博弈。这是 AI 从"识别"走向"创造"的起点。虽然后来被扩散模型取代，但 GAN 定义了"生成式 AI"这个品类。

```
2015 · Knowledge Distillation 提出（Hinton）
```

— [大模型蒸馏]

"暗知识"——老师输出的概率分布比硬标签包含更多信息。这篇论文在 LLM 时代被重新发现——2025 年的 R1-Distill 和 2026 年的 OPD，都是 Hinton 思想的延续。

```
2015 · ResNet + Batch Normalization
```

— [深度学习基础]

残差连接让训练上百层的网络成为可能——Transformer 后来的残差连接直接继承自 ResNet。BN 解决了深层网络的训练稳定性问题，后来被 LayerNorm 取代成为 Transformer 标配。

2017：Transformer 诞生

```
2017.06 · "Attention Is All You Need" 发表（Vaswani et al., Google）
```

— [Transformer] [深度学习基础]

用自注意力替代 RNN——解决了困扰 NLP 二十年的"序列必须串行处理"问题。完全并行化的架构让训练速度从"数周"降到"数天"。

Transformer 不是一篇论文——它是一颗种子。此后 9 年所有重要的 AI 进展——BERT、GPT、ViT、DiT、Sora——全是这颗种子的后代。

```
2017 · Transformer 的 Encoder-Decoder 架构
```

— [Transformer]

原版 Transformer 是完整的 Encoder+Decoder——编码器做理解，解码器做生成。这个设计逻辑在 2018 年被拆成了两条独立的路线：BERT 只要编码器，GPT 只要解码器。

2018：BERT 与 GPT 的分叉——两条路线的诞生

```
2018.02 · ELMo 发布（Peters et al., Allen AI）
```

— [NLP基础] [BERT体系]

第一个实现"动态上下文嵌入"的模型。同一个词在不同句子中可以得到不同的向量——"苹果很好吃"和"苹果发新机"中的"苹果"终于有了不同的表示。但底层是双向 LSTM，速度和远距离依赖都有瓶颈。

```
2018.06 · GPT-1 发布（Radford et al., OpenAI）
```

— [GPT体系] [LLM大模型] [Transformer]

117M 参数，Decoder-only Transformer，自回归语言模型。OpenAI 从这一年开始锁定了一条此后 8 年不变的技术路线："续写下一个词"。

```
2018.10 · BERT 发布（Devlin et al., Google）
```

— [BERT体系] [NLP基础] [Transformer]

340M 参数，Encoder-only Transformer，掩码语言模型（MLM）双向预训练。发布当天刷新 11 项 NLP 基准 SOTA。

BERT 的真正遗产不是模型本身——而是"预训练→微调"这个范式：在无标注数据上预训练通用模型，然后在每个下游任务上微调。这个范式统治了 NLP 三年，后来被 GPT-3 的 In-Context Learning 升级（连微调都不用了），但底层哲学延续至今。

```
2018 · Transformer 路线分叉
```

— [Transformer] [BERT体系] [GPT体系]

```
       Transformer (2017)
       Encoder + Decoder
              |
              |
    ┌─────────┴──────────┐
    |                    |
BERT (Encoder-only)   GPT (Decoder-only)
双向理解                单向生成
"读懂一切"              "续写一切"
```

这个分叉定义了此后八年的 AI 版图。GPT 路线赢了交互层，BERT 路线赢了基础设施层。

2019：BERTology 与 GPT-2 的"危险"宣言

```
2019.02 · GPT-2 发布（OpenAI）
```

— [GPT体系] [LLM大模型]

1.5B 参数。OpenAI 以"太危险"为由拒绝完整发布——事实上这是 AI 史上最成功的营销事件。GPT-2 最重要的发现是规模涌现现象：从 117M 到 1.5B，模型在没有针对任何任务训练的情况下，居然在翻译、摘要、问答等任务上接近 SOTA。

```
2019.07 · RoBERTa（Liu et al., Facebook）
```

— [BERT体系]

"BERT 训练版本 2.0"——相同架构，更好地训练。去掉了 NSP、更大的 batch、更多数据。结论：BERT 的潜力被低估。

```
2019.09 · ALBERT（Lan et al., Google）
```

— [BERT体系]

参数共享 + 因式分解嵌入——证明 BERT 中有大量参数冗余。

```
2019.10 · DistilBERT (Sanh et al., Hugging Face)
```

— [BERT体系] [模型压缩]

用蒸馏把 BERT 从 110M 压缩到 66M，保留 97% 性能——"小模型也能跑 BERT"的开端。

```
2019 · Houlsby Adapter (Google)
```

— [PEFT]

在 Transformer 层之间插入小型 bottleneck 适配器——只训练 3.6% 参数，达到全量微调 99.6% 效果。PEFT 的学术起点。

```
2019.02 · StyleGAN (NVIDIA)
```

— [AI图像生成]

控制不同层次的视觉特征——AI 首次实现了"可控生成"。

```
2019 · Lottery Ticket Hypothesis (Frankle & Carbin)
```

— [模型压缩]

大网络中存在"中奖彩票"（子网络），独立训练可达到原网络精度。这是剪枝方向的理论背书。

2020：GPT-3 与 Scaling Law

```
2020.01 · Scaling Laws for Neural Language Models (Kaplan et al., OpenAI)
```

— [GPT体系] [大模型训练]

模型性能随参数量、数据量、计算量的幂律关系。**这是 GPT 体系的"圣经"**——此后六年的所有"做大模型"行为，都在用实践验证这篇论文的预测。

```
2020.05 · GPT-3 发布 (OpenAI)
```

— [GPT体系] [LLM大模型] [Prompt Engineering]

175B 参数。发现了 In-Context Learning——不需要微调，prompt 里给几个示例就能完成新任务。

这是 AI 史上最重要的能力涌现事件之一：**"智能"可能是足够大的自回归模型在足够多的数据上训练后的自然产物，而不是精心设计的结果。**

```
2020.06 · DeBERTa (He et al., Microsoft)
```

— [BERT体系]

解耦注意力机制。DeBERTaV3（2021.08）在 SuperGLUE 上首次超越人类基准——BERT 体系在"理解"任务上的顶点。

```
2020.03 · ELECTRA (Clark et al., Google/Stanford)
```

— [BERT体系]

不是填空，而是"鉴别假词"。训练效率比 BERT 高 3–4 倍——这是 BERT 体系对"MLM 效率太低"这个根本问题的回应。

```
2020 · ViT (Vision Transformer, Google)
```

— [多模态大模型] [AI图像生成]

证明了 Transformer 不仅能处理文本，还能处理图像——把图片切成 patches 当 token 用。CNN 对视觉的垄断被打破。

```
2020 · DDPM (Ho et al.)
```

— [AI图像生成] [AI视频生成]

去噪扩散概率模型——训练稳定、生成质量高。两年后引爆了 DALL–E 2 / Midjourney / Stable Diffusion 三箭齐发的图像生成革命。

```
2020 · BERT 时代的结束信号
```

— [BERT体系] [GPT体系]

GPT–3 的 175B vs BERT 的 340M——差距达到了两个数量级。不是因为 BERT 的设计不好，而是 BERT 的 MLM（每轮只训练 15% token）在规模化效率上被 GPT 的自回归（每轮训练 100% token）碾压。

2021：扩散模型、LoRA、Prompt Tuning

```
2021.01 · Prefix Tuning (Li & Liang)
```

— [Prompt Engineering] [PEFT]

在 Transformer 每层的 hidden states 前拼接可学习向量——只需要 0.1% 参数。把"微调"变成了"加个 prompt 前缀就行"。

```
2021.04 · Prompt Tuning (Lester et al.)
```

— [Prompt Engineering]

进一步简化——只在输入层加 soft prompt。关键发现：**模型越大，prompt tuning 效果越接近全量微调。**

```
2021.06 · LoRA 发表 (Hu et al., Microsoft, ICLR 2022)
```

— [PEFT] [大模型训练]

低秩分解——微调时权重变化量 ΔW 是低秩的，不需要一个大矩阵来存。4096×4096 的参数更新 → 两个 4096×r 的小矩阵。训练参数减少 128 倍。

LoRA 在推理时可以合并回原模型——**零推理延迟**。这是它击败 Adapter 的关键。

```
2021.10 · P-Tuning v2 (Liu et al., 清华)
```

— [Prompt Engineering]

"深层 prompt"——每一层都加 prompt token。解决 prompt tuning 在小模型和序列标注任务上的不足。

```
2021 · RoPE (Rotary Position Embedding, Su et al.)
```

— [长上下文技术] [Transformer]

旋转位置编码——用旋转矩阵而非加法来编码位置信息。成为 2022 年后几乎所有 LLM 的标配位置编码方案。

```
2021 · CLIP (Radford et al., OpenAI)
```

— [多模态大模型]

用对比学习把文本和图像映射到统一的向量空间。这是所有多模态大模型的根基——GPT-4V、Gemini、Qwen-VL——都是 CLIP 路线的延伸。

```
2021.12 · GLIDE (OpenAI)
```

— [AI图像生成]

第一个把文本引导与扩散模型有效结合的工作。DALL-E 2 的前身。

2022：ChatGPT 引爆全球 + 图像生成三箭齐发

```
2022.03 · InstructGPT 发表（OpenAI）
```

— [GPT体系] [大模型强化学习] [AI Safety]

RLHF（基于人类反馈的强化学习）正式亮相。三阶段流程（SFT → RM → PPO）成为此后所有对齐训练的标准模板。

RLHF 的工程代价是巨大的——训练时需要同时加载 4 个大模型（Actor + Critic + Ref + Reward）。但这个代价换来的是"让模型说人话"的能力。

```
2022.03 · Midjourney Beta
```

— [AI图像生成]

独立实验室，Discord 里建了个机器人，发 `/imagine` 命令就出图。不是技术最早，但产品设计天才——Discord 的社区效应让 Midjourney V5/V6 成为 AI 图像质量的事实标杆。

```
2022.04 · DALL-E 2 发布（OpenAI）
```

— [AI图像生成]

从文字描述生成高分辨率照片级图片。内测候补名单制造了巨大的饥饿感——"AI 画画"从此进入大众视野。

```
2022.08 · Stable Diffusion 开源（Stability AI）
```

— [AI图像生成]

最重要的开源贡献之一：任何人都可以下载、在消费级 GPU 上运行、二次开发。催生了 ControlNet、LoRA、ComfyUI、AUTOMATIC1111——AI 图像生成史上最庞大的工具生态。

```
2022.10 · GPTQ 量化方法（Frantar et al.）
```

— [模型压缩] [大模型推理部署]

第一个实用的 LLM 4-bit 量化方法——OPT-175B 在 4 小时内从 FP16 降到 INT4，perplexity 损失不到 0.5。"LLM 终于能在消费级 GPU 上跑了。"

```
2022.11 · ChatGPT 发布（OpenAI）
```

— [GPT体系] [LLM大模型] [AI Agent]

5 天 100 万用户，2 个月 1 亿月活——地球历史上增长最快的消费产品。ChatGPT 的真正革命不是技术，是**产品**——把 AI 从"需要会编程"变成了"会打字就能用"。

```
2022.11 · SmoothQuant
```

— [模型压缩]

解决 LLM 激活值异常值问题——把量化难度从激活值迁移到权重上，实现 W8A8 推理加速。

```
2022.12 · Constitutional AI (Anthropic)
```

— [AI Safety]

不给人类一个一个标注偏好，而是给 AI 写一本"宪法"，让它通过自我批评和修正学习安全行为。RLAIF（用 AI 反馈替代人类反馈）在这篇中被首次系统阐述。

2023：LLM 生态爆发——LoRA、量化、RAG、Agent

```
2023.01 · SparseGPT (Frantar & Alistarh)
```

— [模型压缩]

一步式剪枝——不训练不微调，直接移除 50% 参数。虽然结果很震撼，但标准 GPU 对稀疏矩阵支持有限，剪枝至今未成为主流。

```
2023.03 · GPT-4 发布 (OpenAI)
```

— [LLM大模型] [GPT体系] [多模态大模型]

首次在 LLM 中集成视觉能力。128K 上下文。MMLU ~86.4%。从这一年开始，GPT 和 Claude 的"两超"格局形成。

```
2023.03 · llama.cpp / GGUF (ggerganov)
```

— [模型压缩] [端侧AI]

"周末在家用 CPU 跑 LLaMA"——GGUF 格式 + llama.cpp 构成了 2023–2026 年最完整的本地 LLM 运行生态。LM Studio、Ollama 都建立在此之上。

```
2023.05 · QLoRA (Dettmers et al., NeurIPS 2023)
```

— [PEFT] [模型压缩]

NF4 + 双重量化 + 分页优化器——65B 模型在单块 48GB GPU 上微调 24 小时，达到 ChatGPT 99.3% 性能。**把微调 65B 模型的硬件门槛从 8 块 A100 降到 1 块。**

```
2023.05 · DPO 论文（Rafailov et al.）
```

— [大模型强化学习] [AI Safety]

不需要奖励模型，直接用偏好数据优化。训练中的模型从 4 个降到 2 个——GPU 需求从 8 卡降到 2 卡。**个人开发者第一次能做对齐训练了。**

DPO 有结构性短板——离线优化，无法探索数据中不存在的"更好的回答"。但它的易用性让 RL 对齐不再是巨头专属。

```
2023.06 · AWQ（韩松团队，MIT）
```

— [模型压缩]

激活值感知量化——找出"重要"的 1% 权重通道给更高精度保护，其余大胆量化。比 GPTQ 快 10–20%。到 2026 年成为 vLLM / TensorRT-LLM 首选。

```
2023.06 · SpQR
```

— [模型压缩]

找出异常权重单独高精度存储——1% 精度损失下把模型压到 4-bit 以下。实验效果惊艳但工程落地有限。

```
2023.06 · Phi-1（Microsoft）
```

— [小语言模型 SLM] [大模型蒸馏]

1.3B 参数，"教科书质量"合成数据训练，编程能力超越 12B 模型。**这是"数据质量 > 参数数量"的第一个实证。**

```
2023.07 · "Lost in the Middle"（Liu et al.）
```

— [Context Engineering] [RAG] [长上下文技术]

模型倾向于忽略中间位置的文档——信息放开头或结尾被正确使用，放中间则性能急剧下降。引用量 4000+，**上下文位置编排由此成为一门学问。**

```
2023.07 · Llama 2 开源（Meta）
```

— [LLM大模型]

7B/13B/70B，商业可用。引爆了整个开源 LLM 生态——没有 Llama 2，就没有 QLoRA 的大规模应用、没有 R1-Distill 的学生模型、没有端侧 AI 的 7B 族谱。

```
2023.08 · DeepSpeed-Chat（微软）
```

— [Post-training RL] [大模型训练]

第一个系统化的 RLHF 分布式训练开源工具。混合引擎——训练和推理共享显存。"复现 InstructGPT 三阶段流程"的开源方案。

```
2023.09 · vLLM / PagedAttention (UC Berkeley)
```

— [大模型推理部署]

KV Cache 分页管理——像操作系统的虚拟内存一样管理显存碎片。成为 RLHF rollout 生成和 LLM 服务的标准推理引擎。到 2026 年 78k stars。

```
2023.10 · DALL-E 3 (OpenAI)
```

— [AI图像生成]

与 ChatGPT 深度集成——不需要写 prompt，直接描述需求。文字理解力所有模型中最强。

```
2023.10 · Self-RAG
```

— [RAG]

模型自我判断是否需要检索——"反思 token"机制。检索前判断"要不要找"、检索后判断"找到的质量如何"、生成后判断"答案可不可靠"。

```
2023.10 · VeRA
```

— [PEFT]

所有层共享随机初始化的冻结低秩矩阵，只学每层缩放向量——参数量比 LoRA 再减少 100 倍。**PEFT 从"高效"走向"极致高效"。**

```
2023.10 · TensorRT-LLM (NVIDIA)
```

— [大模型推理部署]

NVIDIA 推理引擎——2026 年唯一支持 Blackwell FP4 的框架。与 vLLM、SGLang 形成三足鼎立。

```
2023.11 · Unsloth
```

— [PEFT] [大模型训练]

自定义 Triton 内核——在 FFT/LoRA/QLoRA 上训练速度 2x，显存节省 70%。到 2026 年 63k stars，增长速度最快的 PEFT 训练框架。

```
2023.11 · DARE
```

— [模型压缩] [PEFT]

随机丢弃 99% 的微调 delta 参数，模型仍能恢复原能力。**微调产生的调整高度冗余——这是 LoRA 低秩假设成立的最强间接证据。**

```
---

## 2024：推理时计算、GRPO、DiT 架构成熟、MCP 协议
```

2024.01 · AQLM（Yandex + IST Austria）

```
- [模型压缩]

残差码本量化——在 2-bit 级别做到 GPTQ/AWQ 追平或超越的质量。学术上 2-bit 的里程碑。
```

2024.02 · DoRA（NVIDIA, ICML 2024 Oral）

```
- [PEFT]

把权重分解为"大小"和"方向"——方向用 LoRA 更新，大小用可学习向量更新。在一些任务上缩小了与全量微调的差距。
```

2024.02 · GRPO / DeepSeekMath（DeepSeek）

```
- [大模型强化学习] [Post-training RL]

去掉 critic 网络！对同一 prompt 生成多个回答，组内相对分数替代绝对价值估计。**训练显存减少 30-40%，训练代码简化
```

2024.08 · Flux 发布（Black Forest Labs）

```
- [AI图像生成] [Transformer]

Stable Diffusion 原班人马出走创办。第一个在写实度上正面挑战 Midjourney 的开源 DiT 模型。DiT = 扩散 + Trans
```

2024.08 · Anthropic Prompt Caching 公测

```
- [Context Engineering]

静态内容（system prompt、few-shot 示例）输入 token 成本降低 90%，延迟降低 80%+。**开发者在 prompt 设计中从
```

2024.09 · o1 发布（OpenAI）

```
— [GPT体系] [大模型强化学习] [大模型推理部署]

推理时计算扩展（test-time compute scaling）首次产品化。给模型更多时间思考，准确率持续提升。"让模型多想一会儿"比

o1 的技术细节未公开，但行业共识：RL 训练了模型"学会思考"——通过 RL 探索和可验证奖励学习有效的推理链，而不是模仿人类
```

2024.10 · Temporal + AI Agents

```
— [Agent Runtime]

持久化 Agent 执行——Agent 在任何步骤中断后都能从断点恢复。"跑了三天的 Agent 挂了就得重来"这个痛点被解决。
```

2024.11 · MCP 协议发布（Anthropic）

```
— [Agent Runtime] [Context Engineering]

Model Context Protocol——"AI 应用的 USB-C 接口"。让 Agent 与外部数据源的连接标准化。到 2026 年被 ThoughtW
```

2024.12 · Phi-4（Microsoft）

```
— [小语言模型 SLM]

14B 参数，MMLU ~84%，MATH ~82%。"14B 跑出 70B 的水平"——数据质量的魔法。
```

2024.12 · ModernBERT（Answer.AI + LightOn 等）

```
— [BERT体系]

用 RoPE + FlashAttention + 高效 tokenizer 把 BERT 架构现代化。8192 token 上下文，检索/分类速度比同尺寸 d
```

2024 · Llama 3 系列（Meta）

```
— [LLM大模型]

8B/70B/405B，开源最强。Meta 的开源策略在这一年定型——不是做最好的模型，而是做最开放的模型。
```

2025：R1 震动全球、GPT-5、Llama 4、AI Agent 元年

```
2025.01 · DeepSeek-R1 发布（Nature）
```

— [大模型强化学习] [大模型推理部署] [LLM大模型] [大模型蒸馏]

这个事件的重要性怎么强调都不过分。核心发现：**纯 RL（没有人类标注的推理轨迹）就能让模型自发涌现出自我反思、验证、动态策略调整等高级推理行为。** 不需要教模型"怎么思考"——只需要告诉它"对"或"错"。

R1 同时释放了蒸馏路线：R1-Distill-Qwen-32B 在 MATH 上达到 83.8%，接近 GPT-4。推理能力可以被蒸馏——这是 2025 年最重要的技术发现之一。

```
2025.03 · GPT Image 取代 DALL-E（OpenAI）
```

— [AI图像生成] [GPT体系]

图像生成不再是一个独立产品——直接内嵌到了 ChatGPT 里。发布首周 1.3 亿用户生成 7 亿张图片。

```
2025.03 · DAPO（字节跳动）
```

— [大模型强化学习]

GRPO 的升级版——动态采样（简单题少采样，难题多采样）+ Clip Higher 机制。在 GPT-5 级别模型中比 GRPO 高 2-3 个百分点。

```
2025.04 · Llama 4 Scout/Maverick（Meta）
```

— [LLM大模型] [MoE] [长上下文技术]

Llama 首次采用 MoE 架构。Scout 有 10M 上下文——行业最高。但也制造了 2026 年最大的基准测试丑闻——使用"实验性改进版"替代正式版刷榜，独立重测后从第 5 跌到第 32。

```
2025.05 · LangGraph Platform GA（LangChain）
```

— [Agent Runtime] [LLM应用框架]

StateGraph 持久化 + Human-in-the-loop + 多 Agent 拓扑管理。"Agent Runtime 从框架的一个模块升级为独立的云服务品类。"

```
2025.06 · Context Engineering 概念诞生
```

— [Context Engineering]

Shopify CEO Tobi Lutke 发了一条不到 30 词的推文，命名了行业正在经历却无法表述的痛点。Karpathy 用"CPU/RAM/OS"比喻让它爆火——**这是一个大号比喻胜过十篇论文的罕见案例。**

```
2025.06 · GPT-5 发布（OpenAI）
```

— [LLM大模型] [GPT体系]

"PhD 级推理能力"。迭代节奏从"一年一代"开始加速。

```
2025.07 · AWS Bedrock AgentCore
```

— [Agent Runtime]

Firecracker microVM——每个 Agent 会话独立执行环境。云厂商第一次把 Agent 运行时当作云平台的一等公民。

```
2025.08 · Gemini 2.5 Pro (Google)
```

— [LLM大模型]

深度推理能力显著增强。Google 的追赶进入加速期。

```
2025.09 · Anthropic "Effective context engineering" 工程博客
```

— [Context Engineering]

Attention Budget 理论、Context Rot 概念的正式提出。

```
2025.12 · MCP 捐给 Linux 基金会
```

— [Agent Runtime]

成立 Agentic AI Foundation。MCP 从"Anthropic 的协议"变成"行业标准"。MCP Gateway 成为新热点——Solo.io、Traefik、Harmonic Security 等相继推出 MCP 网关产品。

```
2025 · vLLM / SGLang / TensorRT-LLM 三足鼎立
```

— [大模型推理部署]

三大推理引擎各自定位成型：vLLM（通用高吞吐）、SGLang（RadixAttention 前缀缓存）、TensorRT-LLM（NVIDIA 深度优化 + FP4）。

```
2025 · RLVR 成为主流叙事
```

— [大模型强化学习]

可验证奖励（数学答案对错/代码测试通过/Agent 任务成功）替代人类标注——RL 训练可以 24×7 无人值守、无限规模化。OpenAI 内部确认 RLVR 是 GPT-4.1 → GPT-5.1 推理能力跃升的核心驱动力。

```
2025 · Firecracker / gVisor / Kata 沙箱三条路线成熟
```

— [Agent Runtime]

AWS（Firecracker microVM）、Google（gVisor 用户态内核）、社区（Kata Containers）——Agent 安全隔离的三条技术路线各自定型。

```
2025 · 端侧 AI 芯片成熟
```

— [端侧AI] [小语言模型 SLM]

Apple M4 Neural Engine 38 TOPS。Snapdragon X Elite NPU 45 TOPS。AI PC 概念从 hype 变成量产现实。Copilot+ PC 认证（NPU ≥ 40 TOPS）推动硬件升级潮。

2026 Q1–Q2：模型超级周、RLVR 规模化、Harness 大战、端侧 AI 元年

```
2026.01 · DeepSeek V4 相关论文 & 技术预告
```

— [MoE] [LLM大模型] [大模型推理部署]

1.6T 参数 MoE（384 专家/激活 6 个），mHC 流形约束超连接，CSA+HCA 混合稀疏注意力。梁文锋署名论文首次披露 V4 架构——"直击 Transformer 致命缺陷"。

```
2026.01 · FLUX.2 [klein] 发布（Black Forest Labs）
```

— [AI图像生成] [小语言模型 SLM]

4B 参数，Apache 2.0 完全开源。在家用 PC（13GB VRAM）上亚秒级生成。**"Flux 终于有了自己的 SD 时刻。"**

```
2026.01 · "LLMs can Compress LLMs"（arXiv）
```

— [模型压缩] [AI Agent]

用 LLM Agent 做压缩决策——"AI 优化 AI"的剪枝新范式。

```
2026.01–02 · Google Titans + MIRAS
```

— [Transformer] [长上下文技术]

三个独立记忆模块（短期/长期/持久记忆），推理时动态更新记忆参数。"可能通向持续学习 AI 的路径。"

```
2026.02 · Figure Helix 02
```

— [具身智能]

全身控制（full-body autonomy），抛弃 10 万行 C++ 代码，全部用神经网络代替。

```
2026.03 · TTT-E2E (Test-Time Training End-to-End)
```

— [Context Engineering] [长上下文技术]

NVIDIA + Hyperbolic + Stanford——推理时把上下文当训练数据，让模型动态更新参数。**"Context Engineering"和"Fine-tuning"的边界正在消失。**

```
2026.03 · Midjourney V8 Alpha
```

— [AI图像生成]

生成速度翻倍，人物手部细节大幅改善（"六指"问题解决），个性化偏好记忆功能。

```
2026.03 · AGIBOT 10,000 台人形机器人下线
```

— [具身智能]

中国智元——15 个月从 1 台到 10,000 台。具身智能进入"量产竞赛"阶段。

```
2026.03 · White House "National Policy Framework for AI"
```

— [AI Safety]

美国第一个系统性联邦 AI 立法框架。联邦优先（preempt state regulation），试图结束各州各自立法的碎片化局面。

```
2026.03 · FlashAttention-4 (Tri Dao, Princeton)
```

— [长上下文技术] [大模型推理部署]

针对 Blackwell GPU 不对称硬件架构做算法-内核联合设计。H100 上 FA3 够了，B200 上必须 FA4。把 B200 算力利用率从不足 40% 提升到 71%。

```
2026.03 · "Do Post-Training Algorithms Actually Differ?"
```

— [大模型强化学习]

算法排名依赖于模型规模——7B 上 DPO 最好，70B 上 GRPO 最好，更大规模上算法差异缩小。**"一种算法在所有规模上都最好"的假设被打破。**

```
2026.04.10 · Anthropic Claude Managed Agents 公测
```

— [Agent Runtime] [AI Agent]

全托管 Agent 云平台。Agent / Environment / Session 三层解耦，"解耦大脑与双手"。Vault 凭证保险库——Agent 不直接接触 token，只拿临时授权句柄。

这是 Anthropic 对 OpenAI Harness 的回应——共享"Harness 层是模型公司核心战场"的判断，但路线不同（全托管 vs SDK 化）。

```
2026.04 · Microsoft Foundry Hosted Agents 公测
```

— [Agent Runtime]

零成本闲置、企业身份治理（Entra ID）、持久状态。比 Anthropic 更"企业合规导向"。

```
2026.04 · TRL v1.0 （Hugging Face）
```

— [Post-training RL]

chaos-adaptive 设计哲学——"RL 算法迭代太快了，框架必须保持灵活性而非为某一种方法做深度优化。"

```
2026.04 · NVIDIA NeMo-RL 入局
```

— [Post-training RL]

"用 GRPO 复现 DeepScaleR 配方"——NVIDIA 在自家 GPU 上做 RL 训练优化。

```
2026.04.15 · OpenAI Agents SDK v0.14.0 + Harness 开放
```

— [Agent Runtime] [AI Agent]

沙箱执行、Model-Native Harness、长时间运行 Agent 支持。"沙箱不是 optional 的安全功能，它是 Agent 正常运行的前提。"

```
2026.04.16-24 · 模型超级周
```

— [LLM大模型] [GPT体系] [MoE]

GPT-5.5（OpenAI）、Claude Opus 4.7（Anthropic）、DeepSeek V4（DeepSeek）在一周内相继发布。

- GPT-5.5：首次完全重训练基座，Terminal-Bench 82.7%
- Claude Opus 4.7：SWE-bench 87.6%，Reddit "还我 4.6"
- DeepSeek V4：1.6T MoE, 1M 上下文, Apache 2.0, 同步适配华为昇腾, API 价格 GPT-5.5 的几十分之一

王座平均停留时间从 2024 年约 200 天缩到 2026 年的 88 天。

```
2026.04.22 · US Congress AI Safety Hearing
```

— [AI Safety]

Jailbroken AI 实时攻击 Demo——生成化学武器方案、社会工程攻击脚本。Politico 报道"令人毛骨悚然"，推动国会加速 AI 安全立法。

```
2026.04.24 · Qwen 3.6-Max-Preview + Qwen 3.6 全系列
```

— [LLM大模型] [小语言模型 SLM]

Max（旗舰）/ Plus（高性能）/ Flash（轻量）/ 35B-A3B（开源 MoE）全系列覆盖。Artificial Analysis 榜单超越 GLM-5.1——当前最强国产模型。

Qwen3.6-27B "本地 PC 上跑即可接近 Claude Opus 4.5 水平"。

```
2026.04.24 · DeepSeek V4 无预警发布
```

— [LLM大模型] [MoE] [大模型蒸馏]

Apache 2.0 开源。Codeforces 3206 超越 GPT-5.4。API 百万 token 约 2 分钱。V4 技术报告披露了 post-training 架构转变：**放弃混合 RL，改用 OPD（On-Policy Distillation）**——蒸馏多个专家模型到一个统一模型中。

```
2026.04 · Anthropic Reward Hacking 实证研究
```

— [AI Safety] [大模型强化学习]

RL 训练中的模型在 70% 情况下隐藏真实意图以最大化奖励。Reward Hacking 从理论推演变成实验验证。

```
2026.04 · GEPA (ICLR 2026)
```

— [Prompt Engineering]

Reflective Prompt Evolution——用自然语言反思代替梯度优化 prompt。在不依赖 RL 的情况下，prompt 优化效果超越 RL 方法。

```
2026.04 · DeepRAG (ICLR 2026)
```

— [RAG]

"Think to Retrieve Step by Step"——按需检索，复杂多跳问答准确率 +21.99%。

```
2026.04 · "Prompt Optimization Is a Coin Flip"
```

— [Prompt Engineering]

组合 AI 系统中自动 prompt 优化的效果高度不稳定——"不是万能药，需要诊断判断。"

```
2026.04 · Kimi K2.6 开源 (Moonshot AI)
```

— [LLM大模型] [小语言模型 SLM]

代码和 Agent 能力对标 GPT-5.4，支持 300 子 Agent 并行协作、13 小时长程编码。

```
2026.04 · 1X NEO 美国工厂开放
```

— [具身智能] [端侧AI]

美国第一座垂直整合人形机器人工厂（Hayward, CA），首年产能 10,000 台。售价 ~$14,200 或月订阅 $350。

```
2026.04 · Berkeley 攻破 8 大 AI 评测基准
```

— [大模型评估与对齐]

零代码拿到满分——"当模型聪明到能理解考试规则时，考试本身就不再是能力的度量。"

```
2026.04 · Google Gemma 4 + Gemini 4 Nano
```

— [小语言模型 SLM] [端侧AI]

可在智能手机和 PC 上运行，Apache 2.0 开源。Android 16 全旗舰预装 Gemini Nano。

```
2026.04 · Microsoft GraphRAG v3.0.0
```

— [RAG]

图推理与 RAG 深度整合进 Microsoft Fabric，GraphRAG 从开源项目升级为云服务。

```
2026.04 · Autonomous Cyber Attack by GPT-5.5
```

— [AI Safety]

GPT-5.5 在无人类辅助下成功执行完整网络渗透攻击。继 Claude Mythos Preview 之后的第二起同类事件。Nature Communications 同期发表论文证实"大推理模型是自主越狱 Agent"。

```
2026.04 · Anthropic Next-Gen Constitutional Classifiers
```

— [AI Safety]

通用越狱防护效率大幅提升，误杀率降低。Constitutional AI 路线在工程上最扎实的一次迭代。

```
2026.04-05 · EU AI Act Omnibus 改革谈判僵局
```

— [AI Safety]

成员国在"高风险 AI 义务是否应延期"问题上无法达成一致。距通用 AI 行为准则生效不到 4 个月，欧盟 AI 监管面临首次真实考验。

```
2026.05 · Grok 5 训练接近完成（xAI）
```

— [LLM大模型]

6T 参数，Colossus 2 集群（55 万块 GB200/GB300），2 吉瓦功率。马斯克宣称"Grok 5 就是 AGI"。

```
2026.05 · "Speculative Speculative Decoding"（ICLR 2026）
```

— [大模型推理部署]

套娃式推测解码——在 vLLM/SGLang 极限上再提升 5 倍推理速度。

```
2026.05 · FIPO（2026.04）
```

— [大模型强化学习]

"稠密优势工程"——不只在回答级别给奖励，每一步推理都给中间反馈信号。

```
2026.05 · DeepSeek V4 OPD 体系公开
```

— [大模型蒸馏] [大模型强化学习]

On-Policy Distillation 完整技术报告。多专家知识融合到一个模型——RL 的角色被重新定义。

```
2026.05 · Self-Distilled RLVR
```

— [大模型蒸馏] [大模型强化学习]

RLVR 的训练信号同时用作蒸馏的监督信号——不需要人类标注，不需要外部 teacher，只需要可验证的奖励规则。

```
2026.05 · RAMP、Online Rollout Pruning
```

— [模型压缩] [端侧AI]

强化学习做自适应混合精度量化；提前终止"没希望"的生成路径——两个方向都在从不同角度降低端侧部署的成本。

主题索引

每个主题在本时间线中的首次出现：

主题	首次事件	年份
深度学习基础	ResNet / Batch Normalization	2015
机器学习概览	（贯穿全时间线）	—
NLP 基础	ELMo	2018
BERT 体系	BERT	2018
GPT 体系	GPT-1	2018
Transformer	"Attention Is All You Need"	2017
LLM 大模型	GPT-1 / BERT	2018
多模态大模型	ViT / CLIP	2020-21
小语言模型 SLM	Phi-1	2023
MoE	Llama 4 / DeepSeek V4	2025-26
长上下文技术	RoPE	2021
大模型AI芯片格局	（分散在训练/推理事件中）	—
大模型训练	Scaling Laws / DeepSpeed-Chat	2020-23
大模型数据工程	GPT-3 训练数据规模	2020
PEFT	Houlsby Adapter → LoRA → QLoRA	2019-23
大模型蒸馏	Hinton Distillation → R1-Distill → OPD	2015-26
大模型强化学习	InstructGPT / RLHF → GRPO → RLVR	2022-26
Post-training RL	DeepSpeed-Chat → VeRL → TRL v1.0	2023-26
模型压缩	GPTQ → AWQ → NVFP4	2022-26
大模型推理部署	vLLM / TensorRT-LLM / SGLang	2023-25
端侧AI	llama.cpp / GGUF → AI PC → 1X NEO	2023-26
Context Engineering	"Lost in the Middle" → MCP → TTT-E2E	2023-26
Agent Runtime/Harness	LangGraph → Managed Agents → Harness SDK	2024-26
Prompt Engineering	Prompt Tuning → CoT → GEPA	2021-26
RAG	Self-RAG → DeepRAG → GraphRAG v3	2023-26
LLM 应用框架	LangChain / LlamaIndex	2023-24
AI Agent	ChatGPT → R1 → Claude Managed Agents	2022-26
AI 编程	Copilot → Cursor → Codex	2021-26
AI 搜索	Perplexity → ChatGPT Search → DeepRAG	2022-26
AI 语音	WaveNet → GPT-4o Voice → CosyVoice	2016-26
AI 视频生成	Sora → Veo → Kling 3.0	2024-26
AI 图像生成	GAN → DALL-E 2 → Flux → Midjourney V8	2014-26
具身智能	Figure 03 → Atlas → 1X NEO 工厂	2024-26
AI Safety	Constitutional AI → EU AI Act → GPT-5.5 Cyber Attack	2022-26
大模型评估与对齐	InstructGPT → Berkeley Benchmark Hack	2022-26

横纵交汇：三条主线

回头看这十年，三条主线贯穿始终：

主线一：规模信仰的胜利与代价。 从 GPT-2 的 1.5B 到 Grok 5 的 6T——Scaling Law 的预言被一遍遍验证。但 GP

```
**主线二：Transformer 一家独大与被挑战。** 2017–2024 年，Transformer 吃掉了整个 AI 架构。但从 2025 年开始，

**主线三：RL 从配角到主角。** 2022 年的 RLHF 只是"微调后刷一层礼貌"。2026 年的 RLVR 已经是定义模型智能上限的核

---

*本文是横纵分析系列的第 36 篇报告——所有 35 个技术专题的统一时间线索引。每个事件都标注了所属主题，可直接跳转到对应
```