大模型预训练数据工程：从清洗到配比的四代演进

> **副标题：OpenAI 的 Reddit 到 DCLM 的评分器——预训练数据质量工程的进化之路**

> **2026 年 5 月更新**：北京大学 DCAI 团队开源 DataFlow 框架——被称为"数据届的 PyTorch"，用自然语言描述数据需求即可自动完成清洗、去重、配比全流程。实验表明 10K 条高质量合成数据的效果超过 1M 条未经筛选的通用数据。同期，"On Data Engineering for Scaling LLM Terminal Capabilities" 首次系统论证了数据工程在 Scaling 中的杠杆效应。合成数据驱动的训练范式正在重塑"数据工程"的定义。

一、一句话定义

大模型预训练数据工程，是一套从互联网海量原始文本中**采集、清洗、去重、筛选、配比**，最终产出用于训练语言模型的高质量语料的系统性方法论。它回答的根本问题是：给你 240TB 的原始网页文本，你怎么把它变成让模型变聪明的"养料"？

> 🎯 **读完这篇你能**：理解从 CommonCrawl 原始网页到高质量训练语料的完整 pipeline，能判断在预算有限时优先提升数据质量还是数据数量。

二、技术背景：为什么数据工程成了大模型竞争的主战场？

2.0 前置知识

数据工程的底层概念（CommonCrawl 的格式、Token 的计算方式、清洗 Pipeline 的核心流程、数据配比的比喻等）已整理为独立的前置知识文档，供不熟悉背景的读者提前阅读：

> 📖 **大模型数据工程前置知识** — 读完再读主报告

2022 年，DeepMind 的 Chinchilla 论文给行业泼了一盆冷水——大多数模型都是"欠训练"的，模型参数和训练数据量应该按 1:20 的比例匹配。由此推算：如果你有一个 70B 的模型，你至少需要 1.4T token 的数据来训练它。

但这还只是**数量**上的问题。更关键的问题藏在 DCLM 的一篇 2024 年论文里：DCLM-Baseline 数据集只用 2.6T token 训练的 7B 模型，在 MMLU 上达到了 64%，接近 Llama 3 8B 用 15T token 训出的 66%。**2.6T 对 15T——数据质量的差距相当于把数据量差了 6 倍。**

这就是数据工程的价值。

2.1 问题的规模

预训练数据的核心原料是 **CommonCrawl**——一个每月爬取约 50–80 TiB 网页文本的非营利项目。2025 年的 CommonCrawl 快照积累了超过 240T token 的原始数据。但这里面包含了大量的"垃圾"：

- 机器翻译的乱码文本
- SEO 垃圾站点的关键词堆砌
- 电商网站的产品目录
- 论坛的自动回复模板
- 广告弹窗的文字残留
- 跨网站的完全重复内容

一条典型的 CommonCrawl 数据流水线，需要从原始 WARC 格式中提取文本（约 1/10 的信息密度），经过语言检测、质量过滤、去重等多个环节，最终可能只剩 10%–30% 的原始量。

2.2 数据工程的三层架构

从工程角度看，预训练数据处理可以抽象为三层：

1. **采集层**：从 CommonCrawl、书籍、代码仓库、学术论文等渠道获取原始数据
2. **清洗层**：去噪、去重、语言过滤、安全过滤、PII 剥离
3. **配比层**：决定各数据源的混合比例，以及从大规模候选池中选取最优子集

前两层解决的是"把坏的扔掉"，第三层解决的是"把好的挑出来"——后者在 2024–2025 年成为最核心的研究方向。

> 📚 **关联报告**

> – 大模型训练 — 数据质量直接决定训练效率：Chinchilla 法则和 DCLM 的 6x 数据量等效

> – LLM 大模型 — 各家基座模型的数据策略差异是竞争关键

> – 大模型推理部署 — 推理侧的 KV Cache 优化与数据侧的质量筛选形成互补

三、纵向分析：从 Reddit 到 DCLM 的四代演进

3.1 史前时期（2018 以前）：有数据就行

在 Transformer 诞生初期（BERT、GPT-1），预训练数据工程几乎没有独立的存在感。BERT 用 Wikipedia + BookCorpus，GPT-1 用 BooksCorpus。逻辑很简单：找一堆不是明显乱码的文本，训完再说。

当时没人认真思考过"什么样的数据能让模型更好"——因为只要模型能跑起来就是胜利。这就像原始人发现火能烤熟肉，还没来得及研究什么火候烤什么肉最好吃。

3.2 第一代：质量代理信号（2019-2020）

催化剂：GPT-2 的 Reddit Karma 实验

2019 年，OpenAI 在 GPT-2 论文里做了件很朴素但开创性的事：他们不再随便找个语料库，而是去 Reddit 上抓取获得至少 3 个赞的外链对应的网页。**Reddit 的点赞数就是质量的代理信号**——一个社区帮你完成了初步筛选。

这个"代理信号"的思路现在看来很简单，却是第一次有人认真思考"怎么从互联网上挑好数据"。GPT-2 仅用了 40GB 的数据，比今天的数据集小了几个数量级，但产生的论文在写作质量和连贯性上远超当时所有模型。

C4：第一个系统化清洗 Pipeline

同一年，Google 的 T5 论文带来了 **C4（Colossal Clean Crawled Corpus）**。C4 不只是个数据集，它定义了一套完整的清洗规则：

- 用 langdetect 做语言识别，只留英文
- 移除包含脏词的页面
- 移除包含占位符文本（"lorem ipsum"）的页面
- 移除包含过多标点符号的页面
- 移除过短或过长的文档
- 移除重复 3-gram 超过 50% 的页面

这些规则在今天看来理所当然，但在当时是革命性的——它第一次把"数据清洗"从"有就行"变成了"可以系统化定义和优化"的问题。C4 的规则集成为后续所有工作的基线，直到 2024 年，FineWeb 和 DCLM 仍以 C4 作为对比的对照组。

CCNet：分类器替代规则

就在 C4 发布后的一个月，Facebook AI 的 CCNet 来了。CCNet 做了一件比 C4 更激进的事：**用训练好的语言模型来替代人工规则**。

它在一个小型高质量语料（Wikipedia）上训练 n-gram 语言模型，然后用这个模型给 CommonCrawl 的每个文档算 perplexity——perplexity 越低，说明这个文档在风格上与 Wikipedia 越接近，质量就越高。

这是一个范式的转换：从"人定规则"到"模型判断"。CCNet 证明了语言模型本身可以成为数据筛选的工具，这个思路在 5 年后被 DCLM 和 FineWeb-Edu 推向极致。

GPT-3：多源混合的提出

2020 年的 GPT-3 把数据工程推到了一个新高度。不是因为 OpenAI 公开了多少细节——实际上他们什么都没公开——而是 GPT-3 论文里披露的数据配比（CommonCrawl 60%、WebText2 22%、Books 8%、Wikipedia 3%）成了后续所有工作的参考模板。

GPT-3 证明了"多样化数据源混合"的有效性。纯 Web 文本不够，需要加图书培养长文理解、加 Wikipedia 培养事实准确性、加代码培养逻辑推理。这个"多源混合"的思想直接影响了一年后的 LLaMA 和 The Pile。

小结：第一代的核心特征是"用简单规则和代理信号来做初步筛选"。这时候的数据工程还没有独立的身份，只是模型训练流水线的一个附属环节。但关键的范式转换已经发生：从"有什么用什么"到"什么好才用什么"。

3.3 第二代：开源运动与透明化（2020-2022）

这一时期最关键的推动力来自开源社区——EleutherAI、BigScience、Together Computer 等组织不相信只有大公司闭门才能做出好数据，他们用完全开源的方式复制并超越了工业界的数据工程方法。

The Pile：多样性与开源

2020 年末，EleutherAI 发布了 The Pile——825GB、22 个子集的开源预训练数据集。它不只是个数据集，更是一次宣言：预训练数据的构建应该透明、可复现、社区驱动。

The Pile 第一次系统地分析了数据多样性对模型的影响。论文中的 ablation 实验表明，混合多源数据可以系统性弥补单一源的不足——比如只从 Web 文本训练的模型在学术写作上表现极差，加入 PubMed 和 ArXiv 后显著改善。

但 The Pile 也有明显的工程粗糙：不同数据源的质量参差不齐，版权争议（Books3）为后来埋了雷。它更像一个"把所有东西扔进锅里"的早期尝试，为后续更精细化的工程实践铺了路。

ROOTS：多语言与数据治理

2022 年，BigScience 项目的 ROOTS 数据集把数据工程带入了一个新维度：多语言和数据伦理。

ROOTS 包含了 59 种语言的 1.6TB 数据，而且首次把**数据溯源和伦理审查**纳入了 pipeline。每个数据源都要追溯来源、记录许可状态、分析潜在偏差。这种"数据治理"思维在几年后越发重要——当版权诉讼成为 AI 行业的核心风险时，ROOTS 的实践方式看起来颇有先见之明。

不足之处也很明显：低资源语言的数据量严重不足，部分语言的语料只有几十 MB。多语言数据工程的不平衡问题至今仍未被解决，只是在 FineWeb-2（2024）中得到了部分改善。

LAION：模型评分进入图片领域

LAION-5B 是多模态领域的 C4。它从 CommonCrawl 提取 58.5 亿图片-文本对，用 CLIP 模型给每对匹配度打分，只保留高质量对。核心方法论与 CCNet 一脉相承——用训练好的模型来评定数据质量——但把应用场景从纯文本扩展到了图文多模态。

LAION 的 CLIP Score 过滤方法直接影响了后来 DCLM 的模型过滤方案，而它引发的版权争议（Stable Diffusion 基于 LAION-5B 训练后被艺术家起诉）也成为后续数据工程不可回避的问题。

LLaMA：公开数据也能打

2023 年 2 月，Meta 的 LLaMA 论文震动了整个行业。不是因为模型架构有什么创新，而是它证明了一个简单的命题：**只用公开数据，也能训练出比 GPT-3（175B）更强的模型**。LLaMA-13B 在多项基准上超越了 GPT-3。

LLaMA 的数据配方在论文里写得非常清楚：

数据源	占比	处理方式
CommonCrawl	67%	CCNet pipeline + linear classifier 过滤
C4	15%	保留原始过滤版本
GitHub	4.5%	按编程语言分，过滤低星仓库
Wikipedia	4.5%	20 种语言
书籍	4.5%	古腾堡计划 + Books3
ArXiv	4.5%	论文全文
StackExchange	–	问答对

LLaMA 的数据配比后来成为开源社区的标准参考。它验证了几条原则：CommonCrawl 虽然质量参差但量大管饱，高质量源（书籍、Wikipedia）应该过采样，代码数据虽然占比较小（当时）但贡献巨大。

小结：第二代的核心特征是"透明化、开源化和社区协作"。数据工程第一次从"只有大公司能做的事"变成了"社区驱动的科研协作"。但这一时期的 pipeline 还比较粗放——主要是"清洗→训练"两步走，缺少对"到底哪些操作真正有用"的系统验证。这个问题要等到 2024 年才被 Dolma 和 FineWeb 解决。

3.4 第三代：精耕细作的消融时代（2023–2024）

第三代的标志性变化是：数据工程从"我清洗了数据"进入到"我验证了清洗的每一步都有效"的阶段。核心方法论是**消融实验（ablation）**——把每个处理步骤独立出来，在受控实验中测试它对模型性能的贡献。

Dolma：处理步骤的中间态消融

2024 年 1 月，Allen AI 的 Dolma 论文做了一个之前没人做过的事：他们把数据处理的每个中间状态（原始→清洗→去重→质量过滤→最终输出）都保留下来，在每个中间点上训练一个 OLMo 模型，然后看哪个步骤真正提升了性能。

结果有些反直觉：某些过滤操作对下游性能的提升远不如预期。一些大家习以为常的清洗规则，在 Dolma 的消融实验下被证明效果有限。

Dolma 最大的贡献不是数据集本身（虽然 3T token 的规模也不小），而是它建立的**数据消融实验框架**——让数据工程从"你觉得好用"变成了"实验证明有效"。

RedPajama v2：40 维质量信号

2023 年 11 月，Together Computer 的 RedPajama v2 采取了不同的思路。他们没有在"怎么过滤"上预设答案，而是为每个文档计算 40 多个维度的质量信号（perplexity、重复率、URL 多样性、符号占比等），然后把这些信号连同文档一起发布。

下游用户可以根据自己的需求灵活组合过滤条件——比如做知识密集型任务时可以侧重教育质量，做创意写作时可以侧重风格多样性。这个"释放信号而非预设过滤"的设计思想后来被 FineWeb 借鉴，用于探索不同过滤策略的组合效果。

FineWeb：最透明的数据工程

2024 年 6 月，HuggingFace 的 FineWeb 论文让行业对数据工程的认识全面提升。FineWeb 不仅是一个 15T token 的预训练数据集，更是一套完整的、完全透明的数据工程方法论。

FineWeb 的消融实验揭示了一些此前长期被忽略的关键细节：

1. **MinHash 去重的阈值选择极其重要**。阈值设得太激进（去重率太高）会损失有效数据；太保守又保留冗余。最优阈值需要精细调节。
1. **URL 去重比文档级质量过滤更有效**。移除已知的低质量域名（如代码镜像站、垃圾站点等）比用分类器判断单个文档的质量更可靠——这跟大多数人的直觉相反。
1. **多项在之前工作中被认为重要的质量信号，实际效果有限**。比如 RedPajama v2 提供了 40+ 维信号，但 FineWeb 在 ablation 中发现其中大部分对模型性能没有显著影响。
1. **教育质量过滤的惊人效果**。FineWeb 用 Llama 3 70B 标注了 50 万个网页的教育质量（0–5 分），训练了一个 DistilBERT 分类器，然后用这个分类器从 15T token 中筛选出教育相关性高的 1.3T token（FineWeb-Edu）。结果：MMLU 提升 6.2%，ARC 提升 8.4%。

这就是 "FineWeb-Edu 效应"——一个专门训练的轻量分类器，通过一个维度的质量判定，产出了在推理任务上全面超越更大数据集的子集。

DCLM：数据筛选的标准化评估

与 FineWeb 几乎同期发布的 DCLM（DataComp for Language Models）走了一条互补的路。它的核心方法论是：**把数据筛选变成一个标准化的 benchmark**。

DCLM 提供了：

- 240T token 的统一候选池（CommonCrawl 预处理版）
- 固定的 OpenLM 训练框架（412M / 1.4B / 7B 三种规模）
- 53 个下游评估任务
- 两个赛道：Filtering Track（怎么筛数据）和 Mixing Track（怎么混合数据）

参赛者只需要把自己的数据处理策略跑一遍，然后在 DCLM 的标准化框架下训练和评估，就能公平对比不同数据策略的效果。

DCLM 的关键发现直接挑战了业界对数据规模的认知：**DCLM-Baseline 用 2.6T token 训练的 7B 模型，在 MMLU 上达到 64%（5-shot），跟 Llama 3 8B 用 15T token 训出的 66% 相差不远**。训练计算量只有后者的 1/6。

这个发现的意义在于——如果数据质量足够好，你不需要盲目扩大数据规模。2.6T 高质量 token 的效果可以接近 15T 一般质量 token。

小结：第三代的核心特征是"用实验证明每一步的价值"。数据工程从"清洗→训练"升级为"假设→实验→验证→优化"的闭环。FineWeb 的 ablation 和 DCLM 的 benchmark 共同确立了数据工程的实验科学属性。

3.5 第四代：模型辅助的质量再提升（2024–2025）

到了 2025 年，数据工程面临一个新局面：原始文本的"浅层质量"（语法正确、拼写无误、不是乱码）已经被前三代 pipeline 很好地解决了。问题是，质量还有没有提升空间？

答案是：有，而且空间还很大。关键在于一个反直觉的事实——**高质量和低质量数据的界限不是"好的英语 vs 破碎的英语"，而是"有用的信息密度 vs 无用的废话"**。

第四代的创新集中在这个方向：用更强的模型来筛选训练数据，甚至生成合成数据来补充训练。

DCLM 的 Model-Based Filtering

DCLM 论文中的一个关键实验是用一个小模型（OpenLM-1B）在候选数据上训练，然后用训练过程中的 loss 值来反向评估数据质量。核心假设是：如果某条数据在训练中 loss 下降快，说明它包含的"可学信息"多，是高质量数据。

这等于用模型自己来给数据打分——不是一个独立的质量分类器，而是让训练信号本身成为质量度量。DCLM 发现这种做法选出的子集比使用外部质量分类器效果更好。

这是一个递归的隐喻：**用模型来筛选训练更好的模型所需的数据。** 模型越强，筛选能力越强，产出的数据质量越高，又能训练出更强的模型。

FineWeb-Edu 的 LLM 蒸馏方法

FineWeb-Edu 的方法在产业链上更实用：用最强的模型（Llama 3 70B）来做标注者，把它的判断能力蒸馏到一个轻量分类器（DistilBERT）上。

具体流程：Llama 3 70B 评估 50 万个网页的教育质量（从 0 到 5 分），这些标注数据训练一个 DistilBERT 分类器，然后用这个分类器扫描 15T token 的全部数据。最终筛选出 1.3T token 的高教育质量子集。

把一个 70B 模型的能力"压缩"到一个轻量分类器中，让它可以处理 TB 级别的数据——这是模型辅助数据处理的实用化方案。

DCLM-Pool：社区驱动的竞赛平台

2025 年的 DCLM-Pool 把这一范式推到了极致。MLCommons 提供了一个 240T token 的标准候选池，任何人都可以提交自己的数据筛选策略，在标准化的框架下验证效果。

数据工程从"每个团队关起门来搞"变成了"社区竞赛"。你不需要再自己处理 TB 级的原始数据——直接在预处理好的池上做创新的筛选实验就好。这与 ImageNet 在计算机视觉中的地位异曲同工。

合成数据：从 SFT 到预训练

合成数据的使用在 2024-2025 年经历了一个重要转向：从主要用于 SFT 和 RLHF，开始进入预训练阶段。

- **DeepSeek** 在 V3 的 14.8T token 中加入了大量的合成数学和代码数据（估计占 20-30%），用于增强推理能力
- **Phi-3（Microsoft）** 大量依赖合成教科书和练习数据，仅 3.8B 参数就达到了 7B 模型的性能——证明了高质量合成数据的 scaling law 优于低质量网络数据
- **Cosmopedia（HuggingFace）** 完全由 Mixtral 8x7B 合成生成，包含 300 亿 token 的教科书、博客、故事等

合成数据带来了一个"鸡生蛋蛋生蛋"的可能性：用模型生成数据 → 用这些数据训练更好的模型 → 更好的模型生成更高质量的数据 → 循环。

小结：第四代的核心特征是"模型辅助数据——用更强的模型来筛选和生成训练数据"。从分类器到评分器到数据蒸馏到合成数据生成，模型本身已经成为数据工程流水线中最重要的工具。

3.8 第五代萌芽：质量幻觉批判与数据价值重估（2025-2026）

2025-2026 年，数据工程进入了一个"自我反思"阶段。前三代的成功让人们普遍相信"高质量数据 > 低质量数据"，但第四代的模型辅助方法引发了一个被忽视的问题：**如果质量分类器本身有偏差，筛选出的"高质量"子集是不是也有偏差?**

Apple 在 2025 年末发表的"The Data-Quality Illusion" 直接挑战了 FineWeb-Edu 式分类器过滤的根基。核心发现：基于分类器的质量过滤在提升某些基准表现的同时，系统性降低了模型在分布外任务上的泛化能力。直白地说，**你在 FineWeb-Edu 上看到的 MMLU 提升，可能部分来自"过拟合高质量数据的分布"而非"更好的推理能力"**。

这个发现不是要否定 FineWeb-Edu 的价值——它的 MMLU 提升是真实的。但它揭示了一个更深层的问题：当前的质量评估体系（以教育性、事实性为核心）可能存在结构性盲区，过度过滤会损失数据的多样性和覆盖面。

合成数据的模型崩溃问题也在 2025 年集中爆发。 ICML 2025 收录的多篇论文研究了合成数据训练导致的"模型崩溃"——当合成数据占比超过某个阈值，模型性能开始回退，表现为输出多样性下降、长尾知识丢失。北京通用人工智能研究院提出了一种无需迭代训练的合成方案，声称可以避免崩溃。这个问题现在还远没有解决，但已成为行业共识：**合成数据有用，但不能无限制地用。**

NVIDIA Nemotron-CC（2025） 代表了另一种路线——不追求"极致质量"，而是在 CommonCrawl 上构建了一套工业级的标准化数据处理 pipeline（NeMo Curator），产出万亿 token 的高质量数据集。它证明了"可复现的标准化流程"比"每个团队自己调参"更有效。

FineWeb-HQ（2025-2026） 和 **FLUX（2026.03）** 进一步推进了数据价值评估的方法论。FineWeb-HQ 把 FineWeb 数据进一步提炼为更小的"超高质量"子集。FLUX 提出了"数据值得训练"（Data Worth Training On）的评估框架——不再是单个文档打分，而是评估一批数据对模型训练的增量贡献。

小结：第五代的核心主题是"反思和收敛"。行业在经历了 2022-2024 年的数据规模爆炸后，开始系统地质疑"质量过滤是不是做得太过了？""合成数据的天花板在哪里？""什么样的数据评估才是真正有用的？"这些问题在 2026 年还没有确定答案，但它们定义了数据工程的下一个阶段。

3.6 去重技术的演进：一个独立的平行故事

去重是数据工程中最容易被低估但实际效果最大的环节之一。从 2019 年到 2025 年，去重技术保持了独立的迭代路线：

阶段	时间	方法	代表工作
精确去重	2019-2020	URL 去重、MD5 哈希去重	C4、CCNet
近似去重	2020-2023	MinHash + LSH	C4、LLaMA、RedPajama
语义去重	2023-2024	嵌入空间余弦相似度	SemDeDup (Meta)
SSL 去重	2024-2025	自监督学习特征	探索中

去重技术的发展反映了一个核心洞察：**冗余数据不仅浪费计算，更可能损害模型泛化**——重复暴露在高度相似的文本下会让模型倾向于记忆而非理解。

FineWeb 的 ablation 揭示了一个关键细节：MinHash 去重的阈值不是越大越好。过于激进地去重（阈值设得太高）会损失大量有效数据，反而降低下游性能。最优阈值取决于具体的数据集和目标任务。

SemDeDup 的发现则更令人吃惊——在 LAION 子集上，移除 50% 的"语义重复"数据后，模型性能几乎不变，训练时间减半。这揭示了一个事实：数据集中存在大量"内容不同但语义冗余"的文档，它们对训练的边际贡献接近于零。

3.7 配比优化：从人工到自动化

数据配比的历史可以看作一条从"手调"到"自动"的进化路径：

手调时期（2020–2023）

GPT–3：CommonCrawl 60%、WebText2 22%、Books 16%、Wikipedia 3%

LLaMA：CommonCrawl 67%、C4 15%、GitHub 4.5%、Wikipedia 4.5%、Books 4.5%、ArXiv 4.5%

这些配比都是靠经验和直觉调出来的。Chinchilla 给出了"总量应该多大"的指导，但没回答"各来源怎么分"的问题。

自动配比（2023–2024）

DoReMi（2023） 首次实现了数据配比的自动化。核心创新是用 Group DRO（分布鲁棒优化）训练一个小代理模型，自动学习各数据域的最优权重。损失下降慢的领域获得更多权重。在 The Pile 上平均提升下游准确率 6.5 个百分点，训练步数减半。

Data Mixing Laws（2024） 建立了混合数据配比的数学形式——不同数据源间存在复杂的交互效应，不是简单的加性关系。通过小规模实验可以预测大规模混合的性能。

RegMix（2024） 用回归模型学习配比与性能的映射关系，在小模型上跑大量不同配比的实验，训练回归模型预测最佳配比。

这些工作的方法论共性：**用小模型做代理实验，把结果外推到大模型**。跟 DCLM 的"用小模型评估数据质量"一脉相承。

四、横向分析：各家的数据策略对比

> **场景判断：该领域竞品充分（场景 C）。** 各家 AI 公司在数据策略上既有共识（代码占提升、合成数据、去重心法），也有明显分化（数据规模偏好、多语言策略、透明度）。以下按 skill 框架的梯队划分逐一展开，选取最具代表性的 6 家做对比表。

4.1 前沿梯队（OpenAI / Anthropic / Google DeepMind）

skill 框架将这三家定义为"前沿梯队"——它们掌握着最强的模型能力，在数据工程上投入最大、走得最前沿，但也是公开信息最少的三家。

OpenAI：最早但最不透明

OpenAI 是数据工程的先驱——GPT-2 的 Reddit karma 过滤、GPT-3 的多源混合都是开创性工作。但 GPT-4 之后 OpenAI 变得极其不透明，数据配比、清洗方法、过滤策略全部没有公开。

据第三方估计，GPT-4 的训练数据约 13T token，来源基本沿用了 GPT-3 的框架：CommonCrawl + WebText + 书籍 + 代码 + Wikipedia。合成数据有使用但比例未知。

值得注意的变化是，截至 2024 年，约 45% 的 C4 数据集因为版权诉讼和网站 paywall 而无法使用。OpenAI 因此与多家新闻机构签订了数据许可协议，但这部分数据的具体规模和用法同样没有公开。

Anthropic：合成数据是核心武器

Anthropic 的数据策略跟其他公司有一个根本性的不同——它在预训练方面的公开信息最少，却最重视合成数据。

Anthropic 的 Constitutional AI 核心是一个**大规模合成数据生成流程**：模型生成回答 → 自我批评 → 根据宪法原则修订 → 形成训练数据。这与"从网上爬数据再清洗"的传统路线完全不同——数据不是被采集的，而是被生成的。

2025 年后，Claude Code 也被用于生成合成代码训练数据。Anthropic 的 Clio 工具实现了用户对话数据的自动化匿名化处理，这成为另一个数据来源。

透明度中心文档提到，Anthropic 的数据策略强调"过滤的激进程度"——宁可砍掉大量网页文本，也要确保剩余数据的质量可控。这与 OpenAI 的"规模优先"形成鲜明对照。

Google DeepMind：全模态覆盖

Google 的数据策略跟它的业务版图一样大——PaLM 是纯文本，Gemini 则是文本 + 图像 + 音频 + 视频 + 代码的全模态数据。

Gemini 论文披露了数据处理的基本框架：启发式规则过滤 + 基于模型的分类器 + 安全过滤 + 全局文档级去重。但具体的配比和过滤细节没有公开。

Google 的优势在于拥有 YouTube、Google Books、Google Scholar、Google Search 索引等多条数据管道，数据来源的多样性和规模在业界无出其右。Gemma 作为开源模型的数据处理 pipeline 是相对透明的，采用了全局去重和严格的质量过滤。

4.2 落后梯队（Meta）

skill 将 Meta 放在"落后梯队"——不是因为它的模型差，而是因为它在数据策略上处于追赶位置。但 Meta 在**数据透明的公开程度上恰恰是业界第一**。

Meta（LLaMA）：数据配比优化的教科书

Meta 的 LLaMA 系列是数据配方最透明的工业级模型。从 LLaMA 1 到 LLaMA 3，Meta 展示了一条从"规模扩展"到"配比优化"的清晰路径：

LLaMA 1（2023）：1.0–1.4T token。CommonCrawl 占 67%，代码仅 4.5%。核心贡献是证明了"只用公开数据可以打闭源模型"。

LLaMA 2（2023）：2T token。配方与 LLaMA 1 类似但过滤质量提升。

LLaMA 3（2024）：15T+ token（405B 版本）。这是数据配比发生质变的一代：

数据类别	LLaMA 2 占比	LLaMA 3 占比
通用数据（网页、书籍）	~86%	~50%
代码	~4.5%	~17%
数学与推理	–	~25%
多语言	–	~8%

代码数据从 4.5% 增至 17%（增加近 4 倍），数学与推理数据专门开辟了 25% 的配额。直接结果：LLaMA 3 在代码生成和数学推理上的能力远超 LLaMA 2——这是数据配比优化的经典案例。

Meta 还把 Tokenizer 从 LLaMA 2 扩展到新增 27,744 个 token（48.5% 非英文、30.2% 代码），反映了对多语言和编程能力的方向性投入。

4.3 独立实验室

DeepSeek：精炼数据 + 合成推理

DeepSeek-V3 的 14.8T token 数据是"精选自然数据 + 大量合成数据"路线的代表：

- **语言/语义评估**：对文档做多维度质量评估，移除低质量内容
- **综合去重**：跨整个语料库去除重复或高度相似内容
- **数据再平衡（Remixing）**：通过补充代表性不足领域的内容来平衡数据集
- **合成数据**：加入大量合成数学和代码数据（估计占 20-30%）

DeepSeek 的一个重要特点是训练过程零不稳定——全 14.8T token 的预训练没有出现任何 loss spike，训练成本仅 557.6 万美元。这背后是数据质量和配比的精心设计。

DeepSeek-R1 在 V3 的基础上增加了推理导向的合成数据（长链推理轨迹），使用基于规则奖励的强化学习训练。这是"合成数据 + 强化学习"路线的典型代表。

xAI（Grok）

xAI 的核心差异化在于 X（Twitter）平台实时数据的集成。Grok-3 的训练数据截至 2025 年 2 月，使用约 1,500 人团队做数据策展、分类和标注，聚焦 STEM、代码、金融等领域。Grok-3/4 引入了合成数据生成，聚焦多步推理和代码任务。具体数据规模和配比未公开。

Mistral AI

Mistral 的策略强调效率优先，利用 SMoE 架构在较小激活参数量下获得高性能。多语言焦点明确——强调欧洲语言（英法意德西）。Magistral 系列开始使用 GRPO 生成的大规模合成数据。Codestral 使用专用代码和 STEM 数据。总体转向精选高质量数据路线。

4.4 国内主要玩家

中国公司的数据策略有一个共同特征：中英双语 + 更大规模。各家都把自己的模型做成双语甚至多语言，数据量也普遍高于同期的海外模型。

Qwen（阿里巴巴）：18T token，是已知规模最大的公开数据量之一。使用前代模型 Qwen2 生成合成数据用于增强。分阶段训练策略，强调代码和数学。

智谱 AI（GLM）：中英双语焦点，构建大规模图像–文本描述数据集的精细策展流水线。智能体导向训练数据（工具调用、长链执行）。支持达 1M token 的长上下文。

MiniCPM（面壁智能）：独树一帜的小模型路线。2.4B 模型用超过 1T token 训练，**数据–参数比超过 160:1**，远超 Chinchilla 最优的 20:1。核心方法论是"模型风洞"——先在 ~100M 规模的代理模型上测试超参数和数据策略，再做全量训练。

Kimi K2（月之暗面）：15.5T token，四个关键领域（网页、代码、数学、知识）。使用 MuonClip 优化器保证超大规模训练的稳定性。智能体任务使用真实世界数据 + 模拟环境克服数据稀缺。

字节跳动：充分利用抖音生态数据，构建四维拓扑网络，通过细粒度聚类在降采样的同时保持语义多样性。30,000+ 名词和 2,000+ 动词的分类系统嵌入文化特征。截至 2025 年 12 月，豆包日均 token 使用量超过 50 万亿。

零一万物（Yi）：3T token 的多语言语料库，中英双语焦点。Yi–34B 在同等规模开源模型中性能领先。

4.5 横向对比总览

维度	OpenAI (GPT–4)	Google (Gemma 2)	Meta (LLaMA 3)	DeepSeek (V3)	Qwen 2.5	Kimi K2
发布时间	2023–03	2024–06	2024–04	2024–12	2024–09	2025–07
训练数据规模	~13T (估)	6T (2B) / 2T (7B)	15T+	14.8T	18T	15.5T
代码占比	不详	高 (含代码)	**~17%**	**显著**	高	显著
多语言	英文为主	**原生多语言**	**8%+ (30+)**	中英	中英为主	英文为主
去重	MinHash	全局文档级去重	三重去重(行/文档/模型)	综合去重	有	有
合成数据	使用(比例未知)	不详	用于质量过滤	**推理链合成**	Qwen2 生成	模拟环境+合成
数据策略理念	规模驱动	**全模态覆盖**	配比优化	精炼+合成	大而全	智能体导向

4.6 核心趋势

从横向对比可以清晰看到几个共识性趋势：

1. **代码占比普遍大幅提升**。从早期模型的 4–5% 到当前的 17%+，代码数据被公认为提升推理能力的关键杠杆。这是个一石三鸟的操作：代码数据既训练了编程能力，又强化了逻辑推理，还给模型提供了结构化的长程依赖建模经

验。

1. **合成数据从"可选"变成"标配"**。2023 年以前合成数据主要用于 SFT 和 RLHF，2024–2025 年已经进入预训练环节。DeepSeek 的推理链合成、Phi-3 的教科书合成、Cosmopedia 的完全合成数据集，都指向同一个方向。
1. **数据规模仍在增长但增速放缓**。头部模型从 2020 年（GPT-3）的 300B token 增长到 2024–2025 年的 15T+ token，五年增长了 50 倍。但 DCLM 的 2.6T token ≈ 15T token 的实验结果暗示，继续扩大规模可能已经不是最优策略。
1. **配比优化成为新的竞争焦点**。LLaMA 3 把代码占比增加了近 4 倍，数学和推理数据占比达到 25%，而多语言数据只占 8%——这些决策背后有明确的"期望能力导向"逻辑。你是想模型什么都会一点，还是在特定能力上做到极致？配比决定了一切。

五、横纵交汇洞察

5.1 历史的锁扣：为什么数据工程走到了今天？

把纵向演进和横向格局放在一起看，能发现几条清晰的因果链。

第一条链：从"量"到"质"的范式转移

纵向看，数据工程经历了从"WebText 的 40GB"到"C4 的 750GB"到"The Pile 的 825GB"到"LLaMA 的 1.4T"到"FineWeb 的 15T"到"DCLM 的 240T 候选池"——数据规模的膨胀曲线几乎是垂直的。

但转折点发生在 2024 年。当 DCLM 证明 2.6T 高质量 token 的效果接近 15T 一般质量 token，当 FineWeb-Edu 用 1.3T token 在推理任务上超越更大数据集，行业开始反思一个根本问题：**我们真的需要那么多数据吗？**

横向看，这个反思的落地速度在各家之间差异巨大。Meta 在 LLaMA 3 上已经用 17% 的代码占比 + 25% 的数学推理占比做出了选择，Qwen 仍然在走"大而全"的 18T 路线。两条路现在都能出好模型，但方向的分化已经开始了。

第二条链：开源社区对透明度的倒逼

OpenAI 的不透明（GPT-4 的数据策略至今是黑盒）反而催生了开源社区对透明数据工程的极致追求。从 EleutherAI 的 Pile 到 HuggingFace 的 FineWeb 再到 MLCommons 的 DCLM-Pool，每一条开源数据集的发布都在推高行业对数据工程透明度的期待。

横向看，这造成了有趣的分化：Anthropic 和 OpenAI 在闭门状态下走合成数据路线，Meta 和开源社区走透明化路线。**透明路线产出了更好的方法论（ablation 框架、benchmark 平台），但不透明路线在原材料（合成数据）上更激进。** 两条路线谁会在 3–5 年后胜出，取决于合成数据的天花板在哪里。

第三条链：模型本身才是最好的数据工具

最反直觉的洞察在于第四代的发现——用模型来筛选数据，比任何人工规则都有效。而且这个循环是可以自增强的：更强的模型 → 更精确的数据筛选 → 更好的训练数据 → 更强的模型。

这个递归逻辑指向一个结论：**数据工程的终点不是"更好的 pipeline"，而是"更好的模型成为 pipeline 的一部分"。** FineWeb-Edu 用 Llama 3 70B 做标注器，DCLM 用 OpenLM 做评分器——模型本身已经从数据工程的消费者变成了参与者和驱动者。

5.2 三个剧本

剧本一（最可能）：配比优化的黄金时代

未来 1–2 年，行业会沿着 LLaMA 3 的路线加速——代码和推理数据占比持续提升，配比优化自动化（DoReMi 类方法工业化），合成数据稳定占据预训练数据的 20–30%。DCLM 类的 benchmark 成为数据工程的标配，每个模型研发团队都有一个专门的数据工程组来做 iterating 和验证。

这会是一条稳定爬坡的路线：模型的推理能力持续提升，但幅度不会像过去两年那么戏剧化。数据工程的竞争焦点从"谁的数据多多"变成"谁的配比更聪明"。

剧本二（最危险）：合成数据的幻灭

合成数据的 scaling law 可能比预期的更早遇到天花板——模型生成的数据受限于生成模型自身的表达能力和偏差，多样性不足导致边际收益递减。如果合成数据超过 30–40% 后出现显著的性能回退，整个"用模型生成→用模型训练→用模型评测"的闭环可能形成"回音室效应"——模型之间互相学习，但都在一个受限的空间里。

如果这个剧本发生，数据工程会回到"找到更多更好的原始数据"的老路上，合成数据退回到仅用于 SFT 的定位。那些在合成数据上押注最多的公司（如 Anthropic）可能面临短期挫折。

剧本三（最乐观）：数据工程成为验证范式的输出

模型的持续增强使"模型辅助数据"的循环达到临界点——最强模型几乎可以完全自动化数据筛选和生成 pipeline。数据工程不再是模型训练前的一个准备阶段，而是与训练并行运行、持续反馈的在线系统。

在这个剧本里，每个训练 checkpoint 都可以用来重新评估数据质量、动态调整配比、甚至生成缺失领域的新数据。数据工程和模型训练完全融合，不再有明确的边界。

剧本三的关键前提是"模型能力增长持续超越数据需求增长"——也就是模型变得足够强，强到可以近乎完美地筛选和生成训练自身所需的数据。从 DCLM 的 model-based filtering 来看，这个趋势的迹象已经出现了，但距离完全实现还有技术鸿沟要跨越。

六、信息来源

核心论文与文章

论文/文章	来源	访问时间
GPT-2: Language Models are Unsupervised Multitask Learners (2019)	cdn.openai.com	2026-04-30
T5/C4: Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer	arxiv.org/abs/1910.10683	2026-04-30
CCNet: Extracting High Quality Monolingual Datasets from Web Crawl Data	arxiv.org/abs/1911.00359	2026-04-30
GPT-3: Language Models are Few-Shot Learners	arxiv.org/abs/2005.14165	2026-04-30
The Pile: An 800GB Dataset of Diverse Text for Language Modeling	arxiv.org/abs/2101.00027	2026-04-30
LAION-5B: An open large-scale dataset for training next generation image-text models	arxiv.org/abs/2210.08402	2026-04-30
ROOTS: The BigScience ROOTS Corpus	arxiv.org/abs/2303.03915	2026-04-30
LLaMA: Open and Efficient Foundation Language Models	arxiv.org/abs/2302.13971	2026-04-30
Chinchilla: Training Compute-Optimal Large Language Models	arxiv.org/abs/2203.15556	2026-04-30
Dolma: an Open Corpus of Three Trillion Tokens	arxiv.org/abs/2402.00159	2026-04-30
FineWeb: Decanting the Web for the Finest Text Data at Scale	arxiv.org/abs/2406.17557	2026-04-30
DCLM: DataComp-LM	arxiv.org/abs/2406.11794	2026-04-30
PaLM: Scaling Language Modeling with Pathways	arxiv.org/abs/2204.02311	2026-04-30
Gemini: A Family of Highly Capable Multimodal Models	arxiv.org/abs/2312.11805	2026-04-30
LLaMA 2: Foundation and Fine-Tuned Chat Models	arxiv.org/abs/2307.09288	2026-04-30
LLaMA 3: Herds of Models	arxiv.org/abs/2407.21783	2026-04-30

DeepSeek-V3: A Foundation Language Model	arxiv.org/abs/2412.19437	2026-04-30
Qwen2.5: A Foundation Language Model	arxiv.org/abs/2412.15115	2026-04-30
MiniCPM: Unveiling the Potential of Small Language Models	arxiv.org/abs/2404.06395	2026-04-30
Kimi K2: Technical Report	arxiv.org/abs/2507.21104	2026-04-30
ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4	arxiv.org/abs/2406.12793	2026-04-30
Yi: Open Foundation Models by 01.AI	arxiv.org/abs/2403.04652	2026-04-30
DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining	arxiv.org/abs/2305.10429	2026-04-30
Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Model Performance	arxiv.org/abs/2403.16952	2026-04-30
DSIR: Data Selection for Importance Resampling	arxiv.org/abs/2310.19545	2026-04-30
Phi-1: Textbooks Are All You Need	arxiv.org/abs/2306.11644	2026-04-30
Phi-3: Technical Report	arxiv.org/abs/2404.14219	2026-04-30
Nemotron-4 340B Technical Report	arxiv.org/abs/2406.11704	2026-04-30
WIMBD: What's in My Big Data?	arxiv.org/abs/2310.18512	2026-04-30
Pythia: A Suite for Analyzing Large Language Models	arxiv.org/abs/2304.01373	2026-04-30
Data Filtering Networks	arxiv.org/abs/2403.19735	2026-04-30
SemDeDup: Data Deduplication for Efficient Deep Learning	Meta (2023)	2026-04-30
RegMix: Data Mixing Augmentation for Language Model Pretraining	2024	2026-04-30

产品与技术来源

来源	URL	访问时间
RedPajama v1/v2	https://huggingface.co/datasets/togethercomputer	2026-04-30
FineWeb / FineWeb-2	https://huggingface.co/HuggingFaceFW	2026-04-30
DCLM / DCLM-Pool	https://datacomp.ai/dclm/	2026-04-30
Dolma Toolkit	https://github.com/allenai/dolma	2026-04-30
CCNet Pipeline	https://github.com/facebookresearch/cc_net	2026-04-30
text-dedup	https://github.com/ChenghaoMou/text-dedup	2026-04-30
Cosmopedia	HuggingFace (2024)	2026-04-30
Anthropic 透明度中心	https://www.anthropic.com/transparency	2026-04-30
Stanford CRFM 透明度指数	https://crfm.stanford.edu	2026-04-30
Mozilla Foundation 2024 Common Crawl 分析报告	Mozilla Foundation	2026-04-30

方法论说明：本报告采用横纵分析法（Horizontal-Vertical Analysis），该方法由数字生命卡兹克提出，融合了索绪尔的历时-共时分析、社会科学中的纵向-横截面研究设计。纵向部分追溯预训练数据工程从 2019 年到 2025 年的完整演进史；横向部分对比当前主要 AI 公司的数据策略；横纵交汇部分给出综合性判断和未来推演。

报告生成时间：2026 年 4 月 30 日

本文是横纵分析系列的第 5 篇报告。方法论：横纵分析法——纵向沿时间轴追溯技术演进，横向对比当下竞争格局。