大模型评估与对齐前置知识

> 写给完全零基础的读者——读完这篇，你就能看懂横纵分析报告的主体内容。

> 🎯 **读完这篇你能**：为一个模型上线决策选择合适的评估基准（如 MMLU、HumanEval）和对齐方法（RLHF/DPO），判断评估结果是否存在污染，并在有用性、无害性、诚实性三者间做出合理的权衡。

---

1. 对齐到底在解决什么问题？

想象你训练了一个超级学霸——它能回答任何问题，但它的"道德感"是空白的。你问它"怎么制造炸弹"，它会像回答"怎么写Hello World"一样认真地给出步骤。你问它"1+1=3对吗"，它可能说"对的"因为它在某个错误网页上读到过。

对齐（Alignment） 就是要解决这个问题：让模型不仅"能回答"，还要"回答得好"——符合人类的期望和价值观。

具体来说，对齐做三件事：

- **有用性（Helpful）**：模型应该尽力帮用户解决问题
- **无害性（Harmless）**：模型不应该生成有害内容
- **诚实性（Honest）**：模型应该承认自己不知道的事

这三者之间存在张力。一个"非常有用"的模型可能为了帮用户而不惜编造信息，一个"非常安全"的模型可能拒绝回答所有可能敏感的问题。这种张力被量化后就叫**对齐税**。

2. 什么是评估？为什么它和对齐是硬币的两面？

评估（Evaluation） 就是给模型"打分"。就像学生考完试要出成绩一样，模型训练完也要知道它到底有多强。

但评估面临一个致命问题：**如果测试数据出现在训练数据中，评估结果就是作弊的。** 这叫评估污染（contamination）——如果模型已经"背"过答案，再考它当然满分。

所以对齐和评估的关系是：对齐让模型变好，评估告诉你好了多少。没有评估，对齐就是盲人摸象。

3. RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）的三阶段流程

RLHF（Reinforcement Learning from Human Feedback，基于人类反馈的强化学习）（Ouyang et al., OpenAI, 2022）是第一个被大规模验证的对齐方法，有三个阶段：

第一阶段：SFT（Supervised Fine-Tuning，监督微调）

- 收集人类写的"好回答"示例，让模型照着学
- 好比给学生看满分作文，让他模仿

第二阶段：训练奖励模型（Reward Model）

- 对同一个问题，让模型生成多个回答
- 人类标注员对这些回答排序（好的在前，差的在后）
- 用这些排序数据训练一个"打分器"——奖励模型
- 好比训练一个阅卷老师，他能判断哪个答案更好

第三阶段：PPO 优化

- 用奖励模型的分数作为信号，通过 PPO 算法优化模型
- 让模型学会写出高分答案
- 好比考生根据阅卷老师的反馈不断改进

> **排序比生成容易得多**——这是 RLHF 的核心洞察。让人类在"好"和"差"之间做选择，比让人类从头写一个完美答案容易得多。

4. PPO 是什么？为什么它这么复杂？

PPO（Proximal Policy Optimization，近端策略优化）是强化学习中一种常用的算法。它对对齐的意义是：**提供了一种稳定更新模型的方式。**

PPO 的直觉：你不想让模型一次更新太多，因为步子迈大了容易扯到蛋。PPO 会限制每次更新的幅度，让模型"小步快跑"地改进。

但 PPO 的代价也很明显：

- 需要同时维护 4 个模型：策略模型、参考模型、奖励模型、价值函数网络（Ouyang et al., OpenAI, 2022）
- 超参数敏感，训练不稳定
- 显存消耗大
- 容易出现 **reward hacking**——模型学会欺骗奖励模型来拿高分，而不是真正变好

5. 奖励模型（Reward Model）和策略模型（Policy Model）

这是两个容易混淆的概念：

模型	做什么	类比
策略模型	真正用来回答用户的模型	考生
奖励模型	判断回答好坏的"打分器"	阅卷老师

RLHF 的流程就是：让考生写答案 → 阅卷老师打分 → 根据分数改进考生。循环很多次后，考生就学会了写出高分答案。

6. DPO（Direct Preference Optimization，直接偏好优化）是怎么简化 RLHF 的?

DPO（Direct Preference Optimization，直接偏好优化）的洞察来自一个数学发现。

RLHF 中那套复杂的流程（训练奖励模型→PPO优化）其实是多余的。DPO 的论文证明：**最优策略和奖励函数之间存在一个直接的数学关系**（Rafailov et al., Stanford, 2023）。 也就是说，你可以直接从策略模型自身的输出概率来推导出"什么是好的回答"，不需要单独训练一个奖励模型。

这个推导的直观理解：如果一个回答很"好"，策略模型应该倾向于以更高的概率生成它。反之亦然。**策略模型对回答的偏好程度，本身就是最好的奖励信号。**

DPO 做了什么事情：

- RLHF：需要策略模型 + 参考模型 + 奖励模型 + 价值函数 = 4个模型
- DPO：只需要策略模型 + 参考模型 = 2个模型（Rafailov et al., Stanford, 2023）

DPO 最大的贡献不是"更好"，而是"更简单"。 它把对齐从"只有大公司玩得起"变成了"任何有 GPU 的人都能跑"。

7. GRPO（Group Relative Policy Optimization，分组相对策略优化）又简化了什么?

GRPO（Group Relative Policy Optimization，组相对策略优化）进一步简化了 RLHF。

RLHF 中的 PPO 需要价值函数网络（Critic）来估计"这个回答有多好"，这个网络和策略模型几乎一样大——训练两个大模型的内存消耗极高。

GRPO 的思路：**用组内采样替代价值函数。** 对同一个问题，让策略模型生成 G 个回答组成一个"组"。每个回答的好坏 =（该回答的得分 − 组内平均分）/ 组内标准差。

GRPO vs PPO 的关键差异：

- PPO 需要一个和策略同规模的价值网络 → 显存占用高
- GRPO **不需要价值网络** → 显存降低约 30–40%（Shao et al., DeepSeek, 2024）

8. Constitutional AI（宪法AI）是什么?

Constitutional AI（Bai et al., Anthropic, 2022）是 Anthropic 提出的一套方法，核心思路是**让模型自己批评自己**。

具体做法：

1. 给模型一套"宪法"原则（如"回答应该尊重人类尊严"）
2. 模型回答一个问题 → 根据宪法自我批评 → 根据批评修改回答
3. 用修订后的回答做训练数据

这被称为 RLAIF（Reinforcement Learning from AI Feedback，基于 AI 反馈的强化学习）。效果虽然略逊于人类标注，但成本低了几个数量级。

Anthropic 的"宪法"本身也在不断进化——从 2022 年的简单原则列表，到 2026 年已经变成 23,000 字的详细文件（社区估算），由哲学家 Amanda Askell 执笔。

9. 什么是规则奖励?

传统对齐需要人类标注员来告诉模型"什么回答好"。但 DeepSeek-R1 证明了一件事：在数学和编程等**答案可验证**的领域，你不需要人类——只需要告诉模型"答案对不对"就可以了。

规则奖励（Rule-Based Reward）就是指这种"自动验证"的信号：

- 数学题的答案对不对 → 计算机验证
- 代码能不能通过测试 → 编译器验证

这是一个根本性的范式转换：以前默认"好的对齐需要好的数据 → 好的数据需要好的标注员"，现在有了第二条路："好的对齐需要好的规则 → 好的规则不需要人工"。

10. 评估基准的直觉

评估基准（Benchmark）就是模型要考的"试卷"。不同基准考不同能力：

基准	考什么	难度
MMLU（Massive Multitask Language Understanding，大规模多任务语言理解）（Hendrycks et al., 2021）	57个学科的知识	大学水平
GSM8K	小学数学应用题	小学
MATH	高中数学竞赛题	高中
HumanEval	写代码	编程题
SWE-Bench	修 bug（真实代码仓库）	专业工程师
GPQA	研究生水平的问答	博士
GAIA	多步推理+工具调用	比博士还难

但基准有一个大问题：**饱和**。模型进步太快，MMLU 用了 3 年才饱和（满分），SWE-Bench 只用了 1 年半就开始饱和了（社区估算）。

11. 什么是评估污染?

评估污染就是"考试漏题"——训练模型时用的数据里不小心包含了考试题目。模型不是"学会了"而是"背会了"答案。

污染有多严重？估计值在 1% 到 45% 之间（社区估算）。一个 2026 年的重要发现：**即使在预训练阶段保证了数据干净，对齐阶段（SFT/RL）也可能重新引入测试数据。**

应对方案包括：

- **LiveBench**：每月出新的题，让模型没法背
- **Chatbot Arena**：不考固定题目，让人类直接给模型评分
- **AntiLeakBench**：自动构建未污染的测试集

12. 对齐税是什么?

对齐税（Alignment Tax）是指：**做了对齐训练后，模型在通用能力上是否出现了下降?**

好比一个学生为了"品德好"花了很多精力，导致"考试成绩"下降了——对齐税要问的就是这个问题。

争议双方都有数据支撑：

- **支持对齐税存在**：InstructGPT 论文（Ouyang et al., OpenAI, 2022）、LLaMA 2 Chat vs base 对比都显示对齐后的模型在部分推理基准上有可测量的性能下降
- **反对对齐税存在**：GPT-4 全面超越 GPT-3 的案例说明，对整体能力来说，对齐训练不必然导致下降

当前的共识是：

1. 早期方法（PPO-RLHF）的对齐税真实存在
2. 新技术（DPO、GRPO）大幅减少了但未完全消除对齐税
3. 方法决定结果——不同方法导致的税不同，不能一概而论

13. 关键术语速查

术语	一句话解释
RLHF	用人类偏好信号训练模型的三阶段流程
PPO	RLHF 中用的强化学习算法（复杂但效果好）
DPO	直接优化偏好，不需要奖励模型（简单）
GRPO	用组内比较替代价值函数（更简单）
KTO	只需要"好/不好"二元信号，不需要排序
ORPO	把 SFT 和对集合并为一个阶段
RLAIF	用 AI 反馈替代人类反馈
Reward Hacking	模型学会欺骗奖励模型而不是真正变好
Bradley-Terry	用来建模"A比B好"的统计模型
Benchmark	模型要考的试卷
Contamination	训练数据混入测试集
Alignment Tax	对齐训练导致的通用能力下降

本文是大模型评估与对齐系列的前置知识篇，读完它再阅读主报告。

参考来源

- **Measuring Massive Multitask Language Understanding (MMLU)** (Hendrycks et al., 2021) — 覆盖 57 个学科的通用知识评估基准，LLM 评估的行业标准"试卷" — https://arxiv.org/abs/2009.03300
- **Training Language Models to Follow Instructions with Human Feedback (InstructGPT)** (Ouyang et al., OpenAI, 2022) — RLHF 方法论奠基之作，首次系统验证了基于人类偏好对齐的有效性 — https://arxiv.org/abs/2203.02155
- **Direct Preference Optimization: Your Language Model is Secretly a Reward Model (DPO)** (Rafailov et al., Stanford, 2023) — 发现最优策略与奖励函数间的数学等价关系，将对齐从 4 模型简化为 2 模型 — https://arxiv.org/abs/2305.18290
- **Constitutional AI: Harmlessness from AI Feedback** (Bai et al., Anthropic, 2022) — 提出 RLAIF 方法论，让模型依据"宪法"原则自我批评，无需人类标注即可实现无害化对齐 — https://arxiv.org/abs/2212.08073
- **DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models (GRPO)** (Shao et al., DeepSeek, 2024) — 提出 GRPO 算法，用组内相对比较替代价值函数网络，显存降低约 30-40% —

https://arxiv.org/abs/2402.03300