端侧 AI / 设备端部署横纵分析报告

> 从"云端 API 是唯一答案"到"3B 模型在手机上实时跑"——端侧 AI 如何在两年内从"技术可能"变成了"产业必然"，又如何让隐私保护从"政策口号"变成了"硬件承诺"。

一、一句话定义

端侧 AI（On-Device AI）是在智能手机、PC、IoT 设备等用户终端上直接运行 AI 模型的技术体系。它的核心主张是一个与云端 AI 完全相反的逻辑：**AI 不应该把用户数据送到云端——AI 应该跑到用户设备上来。**

2026 年被业界称为"端侧 AI 元年"——Qualcomm Snapdragon X2 Elite 的 NPU 算力突破 80 TOPS、Apple Intelligence 深度整合进 iOS 27/macOS 26、Gemini Nano 成为 Android 16 标配、Copilot+ PC 生态成熟——端侧 AI 从芯片到 OS 到应用的全栈能力首次形成了闭环。

> 🎯 **读完这篇你能**：理解端侧 AI 和云端 AI 的分工边界，能评估一个 AI 应用是否适合端侧部署，能根据芯片平台（Apple Silicon / Snapdragon / Intel Core Ultra / Ryzen AI）做出正确的模型选型和性能预期。

二、技术背景

2.1 端侧 AI 的四大驱动力

隐私需求：用户越来越不愿意把聊天记录、照片、文档上传到云端 AI 服务器。Apple 的"隐私是第一优先级"战略在消费者端侧 AI 市场建立了强大的品牌叙事。

延迟不可容忍：云端 API 的网络延迟（200–1000ms）对实时场景（语音助手、AR 翻译、自动驾驶辅助）来说太慢了。端侧推理延迟可以降到 10–50ms。

离线可用：飞机上、地铁里、地下室——不是所有地方都有稳定的网络连接。端侧 AI 必须能独立工作。

成本规模化：每一百万次 API 调用都要付费。端侧 AI 的推理成本是零——电费和芯片折旧分摊到每次推理可以忽略不计。

2.2 端侧 AI 的技术栈

```
应用层：Siri, Gemini Nano, Copilot+ PC 应用
   ↕
模型层：SLM (3B-7B), Gemma 4, Phi-4, Qwen 3B, Gemini Nano
   ↕
运行时层：Apple Core ML, Qualcomm AI Engine, ONNX Runtime, llama.cpp
   ↕
芯片层：NPU (Neural Processing Unit) + GPU + CPU 协同
   ↕
OS 层：iOS 27, Android 16, Windows 11 Copilot+
```

三、纵向分析：从"不可能"到"标配"

3.1 前 NPU 时代：所有推理都在云端（2018–2022）

2018 年 BERT 发布时，在手机上跑 BERT 是"一件很慢但能做"的事——CPU 推理一个 110M 参数的模型需要几百毫秒到几秒。LLaMA 的出现让端侧推理从"慢"变成了"不可能"——没有专用 AI 芯片的手机，连 7B 模型的 FP16 权重都加载不了（需要 14GB 显存）。

这个阶段的端侧 AI 本质上是"把云端 API 封装成 App"。Siri、Google Assistant、Alexa——所有的智能都在云端完成，端侧只负责录音和播放。

3.2 NPU 的崛起：芯片层革命（2023–2024）

Apple Silicon 率先在 M 系列芯片中集成了专用 Neural Engine。M1（2020）的 Neural Engine 算力 11 TOPS，M4（2024）达到 38 TOPS。Apple 的 Foundation Models 框架让开发者可以用标准 API 调用端侧 AI 能力。

Qualcomm Snapdragon X 系列（2024）是 Windows on ARM 的转折点。Snapdragon X Elite 的 Hexagon NPU 达到 45 TOPS，让 AI PC 的概念从 hype 变成了可量产的现实。

Intel Core Ultra（Meteor Lake, 2024）首次在 x86 平台集成了 NPU（11.5 TOPS），2025 年的 Lunar Lake 和 2026 年的 Panther Lake 分别提升到 48 TOPS 和 100+ TOPS。

AMD Ryzen AI 系列在 2024–2026 年将 NPU 算力从 16 TOPS 提升到 80+ TOPS。

3.3 端侧 AI 生态成熟（2025–2026）

Apple Intelligence（2025.06 WWDC） 是迄今为止最大规模的端侧 AI 消费级部署。每次 iOS 更新都在扩展端侧模型的覆盖范围——从通知摘要到邮件生成到图像编辑。2026 年的 WWDC 预计将发布 Siri 的端侧大模型升级。

Gemini Nano（2025–2026） 是 Google 端侧 AI 的核心载体。Nano 在 Android 16 中从 Pixel 独占扩展到所有搭载支持 NPU 的 Android 旗舰。Gemini 4 Nano（2026.04）与 Gemma 4 同步发布——Google 的端侧策略是"Gemma 开源 + Nano 系统预装"双线推进。

AI PC / Copilot+ PC：2025–2026 年，Microsoft 的 Copilot+ PC 认证（要求 NPU ≥ 40 TOPS）催生了一波硬件升级潮。Qualcomm Snapdragon X2 Elite（80 TOPS）、Intel Panther Lake（100+ TOPS）、AMD Ryzen AI 300（80 TOPS）三家在 AI PC 赛道激烈竞争。

NPU-first 运行时：llama.cpp 在 2026 年添加了对 Hexagon NPU / Apple Neural Engine 的原生支持。npurun 等项目让开发者可以在 NPU 上直接跑 LLM 推理——NPU 推理比 GPU 推理省电 3-5 倍。

Apple Foundation Models：Apple 在 2025 年底开放了 Foundation Models 框架的开发者 API，允许第三方 App 直接调用 iOS 内置的端侧 AI 模型（文本生成、图像生成、语音识别）。

3.4 2026 Q1-Q2：端侧 AI 的关键里程碑

- **Snapdragon X2 Elite 量产**（2026.02）：80 TOPS NPU，支持在笔记本上本地运行 14B-27B 模型。第一批搭载 X2 Elite 的设备（ASUS Zenbook A16、Samsung Galaxy Book 6 Edge）已上市。
- **Gemini 4 Nano 发布**（2026.04）：支持 140+ 种语言的离线翻译和语音交互。
- **Copilot+ PC 生态突破**：2026 年 Q1 全球 AI PC 出货量首次超过传统 PC。
- **LLM Inference at the Edge 基准**（2026.03）：首篇系统性对比移动端 NPU/GPU/CPU 在持续负载下的性能效率论文。
- **端侧 Agent**：CES 2026 上多家厂商展示了在本地运行的 Agent——端侧 AI 从"被动问答"走向"主动执行"。

四、横向分析：2026 年端侧 AI 芯片对比

4.1 旗舰芯片 NPU 算力

芯片	厂商	NPU 算力	GPU	内存带宽	代表设备	发布时间
Apple A18 Pro	Apple	38 TOPS	6-core	78 GB/s	iPhone 18 Pro	2025.09
Apple M4 Ultra	Apple	38 TOPS	80-core	800 GB/s	Mac Studio	2025
Snapdragon X2 Elite	Qualcomm	80 TOPS	Adreno	136 GB/s	ASUS Zenbook A16	2026.02
Snapdragon 8 Gen 4	Qualcomm	45 TOPS	Adreno	68 GB/s	Samsung S26 Ultra	2025.10
Intel Panther Lake	Intel	100+ TOPS	Arc (Xe3)	128 GB/s	Dell XPS 2026	2026
AMD Ryzen AI 300	AMD	80 TOPS	RDNA 3.5	128 GB/s	Lenovo Yoga 2026	2026

4.2 不同硬件可运行的模型大小

设备类型	可用内存	可跑模型	量化方式	典型速度
旗舰手机 (12GB+)	6–8GB 可用	3B–7B	Q4_K_M	10–30 tok/s
旗舰手机 (16GB+)	10–12GB 可用	7B–14B	Q4_K_M	8–20 tok/s
AI PC (32GB)	24GB 可用	14B–27B	Q4_K_M	15–40 tok/s
AI PC (48GB+)	40GB 可用	27B–70B	Q4/Q5	10–30 tok/s
Mac Studio (128GB+)	100GB+	70B–100B+	Q4/Q5/Q8	20–50 tok/s

4.3 OS 层端侧 AI 支持对比

OS	内置 AI	开发者 API	SLM 支持	开放度
iOS 27	Apple Intelligence	Foundation Models API	✅	Apple 生态内
Android 16	Gemini Nano	AI Core API	✅	OEM 可自定义
Windows 11 Copilot+	Copilot	Windows Copilot Runtime	✅	最开放
macOS 26	Apple Intelligence	Foundation Models API	✅	同 iOS

五、横纵交汇洞察

5.1 "AI PC"是 PC 市场 10 年来最大的创新催化剂

2026 年 Q1，全球 AI PC 出货量首次超过非 AI PC。这不是因为消费者特别爱 AI——而是因为所有新发布的 PC 都自带 NPU。AI 能力正在从"卖点"变成"标配"。

5.2 端侧 + 云端 = 混合 AI 才是终局

单一依赖云端或端侧都不是最优解：

- **简单问题（翻译、摘要、聊天）→ 端侧**：低延迟、零成本、隐私保护
- **中等难度（代码生成、文档分析）→ 端侧优先，云端 fallback**
- **高难度（复杂推理、长 Agent 任务）→ 云端**：需要最强的模型

Apple Intelligence 和 Gemini Nano 的架构都采用了这种混合模式——用户通常感知不到"切换"的发生。

5.3 端侧 AI 的最大瓶颈不是计算，是内存

2026 年，NPU 算力（80 TOPS）已经不是 7B 模型推理的瓶颈。真正的瓶颈是**内存带宽**——移动端的 LPDDR5 内存带宽（68–136 GB/s）比桌面端 GDDR6（可达 1TB/s+）差了一个数量级。手机跑 AI 的显存带宽瓶颈短期内无法突

破。

六、信息来源

论文/文章	来源	访问时间
LLM Inference at the Edge: NPU, GPU, CPU Trade-offs	arxiv.org/abs/2603.23640	2026-05-01
Snapdragon X2 Elite 发布	qualcomm.com (2026.02)	2026-05-01
Gemini 4 Nano / Gemma 4 发布	google.com (2026.04)	2026-05-01
Apple Foundation Models 开发者文档	developer.apple.com	2026-05-01
The On-Device LLM Revolution	semiengineering.com (2026)	2026-05-01
The Small Model Revolution 2026: 3B on Raspberry Pi	dev.to (2026)	2026-05-01
AI PC 出货量 2026 Q1 数据	various	2026-05-01

本文是横纵分析系列的第 29 篇报告。与小语言模型、模型压缩互为补充：SLM 讲"什么模型能跑"，模型压缩讲"怎么让模型变小"，端侧 AI 讲"跑在哪、为什么要在那跑"。