Post-training / RL 训练基础设施 横纵分析报告

> 从 InstructGPT 到 o3，RLHF 到 GRPO，DeepSpeed-Chat 到 VeRL——Post-training 如何在三年内从一个"给模型刷礼貌"的微调步骤，变成了定义模型智能天花板的最关键环节。

一、一句话定义

Post-training / RL 训练基础设施是**在预训练完成后，用强化学习（RL）或偏好优化方法进一步训练大模型的技术和工程体系**。它的核心矛盾在于：**最有效的对齐方法（RLHF）工程最复杂，最简单的工程方案（DPO）效果上限最低**——技术和工程之间存在一个始终无法同时满足的三角关系：效果、复杂度、成本。

2026 年，这个矛盾被 GRPO 部分缓解，但真正的范式变化来自"推理时计算扩展"——它证明了一个颠覆性的事实：**在推理时花更多算力思考，比在训练时花更多算力学习更划算。**

二、技术背景：Post-training 到底在做什么？

> 前置知识已整理为独立文档 《Post-training / RL 训练基础设施前置知识》，涵盖 RLHF/DPO/GRPO、推理时计算扩展、训练框架等基础概念的通俗讲解。以下仅做快速串联。

Post-training 的核心不是"让模型多学知识"——预训练已经做了这件事。它做的是三件事：

1. **指令遵循**：让模型学会"用户问什么就答什么"而不是"用户问一句就续写一段"
2. **对齐**：让模型输出符合人类偏好——有帮助、诚实、无害
3. **推理能力**：让模型学会"思考"——在答题前生成内部推理过程

工程上的根本挑战是：RL 训练要求"训练中做推理"——当前模型生成回答（推理）→ 奖励模型打分 → 根据分数更新模型参数（训练）。这意味着训练集群和推理集群必须混在一起工作，而两者的硬件配置和软件栈完全不同。这个矛盾贯穿了整个 post-training 工程史。

三、纵向分析：从 InstructGPT 到 o3 的三年

3.1 InstructGPT：RLHF 的蓝图（2022 年 3 月）

2022 年 3 月，OpenAI 发表了 InstructGPT 论文（arXiv:2203.02155）。这篇论文在今天看来平淡无奇——RLHF 已经成为了常识。但在 2022 年，它是革命性的：**它第一次系统性地展示了"用人类反馈优化语言模型"的完整方法。**

InstructGPT 的三阶段流程成为后续所有工作的基石：

1. **SFT（监督微调）**：人工标注者写示范回答，让模型学会"问答"的格式
2. **RM 训练**：人类对不同模型的输出排序，训练一个奖励模型预测人类偏好
3. **PPO 优化**：用奖励模型的分数做 PPO 更新，优化策略模型

这个流程的工程代价今天看来是巨大的：训练时需要同时部署 **4 个模型**（策略模型 actor、价值模型 critic、冻结的参考模型 reference、奖励模型 reward），每一个都是完整的大模型。而且阶段 3 需要在训练过程中不断地让策略模型生成回答（rollout），然后奖励模型打分——也就是在训练集群里混入了推理工作负载。

InstructGPT 没有开源训练代码。OpenAI 展示了"可以这么做"，但"怎么在大规模上做"是一个黑盒。

3.2 工程化元年：DeepSpeed-Chat 和 DPO（2023）

2023 年是 post-training 从"论文方法"变成"可运行工程"的一年。

2023 年 8 月，微软发布 DeepSpeed-Chat——第一个系统化的 RLHF 分布式训练开源工具。它的核心创新叫"混合引擎"（Hybrid Engine）：训练和推理共享显存，避免重复加载模型。DeepSpeed-Chat 复现了 InstructGPT 的三阶段流程，并宣称训练 100B+ 参数模型的成本降低了 15 倍。

但 DeepSpeed-Chat 的问题是：**它太复杂了。** 4 个模型、混合引擎、ZeRO 优化、多机多卡——用户上手需要理解太多概念。实际上用起来也问题多多（2024 年以后 DeepSpeed-Chat 进入维护模式，不再活跃开发）。

2023 年 5 月，DPO 论文发表——一个简单到令人惊讶的优化方案。核心洞察：不需要训练奖励模型，直接用偏好数据做优化。DPO 把训练中的模型从 4 个减少到 2 个，而且不需要在训练中做推理（rollout）。

DPO 的工程意义怎么强调都不过分：之前做 RLHF 需要 4 个模型同时加载，意味着至少 8 张 A100（每个模型至少 2 张）。DPO 把门槛降到了 2 张卡。**个人开发者终于可以做对齐训练了。**

2023 年还有两个重要的工程贡献：

- **vLLM / PagedAttention（UC Berkeley，2023 年 9 月）**：解决了 KV Cache 显存碎片化的问题，成为 RLHF rollout 生成的标准推理引擎
- **TRL（Hugging Face）**：无缝集成 Hugging Face 生态，成为中小规模 RL 训练的事实标准

3.3 GRPO 与 DeepSeek 的突破（2024）

2024 年 2 月，DeepSeek 发表了 GRPO（Group Relative Policy Optimization）。GRPO 进一步简化：去掉 critic 模型，用 group scoring 替代。对同一个 prompt，生成 G 个回答，用 group 内的相对分数（而非绝对分数）做优化。

GRPO 的工程意义：**从 4 个模型降到 2 个，而且不需要训练和维护 critic 网络。** critic 网络的大小跟 actor 差不多，去掉它显存占用直接减半。

但 GRPO 最大的影响不在 2024 年 2 月——而是 2025 年 1 月的 DeepSeek-R1。

2024 年 9 月，OpenAI 发布了 o1——一个不需要大张旗鼓的发布会，但可能是 2024 年最重要的 AI 事件。o1 展示了"推理时计算扩展"（test-time compute scaling）：给模型更多时间思考，准确率会持续提升。这不是一个新概念

（早在 2022 年的 chain-of-thought 论文就展示过），但 o1 是第一次把它做到产品级别——在数学竞赛、编程竞赛上取得了超过任何以往模型的成绩。

o1 的技术细节没有公开，但行业共识是：它用 RL 训练模型"学会思考"——在训练阶段，模型通过 RL 探索学习如何生成有效的推理链，而不是简单地模仿人类标注的推理步骤。

3.4 R1 开源推理时扩展（2025 年 1 月）

2025 年 1 月，DeepSeek-R1 发布并发表在 Nature 上。这是 post-training 历史上最重要的开源贡献之一。

R1 的训练流程：

1. **冷启动**：用几千条人工编写的长推理链做 SFT，让模型学会"推理格式"
2. **RL 阶段**：用 GRPO + 可验证奖励（数学答案对错、代码是否通过测试）训练，完全不依赖人类标注
3. **拒绝采样 + SFT**：收集 RL 过程中生成的高质量回答，再做一轮 SFT
4. **全场景 RL**：加入语言一致性等辅助目标

R1 最惊人的发现是：**纯 RL（没有人类标注的推理轨迹）就能让模型自发涌现出自我反思、验证、动态策略调整等高级推理行为。** 换句话说，你不需要教模型"怎么思考"——你只需要告诉它"对"或"错"，它自己就能学会怎么思考。

工程上，R1 依赖两个关键基础设施：

- **GRPO**：去掉了 critic 和 reward model，使大规模 RL 训练的显存和调度复杂度大幅降低
- **VeRL / OpenRLHF**：字节的 VeRL 和社区的 OpenRLHF 框架支撑了分布式训练和 rollout 生成调度

3.5 o3 与基础设施成熟（2026 年 4 月）

2026 年 4 月，OpenAI 发布了 o3。o3 代表了推理时计算扩展的更进一步：不只是生成一条推理链，而是在多条候选推理链上做 beam search，用更复杂的验证机制筛选最佳答案。代价是推理成本更高——据说一次 o3 推理可能需要传统模型 10-50 倍的计算量。

到 2026 年，post-training 基础设施已经非常成熟：

- **6 大框架形成明确梯队**：LLaMA Factory（71k stars）微调首选、VeRL（21k stars）大规模训练首选、TRL（18k stars）中小规模快速验证、OpenRLHF（9k stars）算法最全、DeepSpeed-Chat 已进入维护、NeMo-Aligner 已归档
- **GRPO 和 REINFORCE++ 正在替代 PPO**：去掉 critic 网络成为行业共识
- **推理时计算扩展成为标配**：从 o1 到 R1 到 o3，每半年一代，每代的推理精度大幅提升但成本也在增长

四、横向分析：2026 年 Post-training 技术格局

4.1 算法方法对比

方法	提出时间	训练中模型数	需要奖励模型?	需要rollout?	显存需求	工程复杂度	适用场景
PPO-RLHF	2022	4 (Actor+Critic+Ref+RM)	✅	✅	~4x 模型	⭐⭐⭐⭐⭐	通用对齐，效果好但最贵
DPO	2023	2 (Policy+Ref)	❌	❌	~2x 模型	⭐⭐	偏好对齐，简单但上限靠数据
GRPO	2024	2 (Policy+Ref)	❌	✅	~2x 模型	⭐⭐⭐	可验证任务（数学/代码），性价比高
KTO	2024	2	❌	❌	~2x 模型	⭐⭐	只有"好/坏"标签，无成对偏好
ORPO	2024	1	❌	❌	~1x 模型	⭐	在 SFT 中联合优化，最轻量
REINFORCE++	2025	1-2	❌	✅	~1-2x 模型	⭐⭐	GRPO 的进一步简化

趋势非常清晰：从复杂到简单。 2022 年的 PPO-RLHF 需要 4 个模型，2025 年的 ORPO 只需要 1 个。但需要注意的是，"简单"不等于"效果更好"——DPO 比 PPO 简单，但在复杂推理任务上的效果上限不如 PPO+在线探索。

GRPO 是目前最有吸引力的折中方案：训练中只有 2 个模型（没有 critic 和 reward model），但通过在线 group sampling 保持了 RL 的探索能力。DeepSeek-R1 的成功让 GRPO 成为 2025-2026 年最受关注的算法。

4.2 训练框架对比

框架	开发商	发布时间	活跃度	支持算法	最大规模	核心特点
DeepSpeed-Chat	微软	2023-08	维护模式	PPO	100B+	最早的 RLHF 工具，混合引擎
TRL	Hugging Face	2023	⭐⭐⭐⭐	PPO/DPO/GRPO/KTO	7-70B	HuggingFace 生态，易上手
NeMo-Aligner	NVIDIA	2024	❌已归档	PPO/DPO	企业级	GPU 优化最强但不再维护
OpenRLHF	社区	2024	⭐⭐⭐⭐	PPO/DAPO/REINFORCE++/多模态	大规模	算法最全，架构现代
VeRL	字节跳动	2025	⭐⭐⭐⭐⭐	PPO/GRPO/DAPO	**超大规模**	vLLM+Ray 调度，增长最快
LLaMA Factory	社区	2023	⭐⭐⭐⭐⭐	DPO/ORPO/KTO（有限 RL）	~70B	**71k stars**，微调场景绝对领先

OpenRLHF vs VeRL —— 2026 年的主流选择：

OpenRLHF（社区驱动）胜在"算法全面"——支持 PPO、DAPO、REINFORCE++，甚至多模态 VLM 的 RL。它基于 Ray 做分布式调度，跟 vLLM 集成紧密。如果你的团队需要尝试多种 RL 算法，OpenRLHF 是首选。

VeRL（字节跳动内部验证）胜在"大规模性能"——DAPO 论文中披露，VeRL 支撑了 GPT-5 级别模型的 RL 训练。它用 vLLM 做 rollout 生成，Ray 做调度，在数十亿参数的规模上性能比 OpenRLHF 更高。如果你的团队在大 Scale 上做 RL 训练，VeRL 更合适。

LLaMA Factory 是一个异类——它是最受欢迎的微调框架（71k stars），但 RL 功能有限。它更适合"用 LoRA 微调 + 简单对齐"的场景，不适合做全参数的大规模 RL 训练。

4.3 推理时计算扩展的工程实现

推理时计算扩展（test-time compute scaling）是 2024-2026 年 post-training 最令人振奋的方向。它在工程上不是"一种方案"，而是一条从简单到复杂的路线：

方法	描述	计算开销	效果提升	工程复杂度
Best-of-N	生成 N 个答案选最好的	N×	中等	⭐
CoT（Chain-of-Thought）	模型输出推理过程	~2-5×	高	⭐（模型内建）
PRM 引导搜索	每步推理打分引导搜索	~5-20×	很高	⭐⭐⭐⭐⭐
MCTS	树搜索多路径推理	~10-50×	最高	⭐⭐⭐⭐⭐
Self-consistency	多次采样+投票	N×	中等	⭐

o1 的内部机制推测是 CoT + PRM 的组合——模型生成推理链，PRM 在每一步做验证，质量差时回溯。**o3** 在此基础上加了很多倍的 beam search——生成多条候选推理链，用更复杂的验证器筛选。

工程挑战：推理时扩展的成本是线性的——10 倍的计算量意味着 10 倍的推理成本和延迟。o3 的推理成本可能达到普通 GPT-4o 调用的 10-50 倍。这让它只适合"质量比成本重要"的场景（竞赛编程、复杂推理），而不适合日常问答。

4.4 成本对比：到底贵不贵？

Post-training 的算力成本远低于预训练，但绝对数值仍然很高：

方法	典型 GPU 需求	训练时间（参考）	相对预训练成本
预训练（175B 模型）	1000+ GPU	数月	1×
PPO-RLHF（同规模）	64-256 GPU	数天到数周	~2-5%
DPO（同规模）	16-64 GPU	1-3 天	~0.5-1%
GRPO（同规模，有 rollout）	64-128 GPU	2-7 天	~1-3%
R1 风格训练（含多轮 RL）	128-512 GPU	1-2 周	~3-8%
o1/o3 推理时扩展（单次推理）	1 GPU（但用更久）	数秒到数分钟	N/A

Post-training 的成本不是线性增长的——R1 风格训练因为涉及多轮 RL（RL→SFT→RL 循环），总成本可能接近预训练的 10%。相比之下，单轮 DPO 的成本几乎可以忽略。

五、横纵交汇洞察

5.1 历史如何塑造了今天的格局

2026 年的 post-training 格局，是三次范式转换的结果：

第一次：InstructGPT 到 DeepSpeed-Chat（2022-2023）——从研究到工程。 InstructGPT 证明了 RLHF 有效，DeepSpeed-Chat 让 RLHF 可运行。没有 DeepSpeed-Chat，RLHF 会停留在"只有 OpenAI 能做的事"。开源工程力量把对齐训练带给了整个行业。

第二次：DPO 到 GRPO 到 R1（2023-2025）——从慢到快到开源追平。 DPO 让对齐变得简单便宜，GRPO 让 RL 训练去掉最重的组件，R1 把推理时扩展的能力开源给了整个世界。每一步都在降低门槛、扩大参与。

第三次：o1 到 o3（2024-2026）——"训练时思考"到"推理时思考"。 这是最根本的范式转变。在此之前，"让模型更聪明"等于"训练用更多数据和算力"。但推理时计算扩展证明：**推理时花的算力比训练时花的算力更值。** o1/o3 的训练成本可能只比 GPT-4 多 20-30%，但推理成本高 10-50 倍——这种"训练轻推理重"的模式跟传统 AI 完全相反。

5.2 算法的纵向差异

RLHF（2022）是"完整但过重"的方案——效果好但工程代价太大，4 个模型同时训练是大多数团队承受不了的。

DPO（2023）是"轻量化但天真的方案"——它假设离线偏好数据足够好，但实际上"什么样的回答是好回答"需要在训练过程中动态探索。DPO 在做完训练后无法再针对新的偏好做微调。

GRPO（2024）找到了"成本-效果"的甜蜜点——没有 RLHF 那么重，没有 DPO 那么简单，但在这两个极端之间找到了最实用的平衡。R1 的成功不是偶然——GRPO 恰好够轻量又够强。

推理时计算扩展（2024-2026）是对"什么样的思考方式最好"的终极追问——o1→R1→o3 每条线都在探索"让 AI 花更多时间思考"的不同方式。R1 走的是"用 RL 学会自我思考"，o3 走的是"用暴力搜索找到最好的答案"。

5.3 核心优势的历史根源

DeepSeek 在 post-training 上的突破来自"务实选择"——不是选了最先进的算法，而是选了最实用的算法。 GRPO 没有 PPO 的理论完整，没有 DPO 的简单好用，但它在"成本-效果"的折中上做得最好。DeepSeek 在 R1 上的成功证明了 GRPO 这个选择是对的。

OpenAI 在推理时计算扩展上的领先来自"先发积累"——从 InstructGPT 到 o1 到 o3，OpenAI 在做 RL 训练上比其他公司多做了 3 年。PRM、verifier、beam search——这些技术在 2023 年（o1 发布的前一年）就已经有论文发表。OpenAI 在 post-training 上的积累是行业最深厚的。

开源框架（VeRL、OpenRLHF）的崛起来自"工业界需求倒逼"——2024-2025 年，越来越多公司想做 RL 训练，但 DeepSpeed-Chat 太老、TRL 太小（规模上不去）。字节开源 VeRL、社区做 OpenRLHF，是因为市场需要"能在大规模上跑 RL"的工具。

5.4 劣势的历史根源

DPO 的劣势来自"静态优化无法替代动态探索"——这是跟 RL 相比的结构性缺陷。DPO 在离线数据上做优化，永远无法发现训练数据中没有的"更好的回答"。这解释了为什么 GRPO 虽然更复杂但效果上限更高。

DeepSpeed-Chat 的劣势来自"成了先驱但也成了历史"——它在 2023 年之后没有再跟上行业节奏。GRPO 支持？没有。vLLM 集成？没有。新框架（VeRL、OpenRLHF）都在用更现代的技术栈重建了 DeepSpeed-Chat 的功能。

PPO 的劣势来自"一个被证明过度的设计"——critic 网络在传统 RL 中是必要的（需要估计一个状态的价值），但在语言模型中，group scoring（GRPO 的方式）已经能提供足够好的 baselines。PPO 的 critic 网络在语言模型场景下多余了。

5.5 未来推演

剧本一：最可能的方向——GRPO + VeRL 成为行业标配

GRPO 会成为对齐训练的"标配算法"——比 DPO 强，比 PPO 轻。VeRL 和 OpenRLHF 成为主要的开源训练框架。推理时计算扩展成为高端模型的标配能力。

这个剧本里，post-training 的成本会持续下降（更高效的算法 + 更成熟的框架），更多中小团队能负担得起 RL 训练。推理时计算扩展会成为模型差异化的关键——"谁的模型更会思考"比"谁的模型预训练数据更多"更能衡量模型质量的差异。

剧本二：最令人兴奋的方向——推理时计算扩展改变"成本曲线"

如果推理时计算扩展的成本持续下降（通过更好的 PRM、更高效的搜索算法），o3 级别的推理能力可能变得负担得起。未来的 AI 模型可能"训练相对便宜，推理相对贵但按需分配"——简单问题用低成本模式，困难问题花更多算力思考。

这个变化会倒逼整个 AI 基础设施重新设计：推理芯片、模型压缩（量化/蒸馏）、调度系统都需要适应"推理成本可变"的新模式。

剧本三：最危险的方向——post-training 的效果提升开始递减

GRPO 的改进空间有限，DPO 的变体趋近饱和，推理时计算扩展的成本曲线太陡峭。到了某个点，post-training 带来的边际收益开始下降——更多的 RL 训练不再带来显著的推理能力提升，更多的推理时计算不再显著提升准确率。

如果这个剧本成为现实，post-training 会从"AI 研发的核心环节"降级为"标准流程步骤"，行业关注点会回到预训练（更大的模型、更多的数据）或新的范式突破。

最后的想法

Post-training 可能是 AI 行业最"不被看见但至关重要"的一层。预训练吸引了所有的关注和投资——但真正决定一个模型"好不好用"的，往往是 post-training 做得怎么样。

2024-2026 年最重要的两个洞见都来自 post-training：

1. **GRPO 证明了你不需要最复杂的 RL 来做最好的对齐**——去掉 critic、去掉 reward model，剩下 GRPO 的简洁和 R1 的结果。
2. **推理时计算扩展证明了你不需要更大的模型来做更难的任务**——让现有模型"想更久"比训练一个 5 倍大的模型更划算。

这两个洞见本质上说的是同一件事：**AI 的智能水平不取决于规模（参数数量、训练数据大小），而取决于"在推理时花了多少努力去思考"。** 这个认识的转变，可能是 2024-2026 年 AI 行业最重要的认知升级。

六、信息来源

- InstructGPT 论文: arXiv:2203.02155 (2022.03)
- DPO 论文: arXiv:2305.18290 (2023.05)
- Let's Verify Step by Step: arXiv:2305.20050 (2023.05)
- DeepSpeed-Chat: arXiv:2308.01320 (2023.08)
- vLLM/PagedAttention: arXiv:2309.06180 (2023.09)
- GRPO/DeepSeekMath: arXiv:2402.03300 (2024.02)
- KTO: arXiv:2402.01306 (2024.02)
- ORPO: arXiv:2403.07691 (2024.03)
- DeepSeek-R1: arXiv:2501.12948 (2025.01) / Nature 645, 633-638

- DAPO: arXiv:2503.14476 (2025.03)
- OpenAI o1: https://openai.com/index/learning-to-reason-with-llms/ (2024.09)
- OpenAI o3: 2026.04 发布
- OpenRLHF: https://github.com/OpenRLHF/OpenRLHF
- VeRL: 字节跳动开源 RL 训练框架
- LLaMA Factory: https://github.com/hiyouga/LLaMA-Factory

本文是横纵分析系列的第 23 篇报告。方法论：横纵分析法——纵向沿时间轴追溯技术演进，横向对比当下竞争格局。